厦门大学信息学院 本科选修课
2024-2025 第二学期

模 式 识 别
Pattern Recognition

主 讲：王程教授、陈龙彪副教授
厦门大学信息学院计算机科学与技术系
人工智能引论101计划系列课程



第二章 聚类分析
2.1 随机矢量

2.1 特征矢量和特征空间

- ***n*维特征矢量**

$$\vec{X} = (X_1, X_2, \ldots, X_n)'$$

- ***n*维特征空间：$\vec{X}$ 的全体构成的*n*维空间**

  记为 X^n 或 R^n 或 Ω

- **特征矢量是随机矢量**

2.1 随机矢量的描述

（一）随机矢量的分布函数

（二）随机矢量的数字特征

（三）随机变量、随机矢量间的统计关系

（四）随机矢量的变换

2.1 随机矢量的描述

（一）随机矢量的分布函数

设 $\vec{X}=(X_1,X_2,...,X_n)'$为随机矢量

$\vec{x}=(x_1,x_2,...,x_n)'$ 为确定性矢量

- **随机矢量的联合概率分布函数**

$$F(x_1,x_2,...,x_n)=P(X_1\le x_1,X_2\le x_2,...,X_n\le x_n)$$

写为矢量形式 $F(\vec{x})=P(\vec{X}\le\vec{x})$

- **随机矢量的联合概率密度函数**

$$p(x_1,x_2,...,x_n)\overset{\Delta}{=}p(\vec{x})=\partial^n F(x_1,x_2,...,x_n)/\partial x_1\partial x_2...\partial x_n$$

- **类概率分布和类概率密度函数**

$$F(\vec{x}\,|\,\omega_i)=P(\vec{X}\le\vec{x}\,|\,\omega_i)$$

$$p(\vec{x}\,|\,\omega_i)=\partial^n F(x_1,x_2,\cdots,x_n\,|\,\omega_i)/\partial x_1\partial x_2\cdots\partial x_n$$

2.1 随机矢量的数字特征

（1）均值矢量（期望矢量）

n维随机矢量 $\vec{X}$ 的数学期望 $\vec{\mu}$ 定义为

$$\vec{\mu} = E[\vec{X}] \overset{\Delta}{=} \vec{\vec{X}} = \begin{pmatrix} E[X_1] \\ E[X_2] \\ \vdots \\ E[X_n] \end{pmatrix} \overset{\Delta}{=} \int_{X^n} \vec{x} p(\vec{x}) d\vec{x}$$

其中，$\vec{\mu}$ 的分量

$$\mu_i = E[X_i] = \int_{-\infty}^{\infty} x_i p(x_i) dx_i = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} x_i p(x_1, x_2, \cdots, x_n) dx_1 dx_2 \cdots dx_n \overset{\Delta}{=} \bar{X}_i$$

2.1 随机矢量的数字特征

（2）条件期望

$$\vec{\mu}_{\omega_i} = E[\vec{X}\,|\,\omega_i] = \int_{\vec{x}\in\omega_i} \vec{x}\,p(\vec{x}\,|\,\omega_i)\,d\vec{x}$$

（3）协方差矩阵

$$\Sigma = E[(\vec{X}-\vec{\bar{X}})(\vec{X}-\vec{\bar{X}})'] = \int_{X^n} (\vec{x}-\vec{\mu})(\vec{x}-\vec{\mu})'\,p(\vec{x})\,d\vec{x} \overset{\Delta}{=} \left(\sigma_{ij}^2\right)_{n\times n}$$

其中，σ_{ij}^2 是随机矢量$\vec{X}$ 的第*i*个分量与第*j*个分量的协方差。

$$\sigma_{ij}^2 = E[(X_i-\bar{X}_i)(X_j-\bar{X}_j)] = \int_{-\infty}^{\infty}\int (x_i-\mu_i)(x_j-\mu_j)\,p(x_i,x_j)\,dx_i dx_j$$

当*i*=*j*时，σ_{ii}^2 便是X_i的方差。

2.1 随机矢量的数字特征

(4) 自相关矩阵

$$R = E[\vec{X}\vec{X}']$$

$$\Sigma = R - \vec{\bar{X}}\ \vec{\bar{X}}' = R - \vec{\mu}\vec{\mu}'$$

(5) 相关系数

$$r_{ij} = \sigma_{ij}^2 / (\sigma_{ii}\ \sigma_{jj})$$

由柯西-许瓦兹不等式: $(E[VW])^2 \le E[V^2]E[W^2]$

可得 $|\sigma_{ij}^2| \le \sigma_{ii}\sigma_{jj}$

$$-1 \le r_{ij} \le 1$$

相关系数矩阵定义为 $\mathbf{r} = [r_{ij}]_{n\times n}$

2.1 随机矢量的数字特征

(6) 协方差矩阵的非负定性

定义：设*A*为对称矩阵，对任意矢量 $\vec{x}$，$\vec{x}'A\vec{x}$是*A*的二次型。

若对任意矢量$\vec{x}$ 恒有$\vec{x}'A\vec{x} \geq 0$

则称*A*是非负定矩阵。

若对任意的$\vec{x} \neq 0$恒有$\vec{x}'A\vec{x} > 0$

则称*A*是正定矩阵。

对于正定矩阵，其各阶主子式非零（包括$|A| \neq 0$）。

- **协方差矩阵是非负定的。即**

$$\forall \vec{x} \rightarrow \vec{x}' \sum \vec{x} \geq 0$$

2.1 随机变量、随机矢量间的统计关系

(1) 不相关

随机矢量 $\vec{X}$ 的第i个分量 X_i 和第j个分量 X_j，若有

$$\sigma_{ij}^2 = E[(X_i - \bar{X}_i)(X_j - \bar{X}_j)] = 0, \quad (i \neq j)$$

则称它们不相关。这等价于

$$E(X_i X_j) = E[X_i]E[X_j]$$

随机矢量 $\vec{X}$ 和 $\vec{Y}$ 不相关的充要条件是互协方差矩阵

$$\mathrm{cov}(\vec{X}, \vec{Y}) = \phi$$

亦即

$$E(\vec{X}\vec{Y}') = E[\vec{X}]E[\vec{Y}']$$

2.1 随机变量、随机矢量间的统计关系

(2) 正交

随机矢量 $\vec{X}$ 和 $\vec{Y}$ 若满足

$$E[\vec{X}'\vec{Y}]=0$$

则称 $\vec{X}$ 和 $\vec{Y}$ 正交。

(3) 独立

若随机矢量 $\vec{X}$ 和 $\vec{Y}$ 的联合概率密度函数满足

$$p(\vec{x},\vec{y})=p(\vec{x})p(\vec{y})$$

则称 $\vec{X}$ 和 $\vec{Y}$ 独立。

2.1 不相关 正交 独立的关系

(1) 不相关

$$E(\vec{X}\vec{Y}') = E[\vec{X}]E[\vec{Y}']$$

(2) 正交

$$E[\vec{X}'\vec{Y}] = 0$$

(3) 独立

$$p(\vec{x}, \vec{y}) = p(\vec{x})\,p(\vec{y})$$

(1) 不相关和独立的关系

- 独立必不相关，反之不然
- 两个变量或矢量服从正态分布时不相关和独立等价

(2)不相关和正交的关系

- 当有一个变量或矢量的期望为零，不相关和正交等价
- 否则没关系

2.1 随机矢量的变换

$$\vec{Y}=\begin{pmatrix}Y_1\\Y_2\\\vdots\\Y_n\end{pmatrix}=\begin{pmatrix}g_1(X_1,X_2,\cdots,X_n)\\g_2(X_1,X_2,\cdots,X_n)\\\vdots\\g_n(X_1,X_2,\cdots,X_n)\end{pmatrix}\overset{\triangle}{=}\begin{pmatrix}g_1(\vec{X})\\g_2(\vec{X})\\\vdots\\g_n(\vec{X})\end{pmatrix}\overset{\triangle}{=}\vec{g}(\vec{X})$$

若它们的函数关系是一一对应的，则有

$$p(\vec{y})=\frac{p(\vec{x})}{|J|}$$

式中，雅可比行列式

$$J=\begin{vmatrix}\dfrac{\partial g_1}{\partial x_1} & \dfrac{\partial g_1}{\partial x_2} & \cdots & \dfrac{\partial g_1}{\partial x_n}\\\dfrac{\partial g_2}{\partial x_1} & \dfrac{\partial g_2}{\partial x_2} & \cdots & \dfrac{\partial g_2}{\partial x_n}\\\vdots & \vdots & & \vdots\\\dfrac{\partial g_n}{\partial x_1} & \dfrac{\partial g_n}{\partial x_2} & \cdots & \dfrac{\partial g_n}{\partial x_n}\end{vmatrix}$$

2.1 随机矢量的线性变换

$$\vec{Y}=\begin{pmatrix}Y_1\\Y_2\\\vdots\\Y_n\end{pmatrix}=\begin{pmatrix}a_{11}X_1+a_{12}X_2\cdots+a_{1n}X_n\\a_{21}X_1+a_{22}X_2\cdots+a_{2n}X_n\\\vdots\\a_{n1}X_1+a_{n2}X_2\cdots+a_{nn}X_n\end{pmatrix}=\begin{pmatrix}a_{11}a_{12}\cdots a_{1n}\\a_{21}a_{22}\cdots a_{2n}\\\vdots\\a_{n1}a_{n2}\cdots a_{nn}\end{pmatrix}\begin{pmatrix}X_1\\X_2\\\vdots\\X_n\end{pmatrix}=A\vec{X}$$

此时，雅可比行列式：$J=|A|$

$\vec{Y}$的概率密度函数：$p(\vec{y})=p(\vec{x})/\|A\|$

$\vec{Y}$的均值矢量：$\vec{\mu}_y=E[\vec{Y}]=AE[\vec{X}]=A\vec{\mu}_x$

$\vec{Y}$的协方差矩阵：$\Sigma_y=E[(\vec{Y}-\vec{\mu}_y)(\vec{Y}-\vec{\mu}_y)']$

$$=AE[(\vec{X}-\vec{\mu}_x)(\vec{X}-\vec{\mu}_x)']A'=A\Sigma_xA'$$

2.1 正态分布(或高斯分布)

- 正态分布有极其广泛的实际背景, 例如测量误差, 人的生理特征尺寸如身高、体重等 ,正常情况下生产的产品尺寸:直径、长度、重量高度, 炮弹的弹落点的分布等, 都服从或近似服从正态分布.
- 另一方面,有些分布(如二项分布、泊松分布)的极限分布是正态分布.
- 所以,无论在实践中,还是在理论上,正态分布是概率论中最重要的一种分布.

2.1 正态分布(或高斯分布)

（一）正态分布的定义

(1) 一维随机变量的正态分布

一维随机变量X服从正态分布，记为$X\sim N(\mu,\sigma^2)$，其概率密度函数为

$$p(x)=\frac{1}{\sqrt{2\pi}\sigma}\exp[-\frac{(x-\mu)^2}{2\sigma^2}]$$

式中，μ为X的数学期望，σ^2为方差。

$$\mu=E[X]=\int_{-\infty}^{\infty}xp(x)dx$$

$$\sigma^2=E[(X-\mu)^2]=\int_{-\infty}^{\infty}(x-\mu)^2p(x)dx$$

2.1 随机矢量正态分布

正态分布随机矢量 $\vec{X}=(X_1,X_2,\cdots,X_n$的概率密度函数

$$p(x_1,x_2,\cdots,x_n)=p(\vec{x})=\frac{1}{(2\pi)^{n/2}\,|\Sigma|^{1/2}}\exp[-\frac{1}{2}(\vec{x}-\vec{\mu})'\Sigma^{-1}(\vec{x}-\vec{\mu})]$$

式中，$\vec{\mu}$ 为 $\vec{X}$ 的期望矢量，　Σ为 $\vec{X}$的协方差矩阵

$$\vec{\mu}=E[\vec{X}]=(E[X_1],E[X_2],\cdots,E[X_n])'$$

$$\Sigma=E[(\vec{X}-\vec{\mu})(\vec{X}-\vec{\mu})']=\begin{pmatrix}\sigma_{11}^2 & \sigma_{12}^2 & \cdots & \sigma_{1n}^2\\ \sigma_{21}^2 & \sigma_{22}^2 & \cdots & \sigma_{2n}^2\\ \vdots & \vdots & & \vdots\\ \sigma_{n1}^2 & \sigma_{n2}^2 & \cdots & \sigma_{nn}^2\end{pmatrix}$$

2.1 正态分布随机矢量的性质

- 分布函数完全由$\vec{\mu}$ 和Σ确定
- 等概率密度点的轨迹为一超椭球面
- 对正态分布，不相关等价于独立
- 其边缘密度和条件密度仍然是正态分布
- 正态分布随机矢量的线性变换仍为正态随机矢量
- 其分量的线性组合是一正态随机变量

第二章 聚类分析

2.1 聚类的基本概念

2.2 模式相似性测度

2.3 类的定义与类间距离

2.4 聚类算法

2.1 聚类的基本概念

（一）聚类分析的基本思想

（二）特征量的类型

（三）方法的有效性

（一）聚类分析基本思想

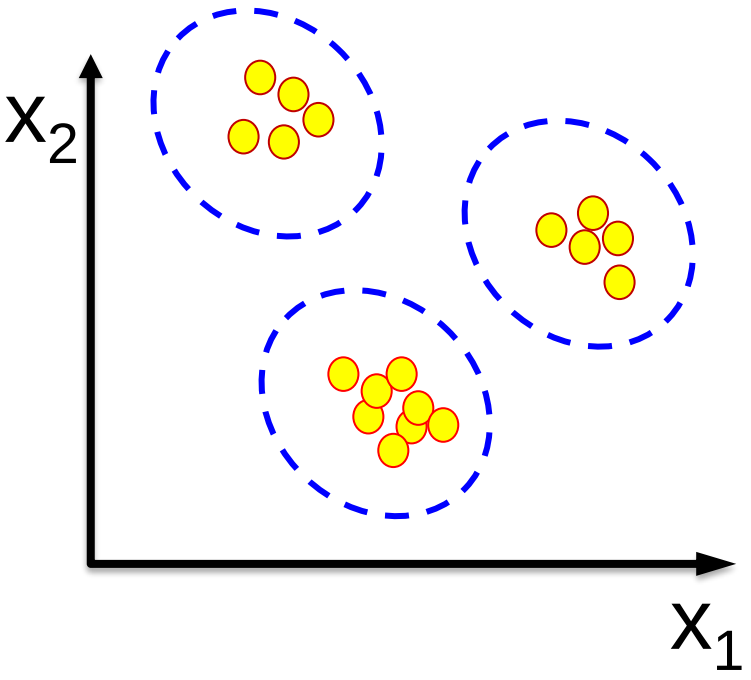
假设：对象集客观存在着若干个自然类，每个自然类中个体的某些属性具有较强的相似性。



（一）聚类分析基本思想

方法：根据待分类的模式属性或特征相似程度进行分类，相似的模式归为一类，不相似的模式分划到不同类中。





（一）聚类分析基本思想

方法：根据待分类的模式属性或特征相似程度进行分类，相似的模式归为一类，不相似的模式分划到不同类中。

基本内容

- 特征提取
- 模式相似性度量
- 点与类间的距离
- 类与类间的距离
- 聚类准则及聚类算法
- 有效性分析

2.1 聚类的基本概念

（一）聚类分析的基本思想

（二）特征量的类型

（三）方法的有效性

（二）特征量的类型

- **物理量：直接反映特征的实际物理意义。**

  如:长度、重量、速度等。处理前需要离散化。

- **次序量：反映特征的次序关系或等级。**

  如:产品的等级、病症的级或期。已是离散量。

- **名义量：反映样本的状态特征，非数值的。**

  如男性与女性、事物的状态、种类等。需要数值化。这些特征的数值指标既无数量含义，也无次序关系，只是用数字代表各种状态。

2.1 聚类的基本概念

（一）聚类分析的基本思想

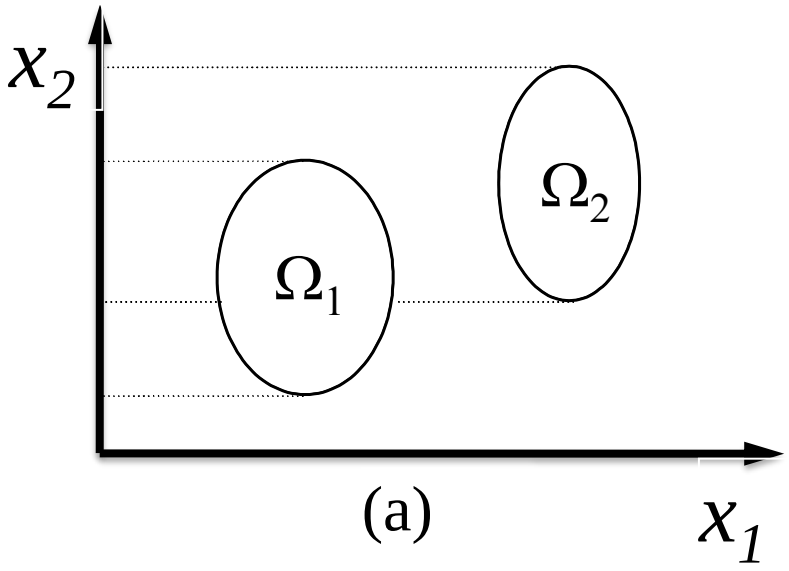
（二）特征量的类型

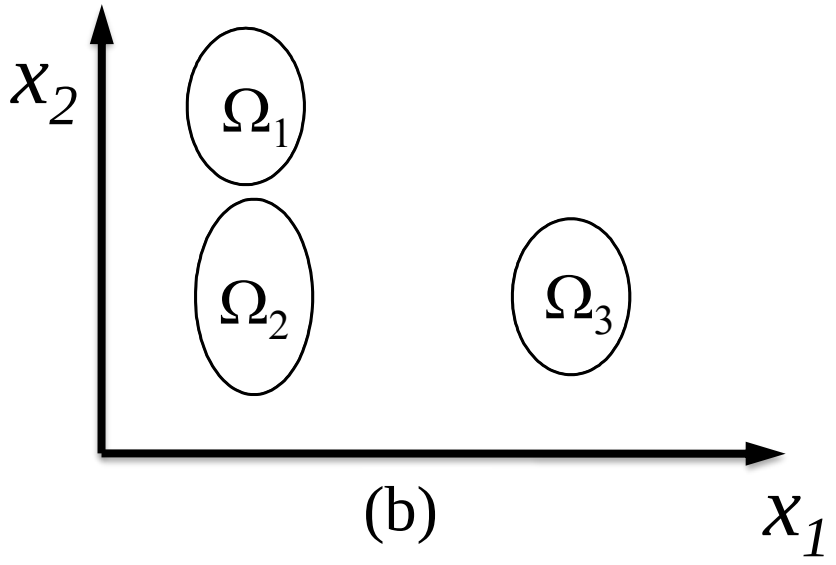
（三）方法的有效性

（三）方法的有效性

(1) 特征选取不当或不足使分类无效

(2) 特征选取过多可能有害无益，且增加分析负担



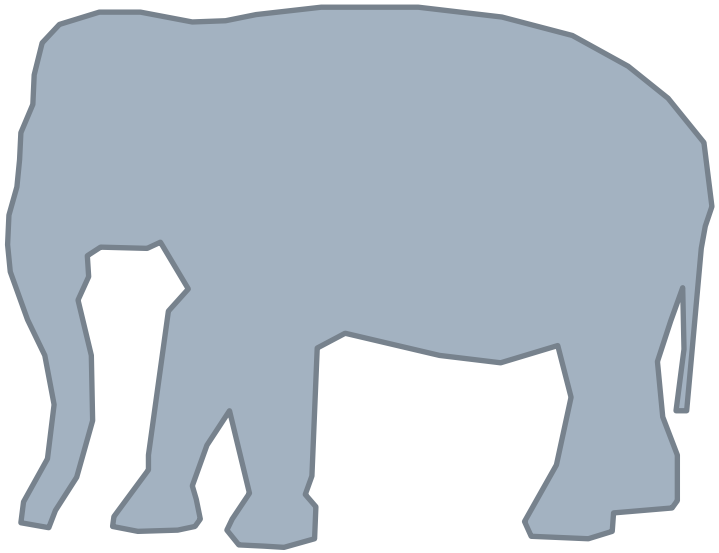


（三）方法的有效性



这是什么？

- A 墙纸
- B 动物
- C 天空
- C 织物



这是什么？

- A 大象
- B 长颈鹿
- C 斑马

班克斯(Banksy)

（三）方法的有效性





这是什么？

- A 墙纸
- B 动物
- C 天空
- C 织物

The Elephant in the Room by #Banksy

（三）方法的有效性



房间里的大象y #Banksy

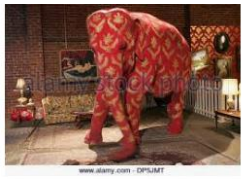


Sep 16, 2006 - Los Angeles, CA, USA ...
alamy.com


Banksy | enwp.org ...
flickr.com


Banksy | Elephant art, Banksy art, Banksy
pinterest.at


Sep 16, 2006 - Los Angeles, CA, USA ...
alamy.com


Sep 16, 2006 - Los Angeles, CA, USA ...
alamy.com

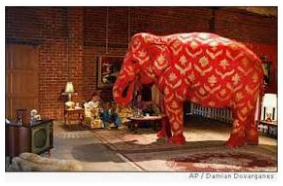

Sep 16, 2006 - Los Angeles, CA, USA ...
alamy.com


Banksy: quando la provocazione diventa ...
successo.com


Sep 16, 2006 - Los Angeles, CA, USA ...
alamy.com


Stephen Lemon questions fintech ...
businessinsider.com


Eléphant | A Lady in the City
aladyinthecity.wordpress.com


Street artist Banksy welcomes visitors ...
chron.com


Tai, a 38-year-old Asian elephant ...
stock.adobe.com


Artist Gallery | Widewalls
widewalls.ch


When Is It Okay to Use A...
artsy.net


bansky | Elephant painting ...
pinterest.nz


London Art News: Jolie buys Banksy art
coxsoft.blogspot.com


Banksy- Elephant in the Room...Thanks ...
pinterest.ca



Is the Banksy exhibition in Sydney ...
londonerinsydney.com


Artwork by Banksy Ne...
gettyimages.fi


red dirt mule | Elephant art, Elephant ...
pinterest.com


Street Artist" Thierry Guetta ...
stencilrevolution.com













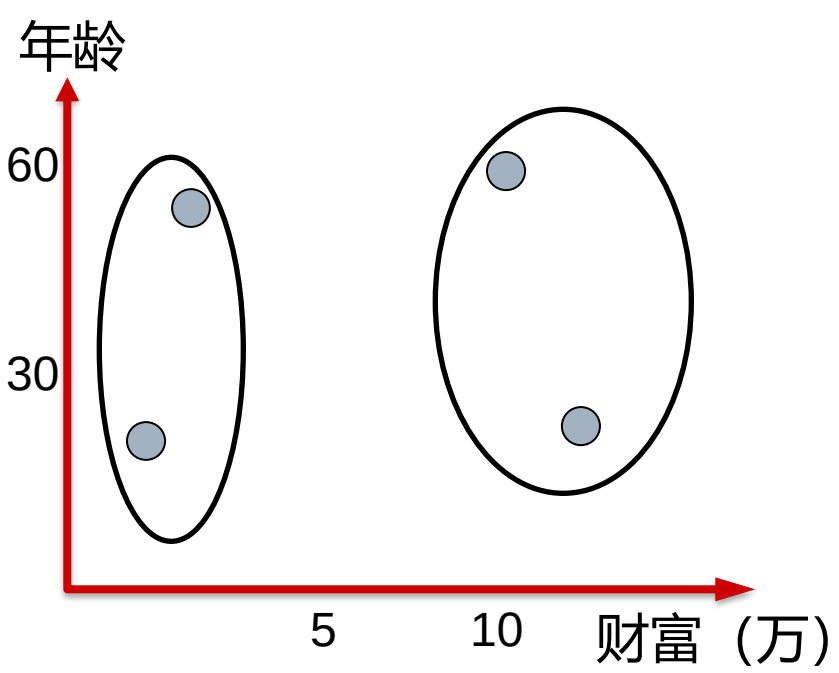


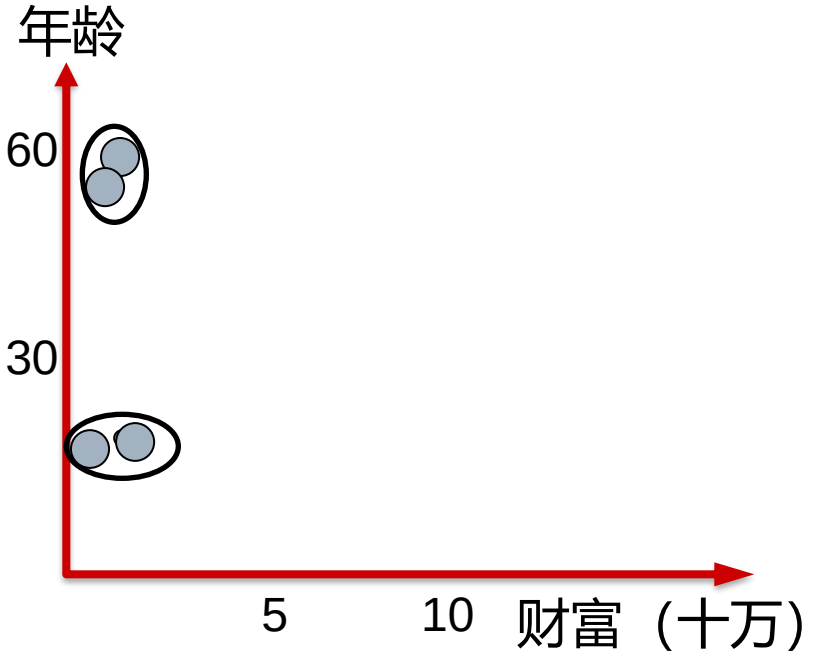


The Elephant in the Room by #Banksy

（三）方法的有效性

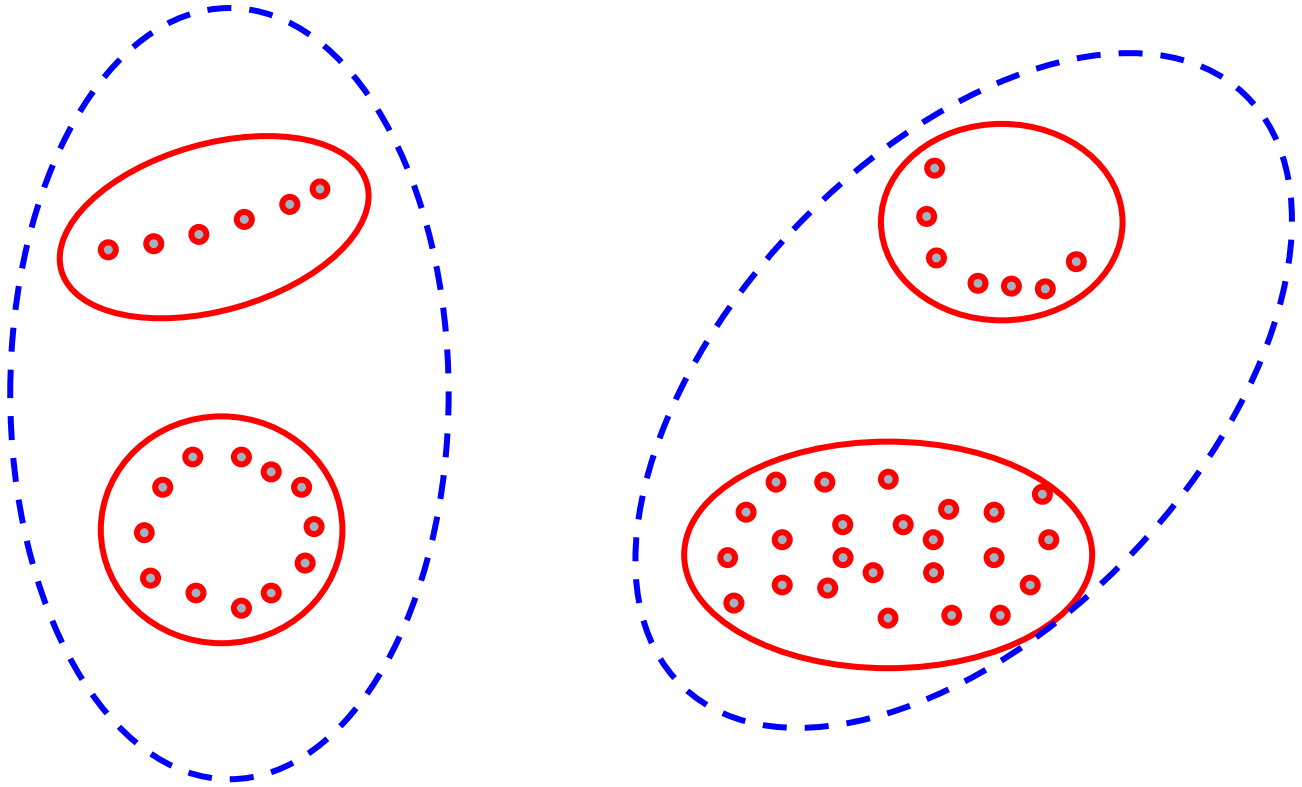
(3) 特征量纲对聚类结果的影响





（三）方法的有效性

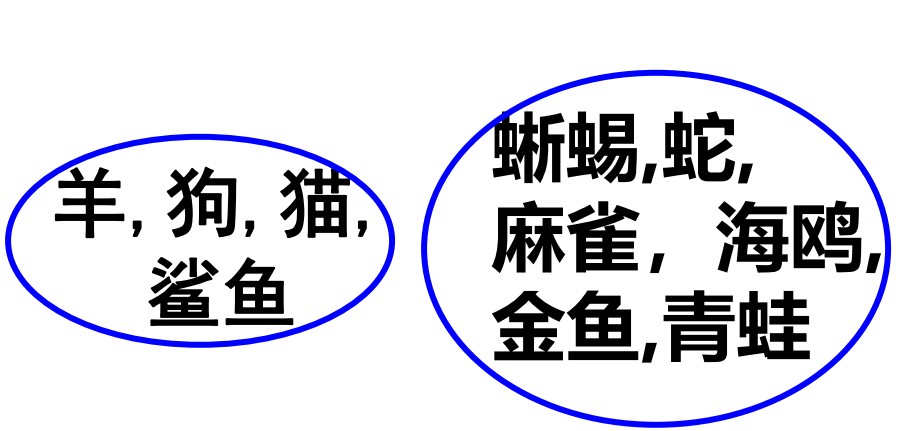
(4) 距离测度对聚类结果的影响



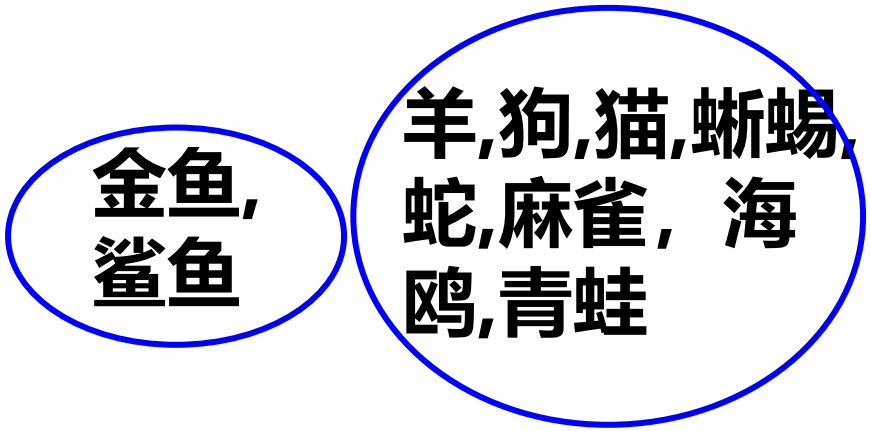
数据的粗聚类是两类,细聚类为4类

（三）方法的有效性

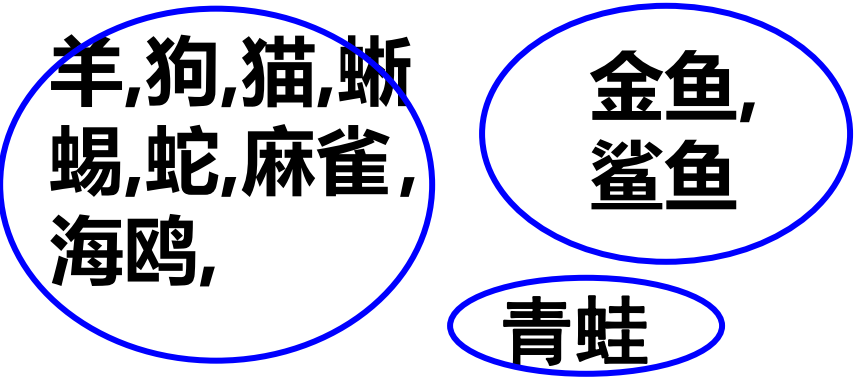
(5) 聚类准则对聚类结果的影响



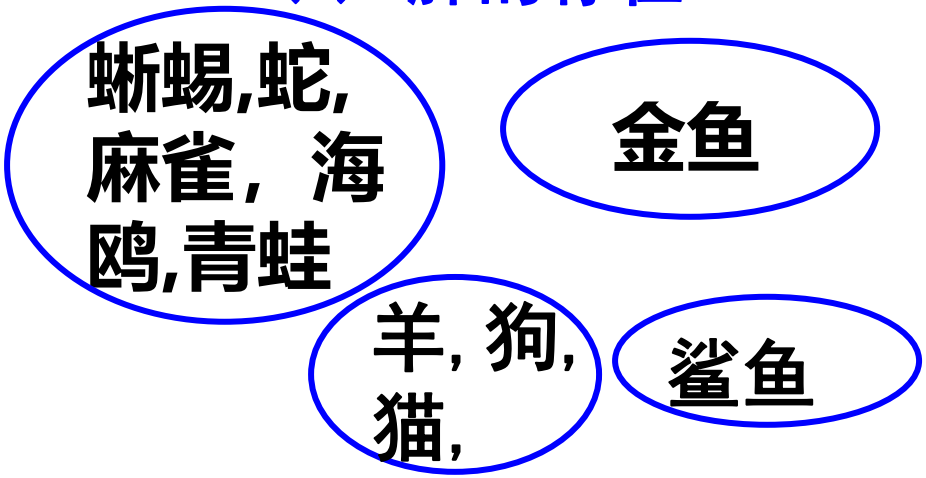
(a) 繁衍后代的方式



（b） 肺的存在



(c) 生存环境



(d) 繁衍后代的方式和是否存在肺

第二章 聚类分析

2.1 聚类的基本概念

2.2 模式相似性测度

2.3 类的定义与类间距离

2.4 聚类算法

2.2 模型相似性测度

（一） 距 离 测 度

（二） 相 似 测 度

（三） 匹 配 测 度

（一）距离测度

Distance (or Dissimilarity) Measure

设特征矢量 $\vec{x}$ 和 $\vec{y}$ 的距离为 $d(\vec{x},\vec{y})$

则 $d(\vec{x},\vec{y})$ 一般应满足如下公理

(1) $d(\vec{x},\vec{y}) \geq 0$, 当且仅当 $\vec{x}=\vec{y}$ 时等号成立，即 $d(\vec{x},\vec{y})=0 \Leftrightarrow \vec{x}=\vec{y}$

(2) $d(\vec{x},\vec{y})=d(\vec{y},\vec{x})$

(3) $d(\vec{x},\vec{y}) \leq d(\vec{x},\vec{z})+d(\vec{z},\vec{y})$ **(triangular inequality)**

（一）距离测度

- **概念**

  以两个矢量矢端的距离作为度量基础，
  距离测度值是两矢量各相应分量之差的函数 。

- **方法**
  - 欧氏(Euclidean)距离
  - 绝对值距离(街坊距离或Manhattan距离)
  - 切氏(Chebyshev)距离
  - 明氏(Minkowski)距离
  - Camberra距离(Lance距离、Willims距离)
  - 马氏(Mahalanobis)距离

（一）距离测度

设 $\vec{x}=(x_1,x_2,\cdots,x_n)'$ ， $\vec{y}=(y_1,y_2,\cdots,y_n)'$

(1) 欧氏（Euclidean）距离

$$d(\vec{x},\vec{y})=\|\vec{x}-\vec{y}\|=[\sum_{i=1}^{n}(x_i-y_i)^2]^{1/2}$$

(2) 绝对值距离（街坊距离或Manhattan距离）

$$d(\vec{x},\vec{y})=\sum_{i=1}^{n}|x_i-y_i|$$

(3) 切氏（Chebyshev）距离

$$d(\vec{x},\vec{y})=\max_i|x_i-y_i|$$

切氏距离 ≤ 欧氏距离 ≤ 绝对值距离 **（作业）**

（一）距离测度

(4) 明氏(Minkowski)距离

$$d(\vec{x},\vec{y})=[\sum_{i=1}^{n}|x_i-y_i|^m]^{1/m}$$

m=2:欧式距离，m=1:绝对值距离，m=∞:切氏距离

(5) Cambera距离(Lance距离、Willims距离)

$$d(\vec{x},\vec{y})=\sum_{i=1}^{n}\frac{|x_i-y_i|}{|x_i+y_i|}\quad (x_i,y_i\geq 0, x_i+y_i\neq 0)$$

该距离能克服量纲的影响，
但不能克服分量间的相关性。

（一）距离测度

(6)马氏(Mahalanobis)距离

设 n 维矢量 $\vec{x}_i$ 和 $\vec{x}_j$ 是矢量集 $\{\vec{x}_1, \vec{x}_2, \cdots, \vec{x}_m\}$ 中的两个矢量，它们的马氏距离定义为

$$d^2(\vec{x}_i, \vec{x}_j) = (\vec{x}_i - \vec{x}_j)^{\mathrm{T}} V^{-1} (\vec{x}_i - \vec{x}_j)$$

式中

$$V = \frac{1}{m-1} \sum_{i=1}^{m} (\vec{x}_i - \vec{\bar{x}})(\vec{x}_i - \vec{\bar{x}})^{\mathrm{T}} \qquad \vec{\bar{x}} = \frac{1}{m} \sum_{i=1}^{m} \vec{x}_i$$

性质：对一切非奇异线性变换都是不变的。即，具有坐标系比例、旋转、平移不变性，并且从统计意义上尽量去掉了分量间的相关性。

马氏距离具有非奇异线性变换不变性

证明： 设，有非奇异线性变换：$\vec{y} = A\vec{x}$

则 $$\vec{\bar{y}} = \frac{1}{m}\sum_{i=1}^{n}\vec{y}_i = \frac{1}{m}\sum_{i=1}^{n}A\vec{x}_i = A\frac{1}{m}\sum_{i=1}^{n}\vec{x}_i = A\vec{\bar{x}}$$

$$V_y = \frac{1}{m-1}\sum_{i=1}^{m}(\vec{y}_i - \vec{\bar{y}})(\vec{y}_i - \vec{\bar{y}})'$$

$$= \frac{1}{m-1}\sum_{i=1}^{m}(A\vec{x}_i - A\vec{\bar{x}})(A\vec{x}_i - A\vec{\bar{x}})'$$

$$= \frac{1}{m-1}\sum_{i=1}^{m}A(\vec{x}_i - \vec{\bar{x}})(\vec{x}_i - \vec{\bar{x}})'A' \qquad \{\because (AB)' = B'A'\}$$

$$= A[\frac{1}{m-1}\sum_{i=1}^{m}(\vec{x}_i - \vec{\bar{x}})(\vec{x}_i - \vec{\bar{x}})']A' = AV_xA'$$

马氏距离具有非奇异线性变换不变性

故 $d_y^2(\vec{y}_i,\vec{y}_j)=(\vec{y}_i-\vec{y}_j)'V_y^{-1}(\vec{y}_i-\vec{y}_j)$

$=(A\vec{x}_i-A\vec{x}_j)'V_y^{-1}(A\vec{x}_i-A\vec{x}_j)$

$=(\vec{x}_i-\vec{x}_j)'A'V_y^{-1}A(\vec{x}_i-\vec{x}_j)$

$=(\vec{x}_i-\vec{x}_j)'A'(AV_xA')^{-1}A(\vec{x}_i-\vec{x}_j)$

$=(\vec{x}_i-\vec{x}_j)'A'A'^{-1}V_x^{-1}A^{-1}A(\vec{x}_i-\vec{x}_j)$ $\{\because (AB)^{-1}=B^{-1}A^{-1}\}$

$=(\vec{x}_i-\vec{x}_j)'V_x^{-1}(\vec{x}_i-\vec{x}_j)$

$=d_x^2(\vec{x}_i,\vec{x}_j)$

马氏距离的一般定义

设 $\vec{x}$ 、 $\vec{y}$ 是从期望矢量为 $\vec{\mu}$ 、协方差矩阵为Σ的母体G中抽取的两个样本，则它们间的马氏距离定义为

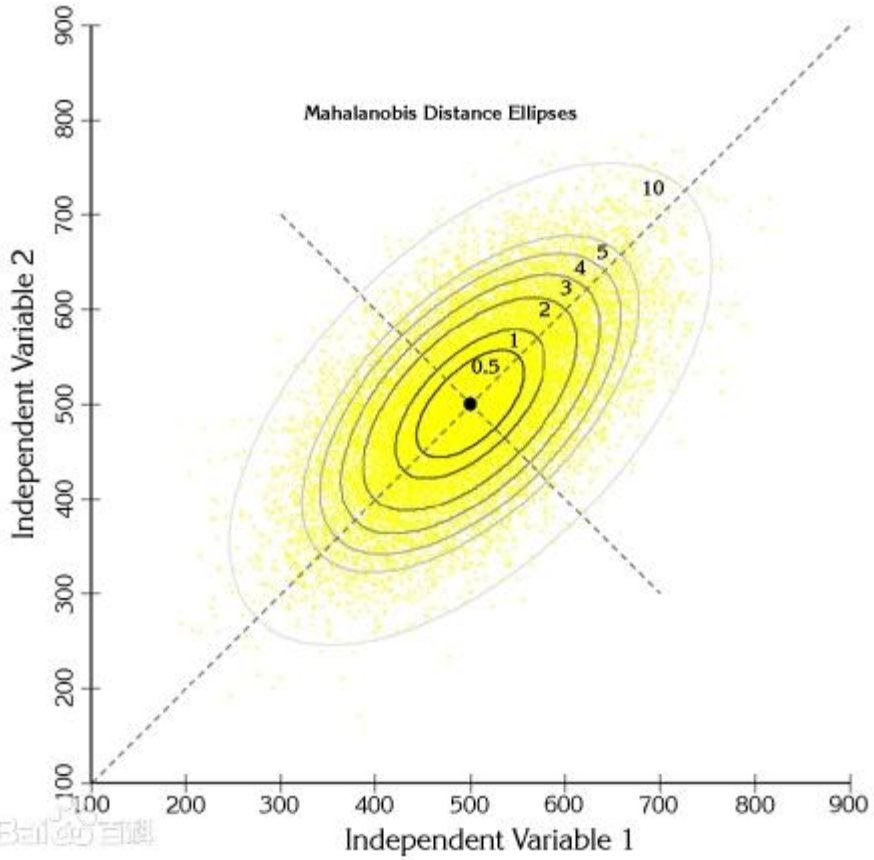
$$d^2(\vec{x},\vec{y}) = (\vec{x}-\vec{y})'\Sigma^{-1}(\vec{x}-\vec{y})$$

当 $\vec{x}$ 和 $\vec{y}$ 是分别来自两个数据集中的样本时，设C是它们的互协方差阵，则它们间的马氏距离定义为

$$d^2(\vec{x},\vec{y}) = (\vec{x}-\vec{y})'C^{-1}(\vec{x}-\vec{y})$$

- **当Σ、V、C为单位矩阵时，马氏距离⇔欧氏距离。**
- **对于正态分布，等概率密度点轨迹是到均值矢量的马氏距离为常数的点所构成的超椭球面。**

马氏距离的物理意义


Mahalanobis Distance Ellipses
10
5
4
3
2
1
0.5
Independent Variable 2
Independent Variable 1
100
200
300
400
500
600
700
800
900

例2.1

已知一个二维正态母体G的分布为 $N\left(\begin{pmatrix}0\\0\end{pmatrix},\begin{pmatrix}1 & 0.9\\0.9 & 1\end{pmatrix}\right)$

求点 $A:\begin{pmatrix}1\\1\end{pmatrix}$ 和 $B:\begin{pmatrix}1\\-1\end{pmatrix}$ 至均值点 $M:\ \vec{\mu}=\begin{pmatrix}0\\0\end{pmatrix}$ 的距离。

解：由题设，可得 $\Sigma=\begin{pmatrix}1 & 0.9\\0.9 & 1\end{pmatrix}$ $\Sigma^{-1}=\dfrac{1}{0.19}\begin{pmatrix}1 & -0.9\\-0.9 & 1\end{pmatrix}$

从而马氏距离

$$d_M{}^2(A,M)=\begin{pmatrix}1 & 1\end{pmatrix}\Sigma^{-1}\begin{pmatrix}1\\1\end{pmatrix}=0.2\big/0.19 \qquad d_M{}^2(B,M)=\begin{pmatrix}1 & -1\end{pmatrix}\Sigma^{-1}\begin{pmatrix}1\\-1\end{pmatrix}=3.8\big/0.19$$

它们之比达 $\sqrt{19}$ 倍。

若用欧氏距离，则算得的距离值相同：

$$d_E^2(A,M)=2 \qquad d_E^2(B,M)=2$$

由分布函数知，A、B两点的概率密度分别为

$$p(1,1)=0.2157 \qquad p(1,-1)=0.00001658$$

2.2 模型相似性测度

（一） 距 离 测 度

（二） 相 似 测 度

（二）相似测度

- 概念

  重点考虑两矢量的方向是否相近，而忽略矢量长度。

- 方法
  - 角度相似系数
  - 相关系数
  - 指数相似系数
  - 最值相似系数

（二）相似测度

- **重点考虑两矢量的方向是否相近，而忽略矢量长度。**

（1） 角度相似系数（夹角余弦）

矢量之间的相似性可用它们的夹角余弦来度量

$$\cos(\vec{x},\vec{y})=\frac{\vec{x}'\vec{y}}{\|\vec{x}\|\|\vec{y}\|}=\frac{\vec{x}'\vec{y}}{[(\vec{x}'\vec{x})(\vec{y}'\vec{y})]^{1/2}}$$

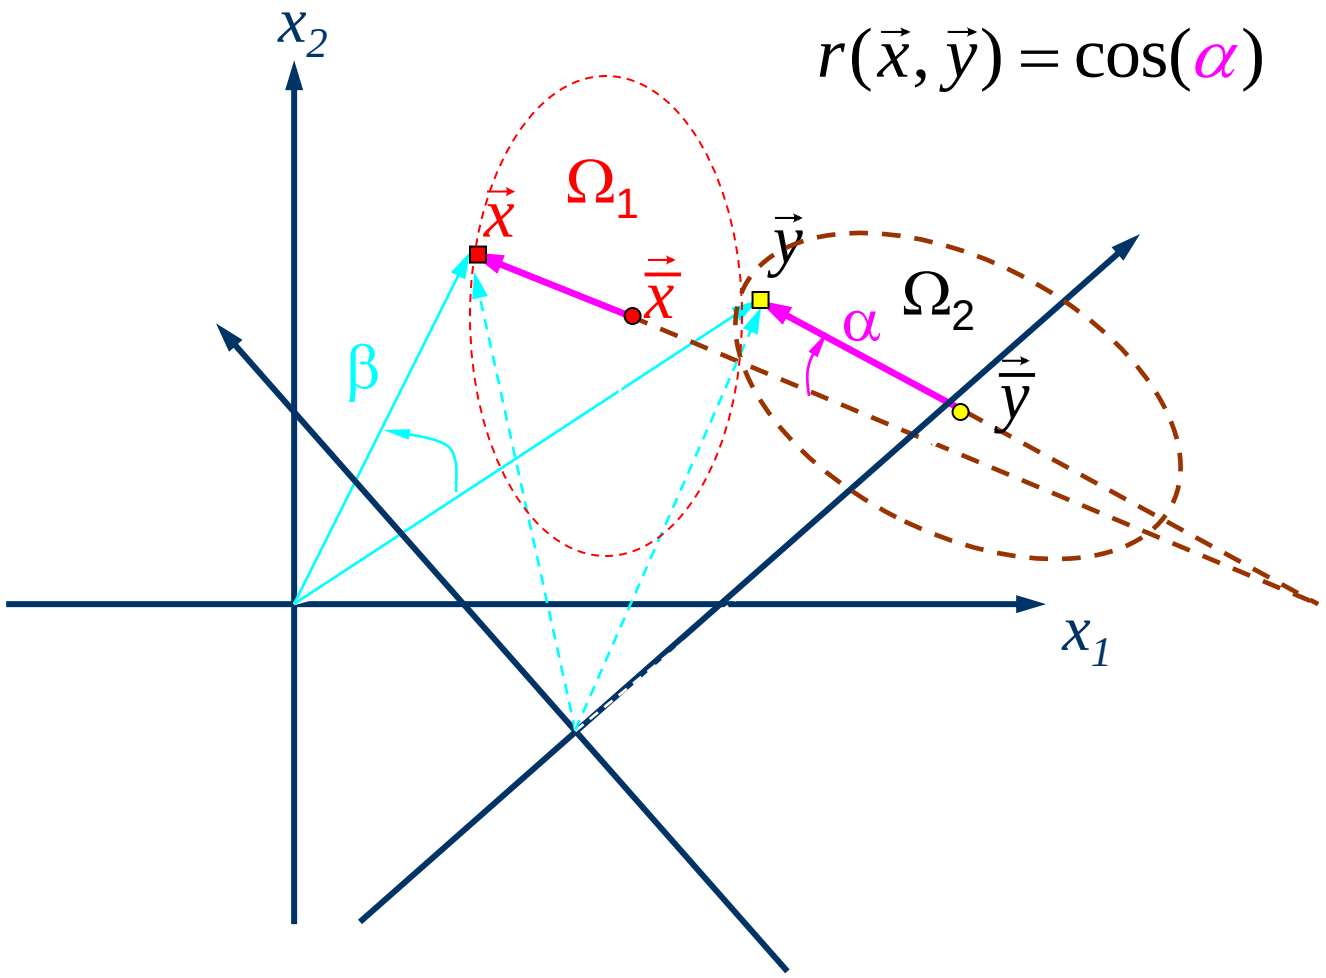
（2） 相关系数

数据中心化后的矢量夹角余弦

$$r(\vec{x},\vec{y})=\frac{(\vec{x}-\bar{\vec{x}})'(\vec{y}-\bar{\vec{y}})}{[(\vec{x}-\bar{\vec{x}})'(\vec{x}-\bar{\vec{x}})(\vec{y}-\bar{\vec{y}})'(\vec{y}-\bar{\vec{y}})]^{1/2}}$$

性质：相关系数具有坐标系平移、旋转、比例不变性。

相关系数的几何意义


$r(\vec{x},\vec{y})=\cos(\alpha)$
x_2
x_1
Ω_1
Ω_2
$\vec{x}$
$\vec{\bar{x}}$
$\vec{y}$
$\vec{\bar{y}}$
α
β

（二）相似测度

(3) 指数相关系数

$$e(\vec{x},\vec{y})=\frac{1}{n}\sum_{i=1}^{n}\exp[-\frac{3}{4}\frac{(x_i-y_i)^2}{\sigma_i^2}]$$

这里假设 $\vec{x}$ 和 $\vec{y}$ 的维数n相同、概率分布相同。

σ_i^2 是第i个分量的方差。

性质：不受量纲变化的影响。

从函数构造看属于距离度量，

但由于差矢量长度对其的影响并不大，

所以将其归为相似性测度。

小 结

一、影响分类的因素

（1）分类准则；（2）特征量的选择；（3）量纲。

二、模式相似性测度

（一） 距 离 测 度

(1) 欧氏距离

(2) 马氏距离 $d^2(\vec{x}_i,\vec{x}_j)=(\vec{x}_i-\vec{x}_j)'V^{-1}(\vec{x}_i-\vec{x}_j)$

对坐标系平移、旋转、比例不变（非奇异线性变换不变）。

（二） 相 似 测 度

相关系数 (特征矢量的方向) $r(\vec{x},\vec{y})=\dfrac{(\vec{x}-\bar{\vec{x}})'(\vec{y}-\bar{\vec{y}})}{[(\vec{x}-\bar{\vec{x}})'(\vec{x}-\bar{\vec{x}})(\vec{y}-\bar{\vec{y}})'(\vec{y}-\bar{\vec{y}})]^{1/2}}$

对坐标系平移、旋转、比例不变。

（三） 匹 配 测 度

(0-1) 匹配系数, Tanimoto相似性测度

2.3 类间距离

2.3.1 类间距离测度方法

（一）最近距离

两个聚类ω_k和ω_l之间的最近距离定义为

$$D_{kl} = \min_{i,j}[d_{ij}]$$

式中，d_{ij}表示$x_i \in \omega_k$与$x_j \in \omega_l$间的距离。

如果ω_l由ω_p和ω_q两类合并而成，则有递推公式

$$D_{kl} = \min[D_{kp}, D_{kq}]$$

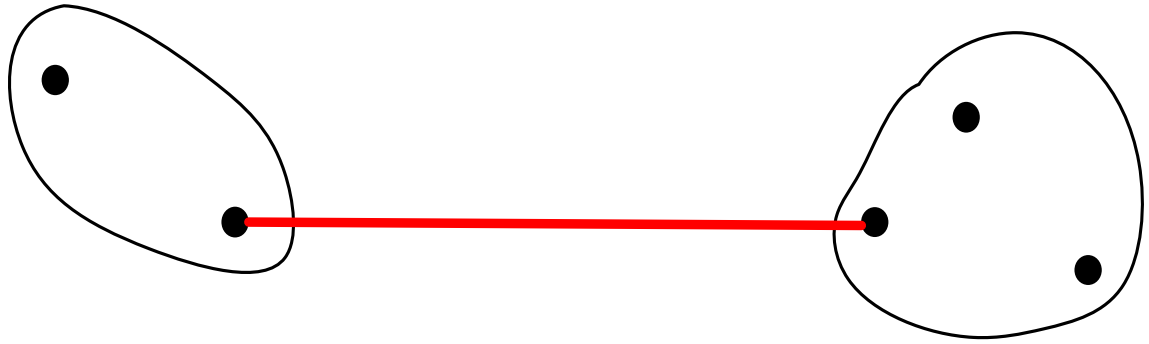
（二）最远距离

$$D_{kl} = \max_{i,j}[d_{ij}]$$

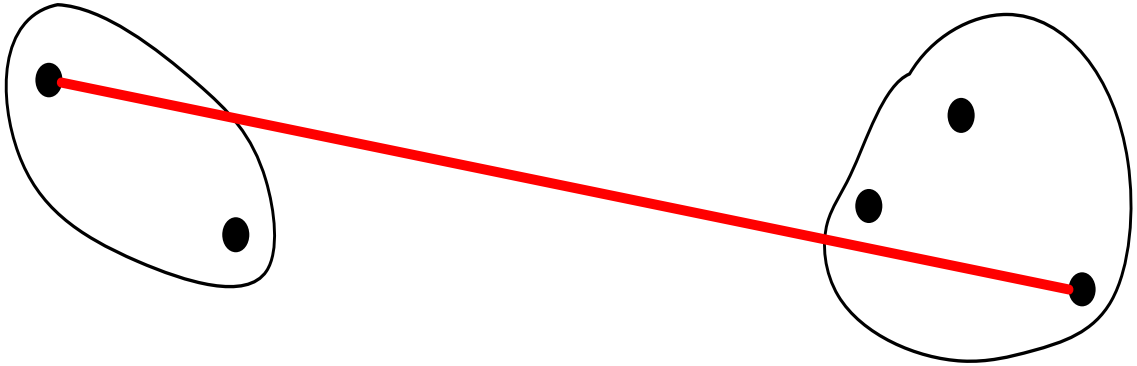
递推公式

$$D_{kl} = \max[D_{kp}, D_{kq}]$$

2.3.1 类间距离测度方法



最近距离法图示



最远距离法图示

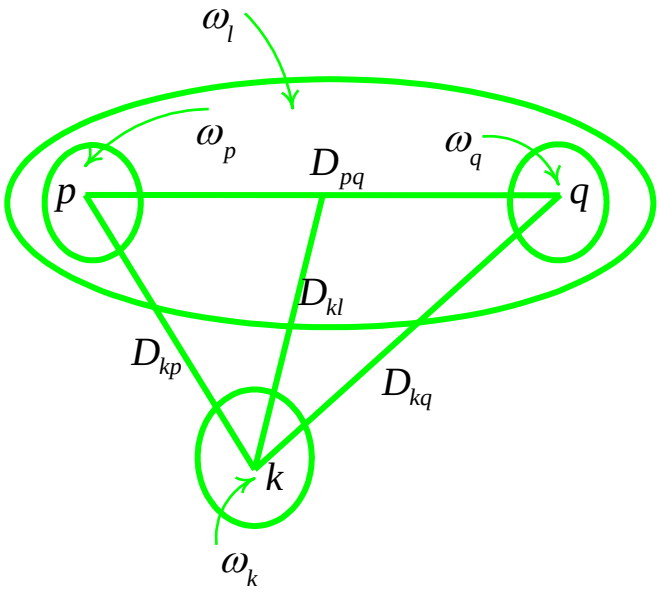
2.3.1 类间距离测度方法

设ω_i有n_i个样本，$i=k,l,p,q$；如果ω_l由ω_p和ω_q两类合并而成。

（三）中间距离

递推公式

$$D_{kl}^2 = \frac{1}{2}D_{kp}^2 + \frac{1}{2}D_{kq}^2 - \frac{1}{4}D_{pq}^2$$



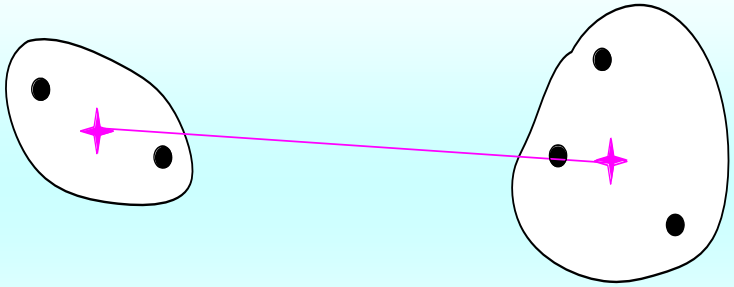
2.3.1 类间距离测度方法

设ω_i有n_i个样本，$i=k,l,p,q$；如果ω_l由ω_p和ω_q两类合并而成。

（四）重心距离

$$D_{pq}^2=(\vec{x}_p-\vec{x}_q)'(\vec{x}_p-\vec{x}_q)$$

$\vec{x}_p$ 和$\vec{x}_q$分别是ω_p和ω_q的重心



重心距离法图示

递推公式

$$D_{kl}^2=\frac{n_p}{n_p+n_q}D_{kp}^2+\frac{n_q}{n_p+n_q}D_{kq}^2-\frac{n_pn_q}{(n_p+n_q)^2}D_{pq}^2$$

式中 $D_{ij}^2=(\vec{x}_i-\vec{x}_j)'(\vec{x}_i-\vec{x}_j)$ ，$\vec{x}_i$ 和$\vec{x}_j$分别是ω_i和ω_j的重心，$i,j=k,l,p,q$ 。

2.3.1 类间距离测度方法

（五） 平均距离

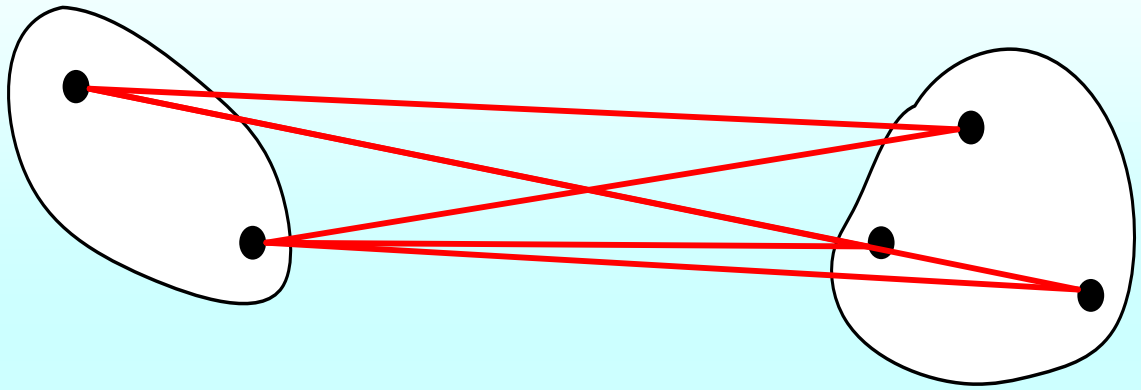
两类ω_p和ω_q间的距离平方定义为这两类元素两两之间的平均平方距离，即

$$D_{pq}^2 = \frac{1}{n_p n_q} \sum_{\vec{x}_i \in \omega_p, \vec{x}_j \in \omega_p} d_{ij}^2$$

设$\omega_l = \omega_p \cup \omega_q$，类平均距离的递推公式为

$$D_{kl}^2 = \frac{n_p}{n_p + n_q} D_{kp}^2 + \frac{n_q}{n_p + n_q} D_{kq}^2$$

2.3.1 类间距离测度方法



平均距离法图示

2.3.1 类间距离测度方法

（六） 离差平方和法

设类ω_t的重心是$\vec{x}_t$， ω_t的类内离差平方和定义为

$$s_t = \sum_{\vec{x}_i \in \omega_t} (\vec{x}_i - \vec{x}_t)'(\vec{x}_i - \vec{x}_t)$$

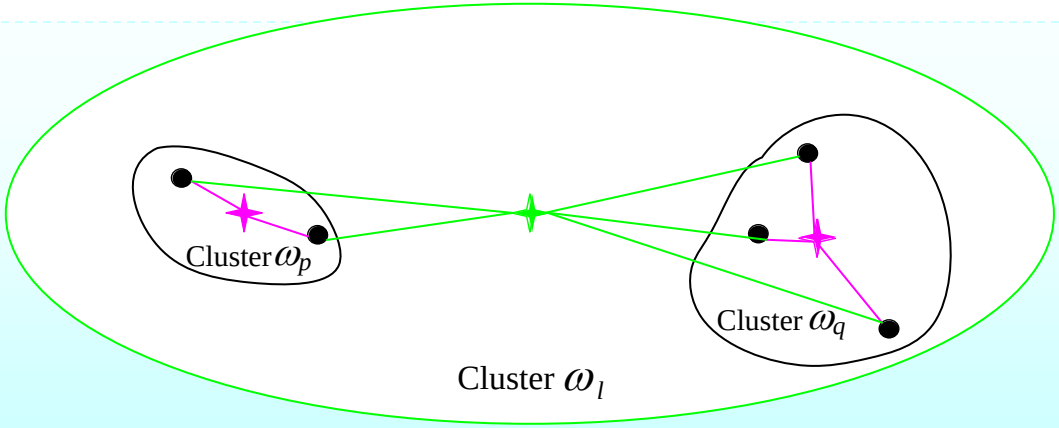
设$\omega_l = \omega_p \cup \omega_q$，则$s_l$要变大。把两类合并所增加的离差平方和定义为两类平方距离，即 $D_{pq}^2 = s_l - s_p - s_q$可以证明

$$D_{pq}^2 = \frac{n_p n_q}{n_p + n_q}(\vec{x}_p - \vec{x}_q)'(\vec{x}_p - \vec{x}_q) \quad \vec{x}_p = \frac{1}{n_p}\sum_{\vec{x}_i \in \omega_p} \vec{x}_i, \quad \vec{x}_q = \frac{1}{n_q}\sum_{\vec{x}_j \in \omega_q} \vec{x}_j$$

ω_k与$\omega_l = \omega_p \cup \omega_q$的离差平方和的递推公式

$$D_{kl}^2 = \frac{n_k + n_p}{n_k + n_l} D_{kp}^2 + \frac{n_k + n_q}{n_k + n_l} D_{kq}^2 - \frac{n_k}{n_k + n_l} D_{pq}^2$$

2.3.1 类间距离测度方法



离差平方和法图示

递推公式

$$D_{kl}^2 = \frac{n_k + n_p}{n_k + n_l} D_{kp}^2 + \frac{n_k + n_q}{n_k + n_l} D_{kq}^2 - \frac{n_k}{n_k + n_l} D_{pq}^2$$

谱系聚类算法中多采用平均距离法和离差平方和法计算类间距离。

类间距离递推公式

$$D_{kl}^2 = \alpha_p D_{kp}^2 + \alpha_q D_{kq}^2 + \beta D_{pq}^2 + \gamma \left| D_{kp}^2 - D_{kq}^2 \right| \quad (\text{其中} \omega_l = \omega_p \cup \omega_q)$$

	α_p	α_q	β	γ
最近距离	1/2	1/2	0	-1/2
最远距离	1/2	1/2	0	1/2
中间距离	1/2	1/2	-1/4	0
重心距离	$n_p/(n_p+n_q)$	$n_q/(n_p+n_q)$	$-\alpha_p\alpha_q$	0
平均距离	$n_p/(n_p+n_q)$	$n_q/(n_p+n_q)$	0	0
可变平均距离	$(1-\beta)n_p/(n_p+n_q)$	$(1-\beta)n_q/(n_p+n_q)$	<1	0
可变距离	$(1-\beta)/2$	$(1-\beta)/2$	<1	0
离差平方和	$(n_k+n_p)/(n_k+n_l)$	$(n_k+n_q)/(n_k+n_l)$	$-n_k/(n_k+n_l)$	0

$$\min[a,b] = [\frac{a^2+b^2}{2} - \frac{|a^2-b^2|}{2}]^{1/2}, \quad \max[a,b] = [\frac{a^2+b^2}{2} + \frac{|a^2-b^2|}{2}]^{1/2}$$

2.3.1 类间距离测度方法

各种类间距离的性能

(1) **最远距离**：类域半径增长最慢，倾向成团聚类

(2) **最近距离**：可能产生细长分布的类

(3) **中间距离**：克服重心距离聚类合并后重心靠近较大聚类重心的问题

(4) **离差平方和**：倾向于将孤立点或较小类与较大类合并。

(5) **平均距离和重心距离**：对孤立点和噪声不敏感

2.4 准则函数

2. 4. 1 点与点的集合的距离

$$\text{if } d(\vec{x},\omega_i)=\min_{j=1,2,\ldots,c}[d(\vec{x},\omega_j)],\ \text{then } \vec{x}\in\omega_i$$

其中，$d(\vec{x},\omega_i)$为待分类模式$\vec{x}$到聚合类ω_i的距离

（一）第一类（在无集合中点的分布的先验知识时用）

（1）最小距离 $d(\vec{x},\omega_i)=\min_{\vec{y}\in\omega_i}[\vec{x},\vec{y}]$

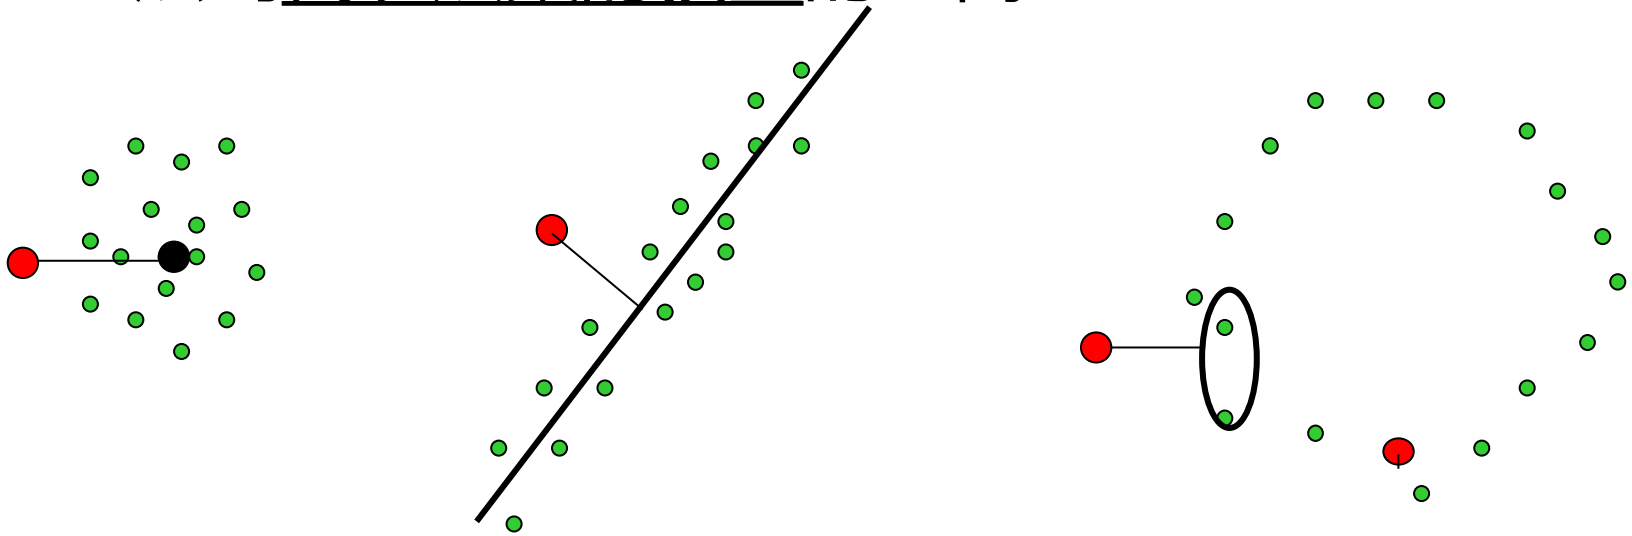
（2）最大距离 $d(\vec{x},\omega_i)=\max_{\vec{y}\in\omega_i}[\vec{x},\vec{y}]$

（3）平均距离 $d(\vec{x},\omega_i)=\frac{1}{N_i}\sum_{\vec{y}\in\omega_i}d(\vec{x},\vec{y})$

2.4.1 点与点的集合间的距离

(二) 第二类（有集合中点的分布的先验知识时用）

点到代表点集的**模型**的距离



(a) 团状分布
点模型

(b) 线状分布
超平面模型

(c) 环状分布
超球面模型

2.2 动态聚类法

- **动态聚类: 聚类过程中，*类心*和*类别*可变**
  - 技术要点

(1) 确定模式和聚类的距离测度

(2) 建立评估聚类质量的准则函数

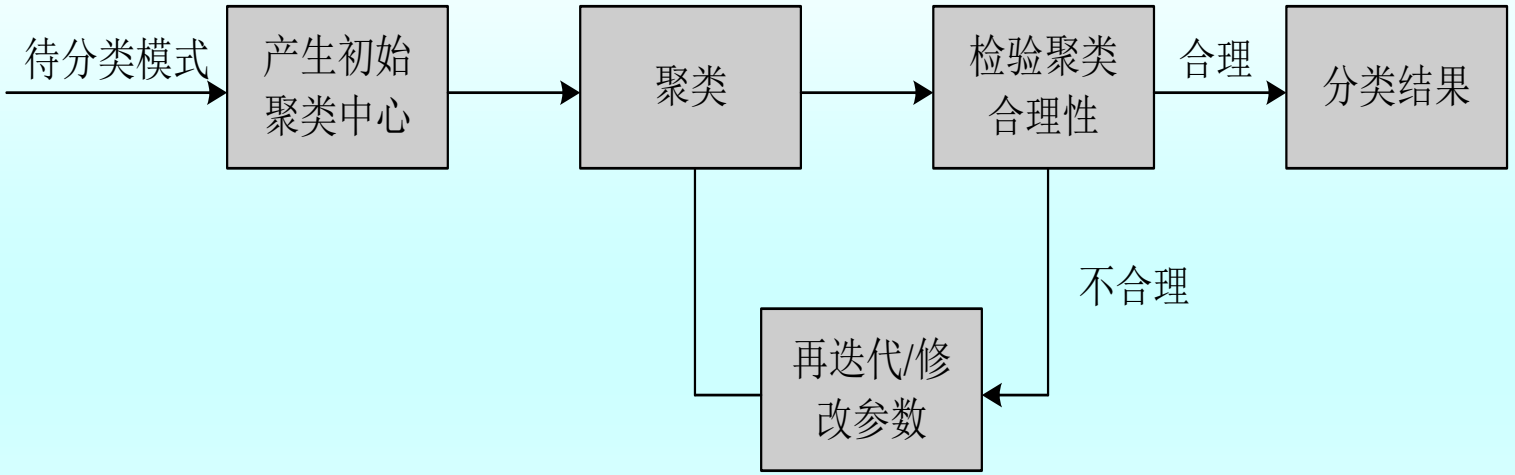
(3) 确定分划、聚类合并或分裂的规则和策略

  - 基本步骤

- 选取中心和有关参数进行初始聚类
- 计算模式和聚类的距离，调整模式类别
- 计算聚类参数，删除、合并或分裂聚类
- 运用迭代算法动态改变模式类别和聚类中心，直至达到聚类结束条件

2.2 动态聚类法

- 原理框图



- 代表算法

C-均值法 ISODATA算法

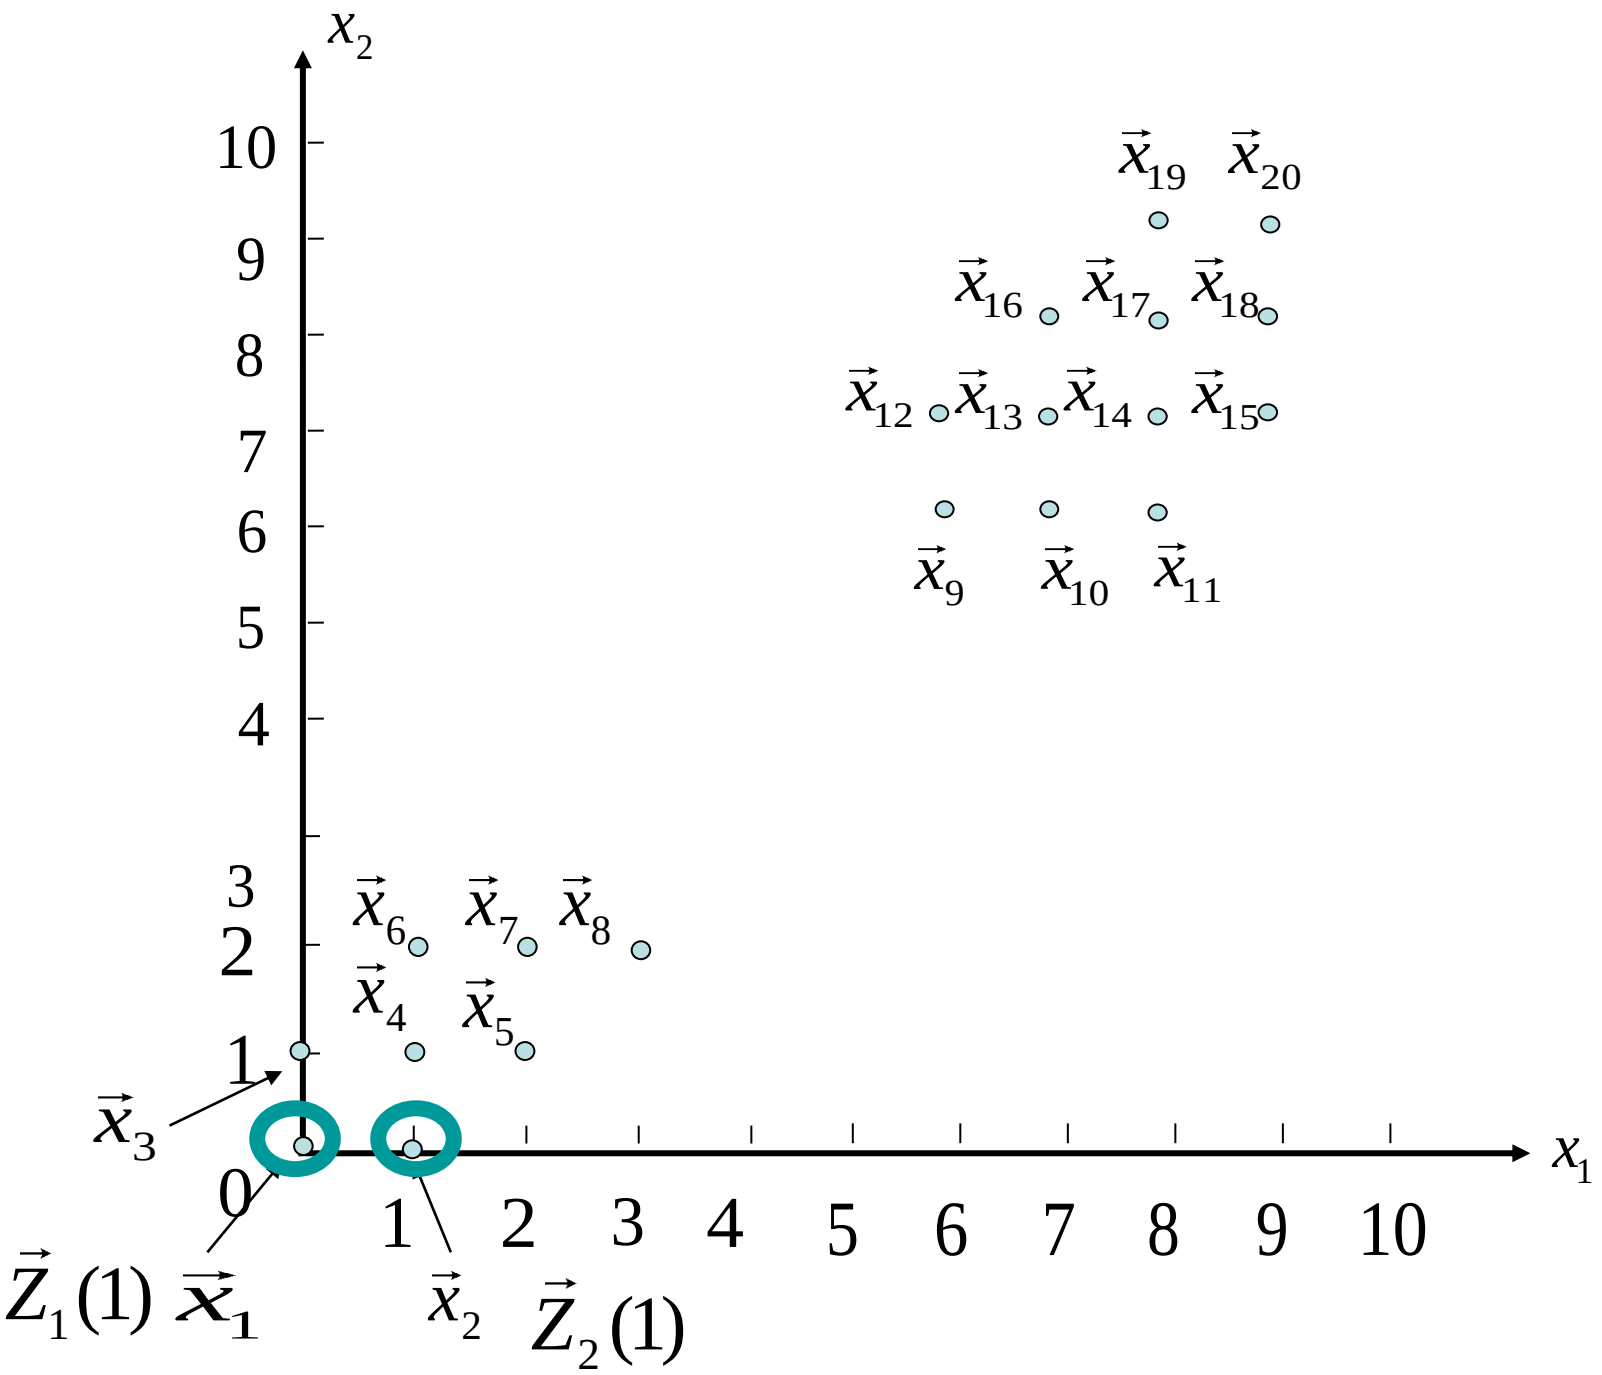
（一）C-均值法(C-Means)

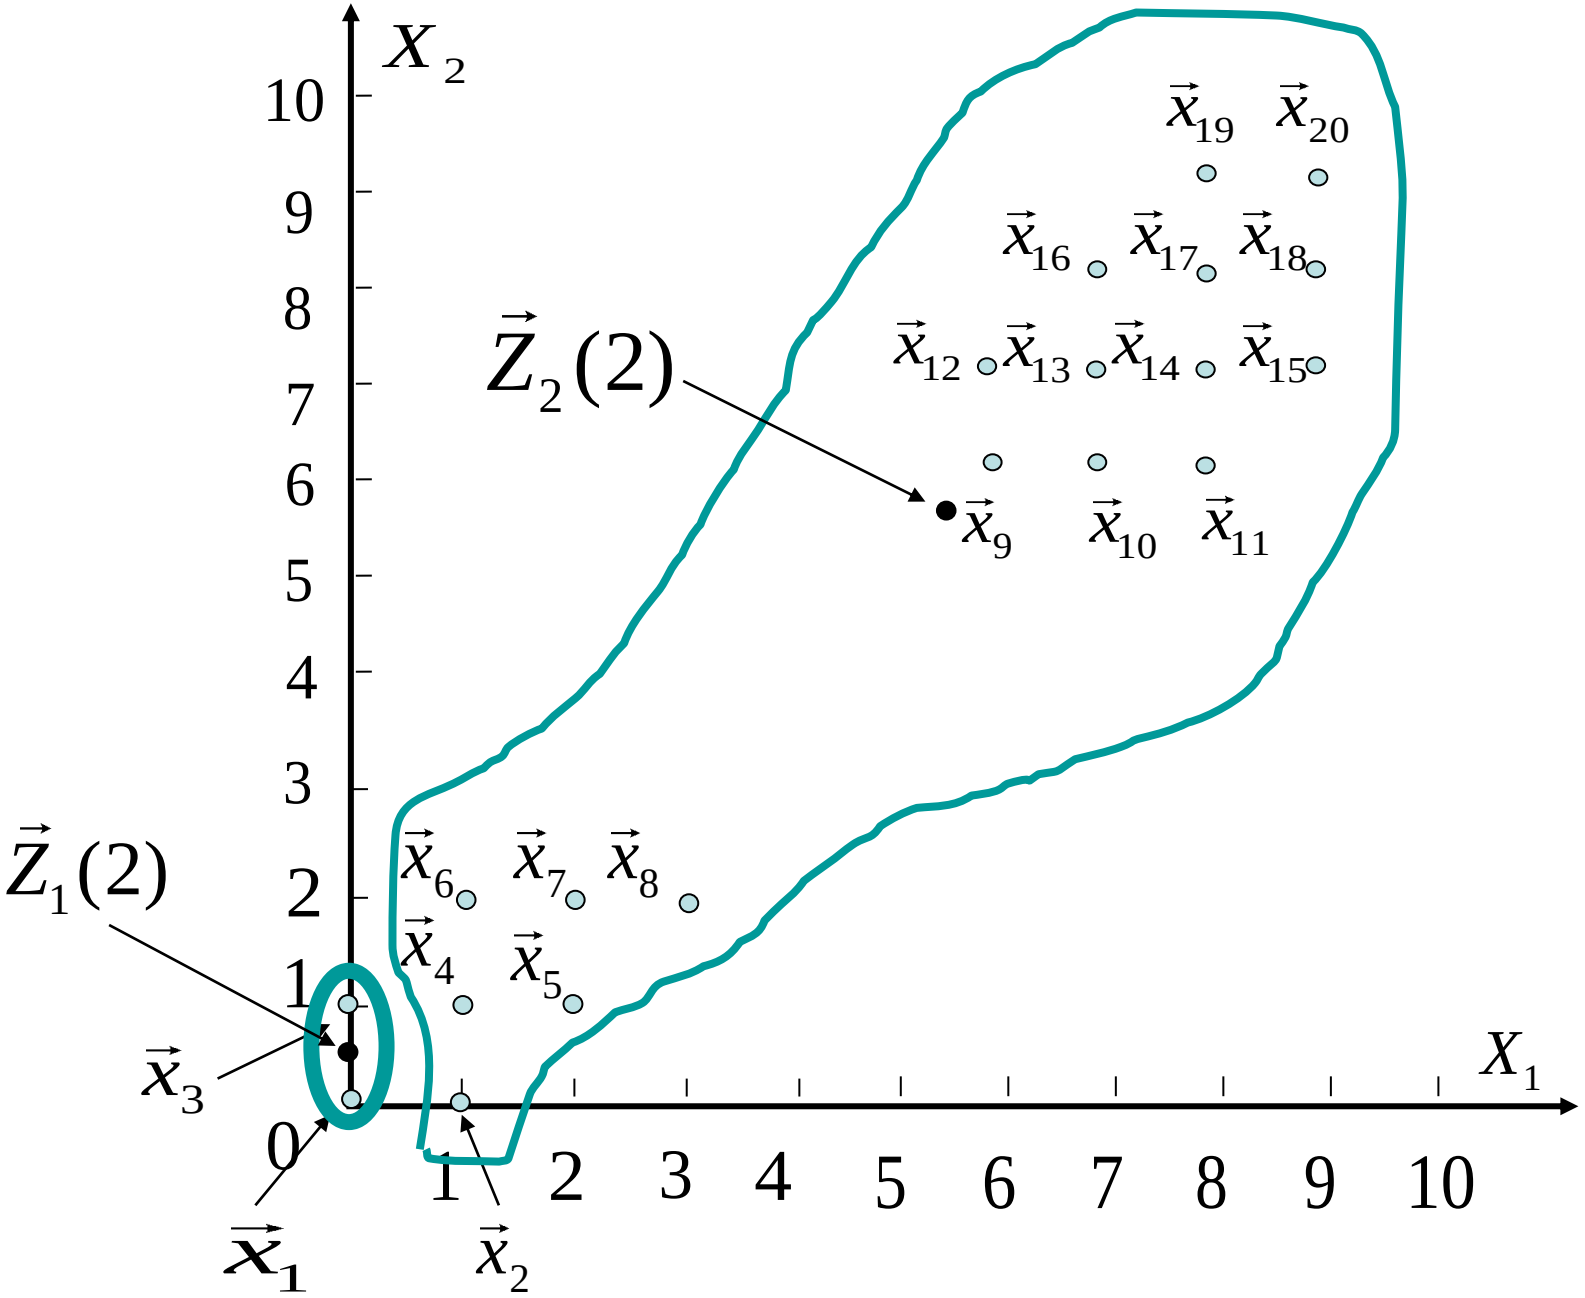
- 条件和约定

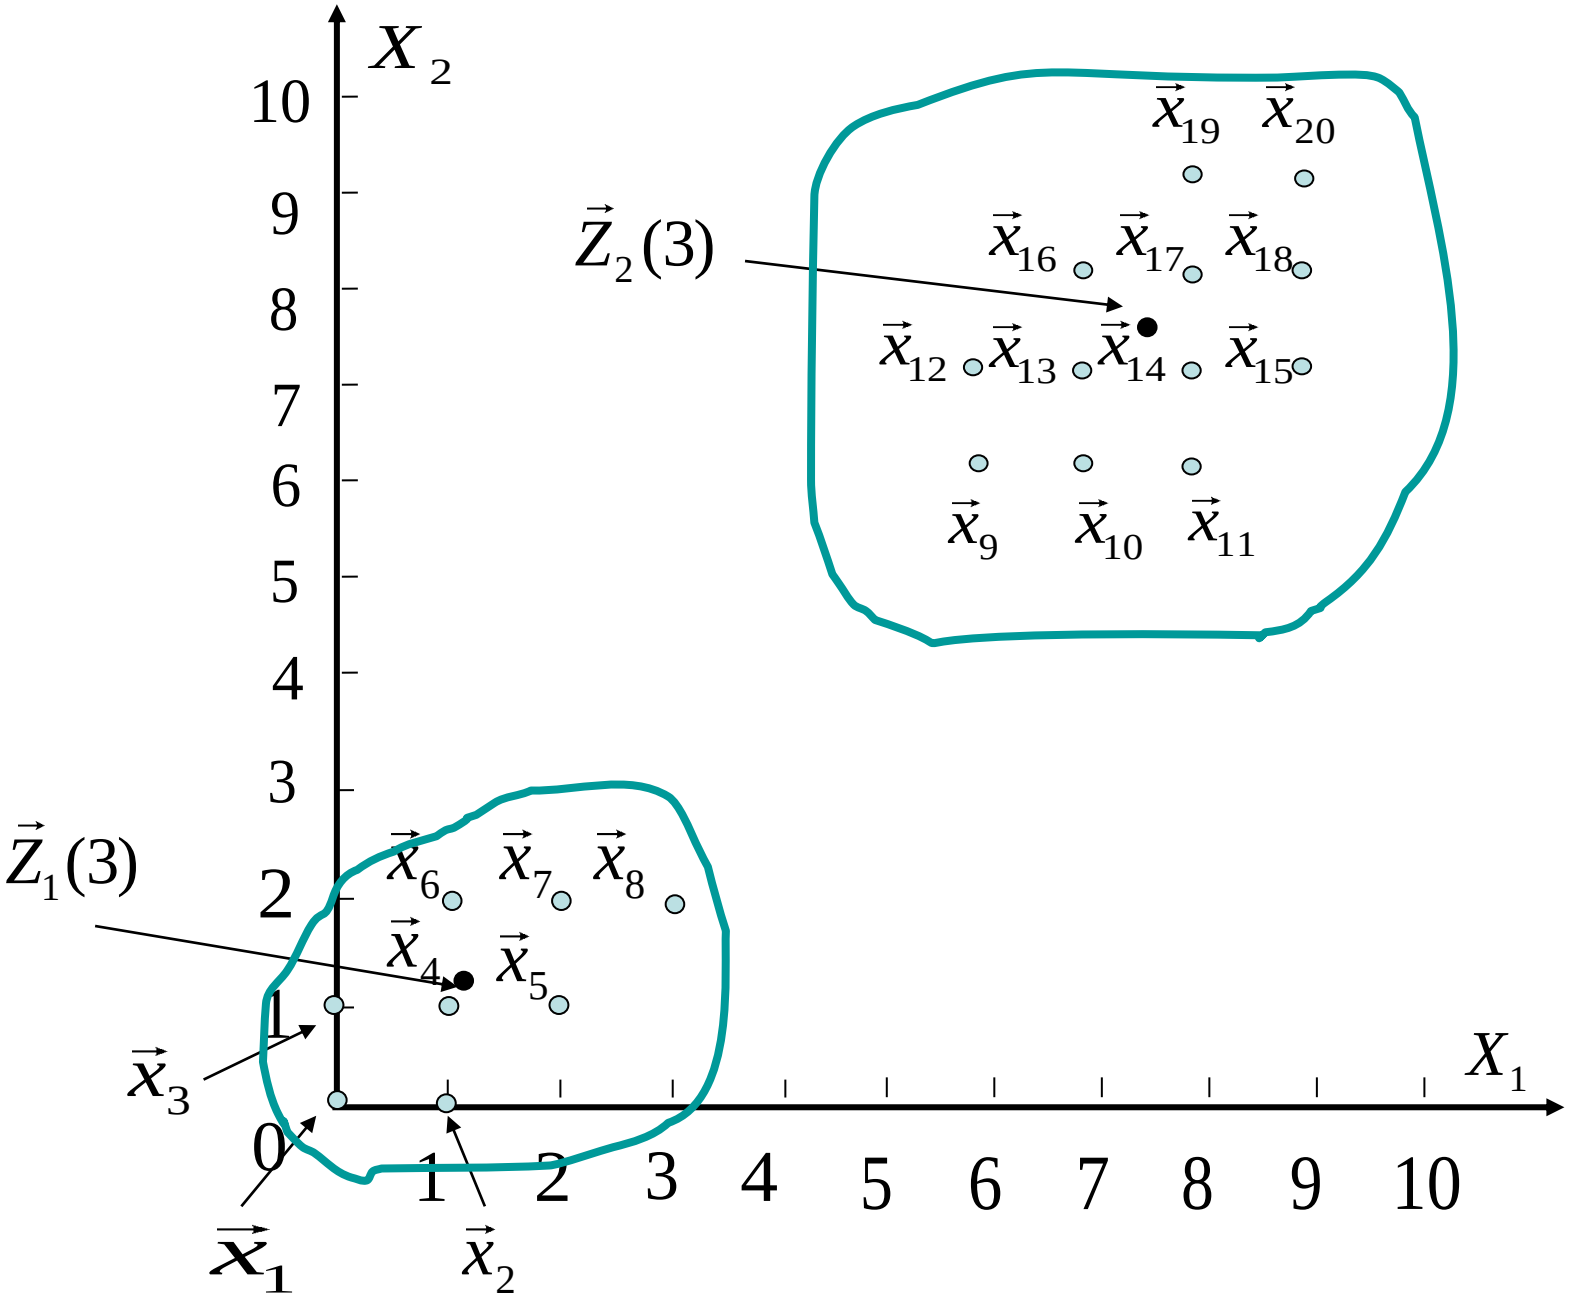
设待分类的模式特征矢量为 $\{x_1, x_2, \cdots, x_N\}$
类数 c事先取定。

- 基本思想

取定c个类别和选取c个初始聚类中心，按最小距离原则将各模式分别分配到各类；不断地计算类心和调整各模式的类别，直至各模式到其判属类别中心的距离平方和最小。


x_2
x_1
10
9
8
7
6
5
4
3
2
1
0
1 2 3 4 5 6 7 8 9 10
$\vec{x}_{19}$ $\vec{x}_{20}$
$\vec{x}_{16}$ $\vec{x}_{17}$ $\vec{x}_{18}$
$\vec{x}_{12}$ $\vec{x}_{13}$ $\vec{x}_{14}$ $\vec{x}_{15}$
$\vec{x}_9$ $\vec{x}_{10}$ $\vec{x}_{11}$
$\vec{x}_6$ $\vec{x}_7$ $\vec{x}_8$
$\vec{x}_4$ $\vec{x}_5$
$\vec{x}_3$
$\vec{Z}_1(1)$ $\vec{x}_1$
$\vec{x}_2$ $\vec{Z}_2(1)$


X_2
X_1
$\vec{Z}_2(2)$
$\vec{Z}_1(2)$
$\vec{x}_1$
$\vec{x}_2$
$\vec{x}_3$
$\vec{x}_4$
$\vec{x}_5$
$\vec{x}_6$
$\vec{x}_7$
$\vec{x}_8$
$\vec{x}_9$
$\vec{x}_{10}$
$\vec{x}_{11}$
$\vec{x}_{12}$
$\vec{x}_{13}$
$\vec{x}_{14}$
$\vec{x}_{15}$
$\vec{x}_{16}$
$\vec{x}_{17}$
$\vec{x}_{18}$
$\vec{x}_{19}$
$\vec{x}_{20}$
0
1
2
3
4
5
6
7
8
9
10


X_2
X_1
$\vec{Z}_2(3)$
$\vec{Z}_1(3)$
$\vec{x}_1$
$\vec{x}_2$
$\vec{x}_3$
$\vec{x}_4$
$\vec{x}_5$
$\vec{x}_6$
$\vec{x}_7$
$\vec{x}_8$
$\vec{x}_9$
$\vec{x}_{10}$
$\vec{x}_{11}$
$\vec{x}_{12}$
$\vec{x}_{13}$
$\vec{x}_{14}$
$\vec{x}_{15}$
$\vec{x}_{16}$
$\vec{x}_{17}$
$\vec{x}_{18}$
$\vec{x}_{19}$
$\vec{x}_{20}$
0 1 2 3 4 5 6 7 8 9 10

3. 算法步骤

C-均值法

- 算法步骤

（1）任选 c 个模式特征矢量作为初始聚类中心。

（2）将待分类模式逐个按最小距离准则分划到c类

如果 $d_{il}^{(k)} = \min_j [d_{ij}^{(k)}]$ ， $i = 1, 2, \cdots, N$

则判 $\boldsymbol{x}_i \in \omega_l^{(k+1)}$

式中， $d_{ij}^{(k)}$ 表示 $\boldsymbol{x}_i$ 和 $\omega_j^{(k)}$ 的中心 $\boldsymbol{z}_j^{(k)}$ 的距离，上标表示迭代次数。

3. 算法步骤

C-均值法

- 算法步骤

（3）计算重新分类后的类心

$$\boldsymbol{z}_j^{(k+1)} = \frac{1}{n_j^{(k+1)}} \sum_{\boldsymbol{x}_i \in \omega_j^{(k+1)}} \boldsymbol{x}_i$$

$n_j^{(k+1)}$表示 $\omega_j^{(k+1)}$ 类中的模式个数。

（4）如果 $\boldsymbol{z}_j^{(k+1)} = \boldsymbol{z}_j^{(k)} \ (j = 1, 2, \cdots, c)$ 则结束；否则，

$k = k+1$ ，转至步骤（2）。

例2.5.2

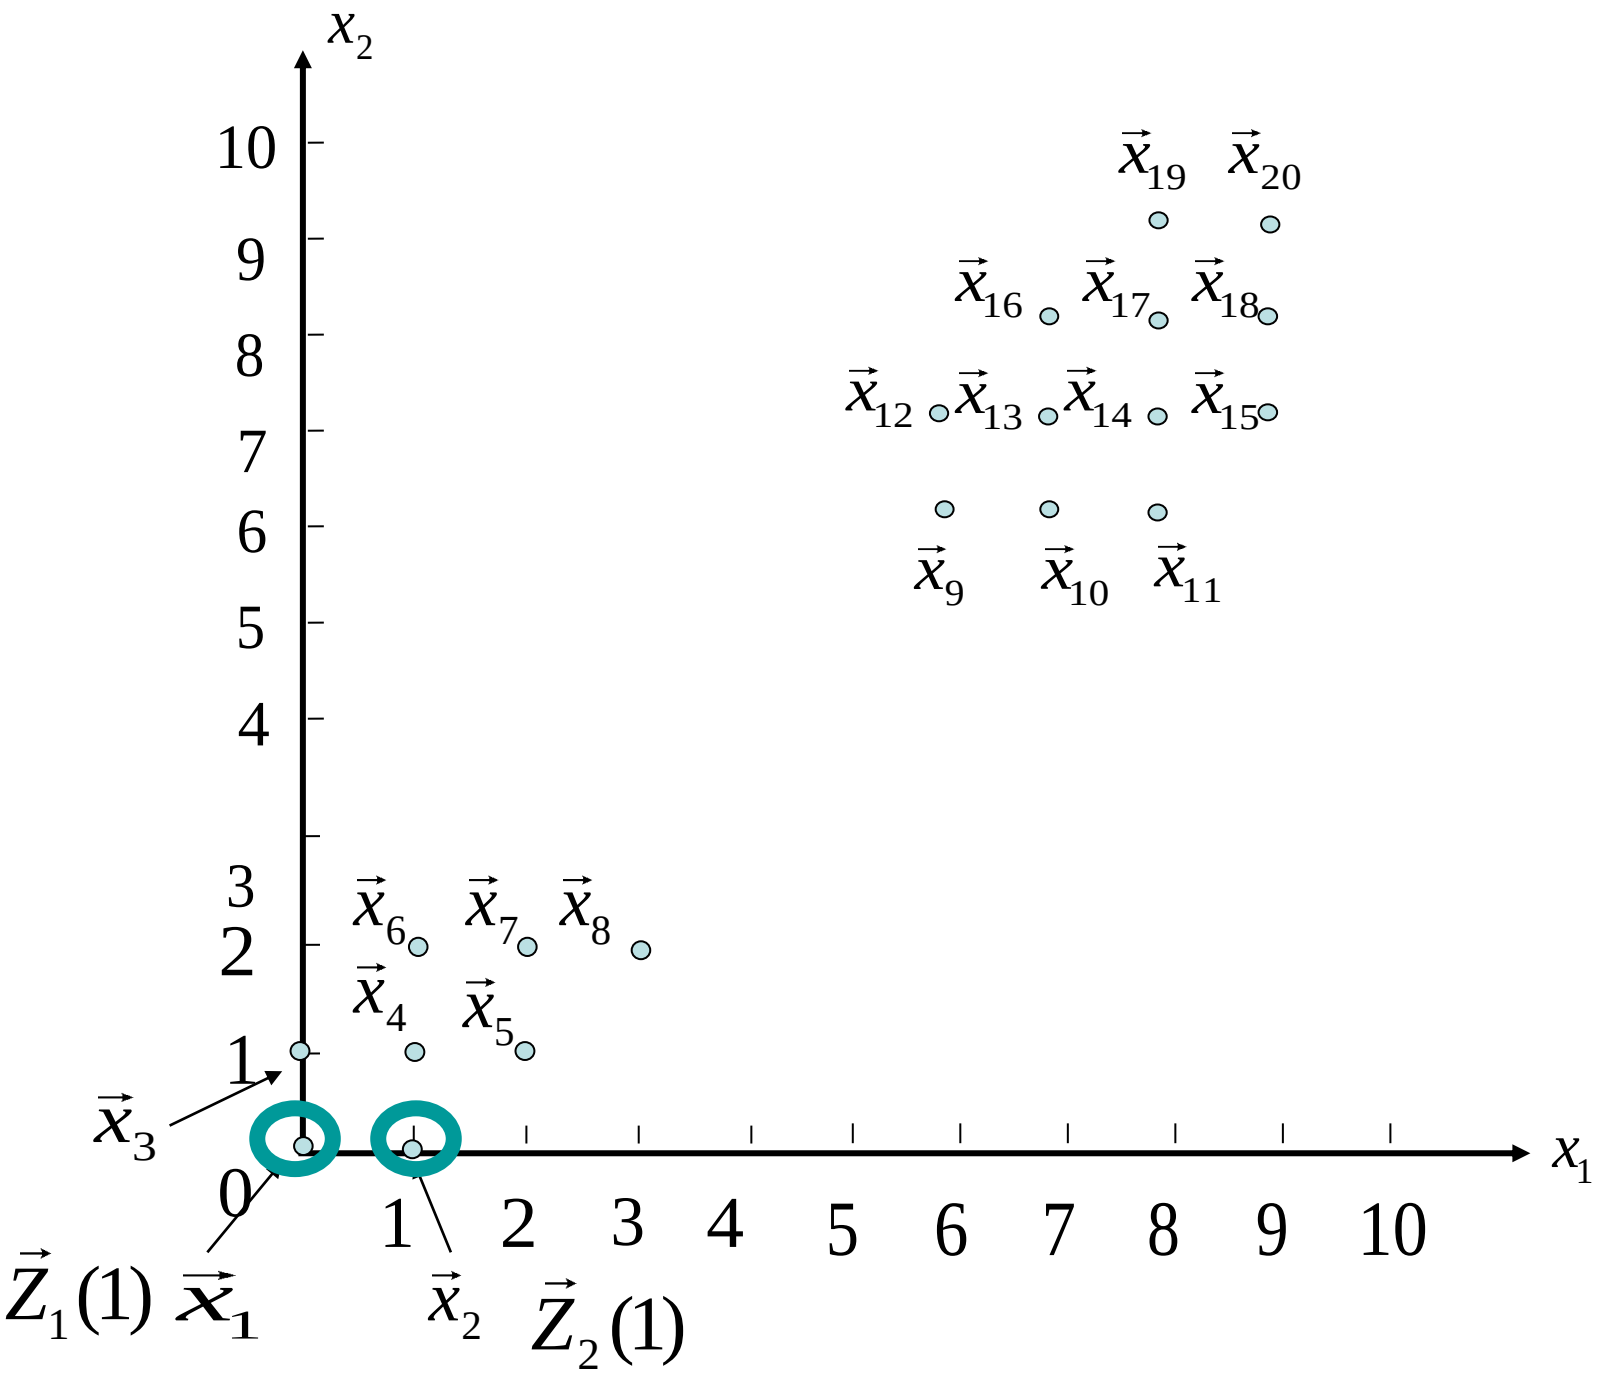
- 已知有20个样本，每个样本有2个特征，数据分布如下图，使用C－均值法实现样本分类（C=2）。

样本序号	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8	x_9	x_{10}
特征x_1	0	1	0	1	2	1	2	3	6	7
特征x_2	0	0	1	1	1	2	2	2	6	6

x_{11}	x_{12}	x_{13}	x_{14}	x_{15}	x_{16}	x_{17}	x_{18}	x_{19}	x_{20}
8	6	7	8	9	7	8	9	8	9
6	7	7	7	7	8	8	8	9	9

第一步：令C=2，选初始聚类中心为

$$\vec{Z}_1(1)=\vec{x}_1=(0,0)^T;\vec{Z}_2(1)=\vec{x}_2=(1,0)^T$$


x_2
x_1
10
9
8
7
6
5
4
3
2
1
0
1 2 3 4 5 6 7 8 9 10
$\vec{x}_{19}$ $\vec{x}_{20}$
$\vec{x}_{16}$ $\vec{x}_{17}$ $\vec{x}_{18}$
$\vec{x}_{12}$ $\vec{x}_{13}$ $\vec{x}_{14}$ $\vec{x}_{15}$
$\vec{x}_9$ $\vec{x}_{10}$ $\vec{x}_{11}$
$\vec{x}_6$ $\vec{x}_7$ $\vec{x}_8$
$\vec{x}_4$ $\vec{x}_5$
$\vec{x}_3$
$\vec{Z}_1(1)$ $\vec{x}_1$
$\vec{x}_2$ $\vec{Z}_2(1)$

第二步

$$\| \vec{x}_1 - \vec{Z}_1(1) \| = \| \begin{pmatrix} 0 \\ 0 \end{pmatrix} - \begin{pmatrix} 0 \\ 0 \end{pmatrix} \| = 0$$

$$\| \vec{x}_1 - \vec{Z}_2(1) \| = \| \begin{pmatrix} 0 \\ 0 \end{pmatrix} - \begin{pmatrix} 1 \\ 0 \end{pmatrix} \| = 1$$

因为 $\| \vec{x}_1 - \vec{Z}_1(1) \| < \| \vec{x}_1 - \vec{Z}_2(1) \|$ **所以** $\vec{x}_1 \in \omega_1^{(1)}$

$$\| \vec{x}_2 - \vec{Z}_1(1) \| = \| \begin{pmatrix} 1 \\ 0 \end{pmatrix} - \begin{pmatrix} 0 \\ 0 \end{pmatrix} \| = 1$$

$$\| \vec{x}_2 - \vec{Z}_2(1) \| = \| \begin{pmatrix} 1 \\ 0 \end{pmatrix} - \begin{pmatrix} 1 \\ 0 \end{pmatrix} \| = 0$$

因为 $\| \vec{x}_2 - \vec{Z}_1(1) \| > \| \vec{x}_2 - \vec{Z}_2(1) \|$ **所以** $\vec{x}_2 \in \omega_2^{(1)}$

第二步

同理

$$\because \| \vec{x}_3 - \vec{Z}_1(1) \| = 1 < \| \vec{x}_3 - \vec{Z}_2(1) \| = 2 \quad \therefore \vec{x}_3 \in \omega_1^{(1)}$$

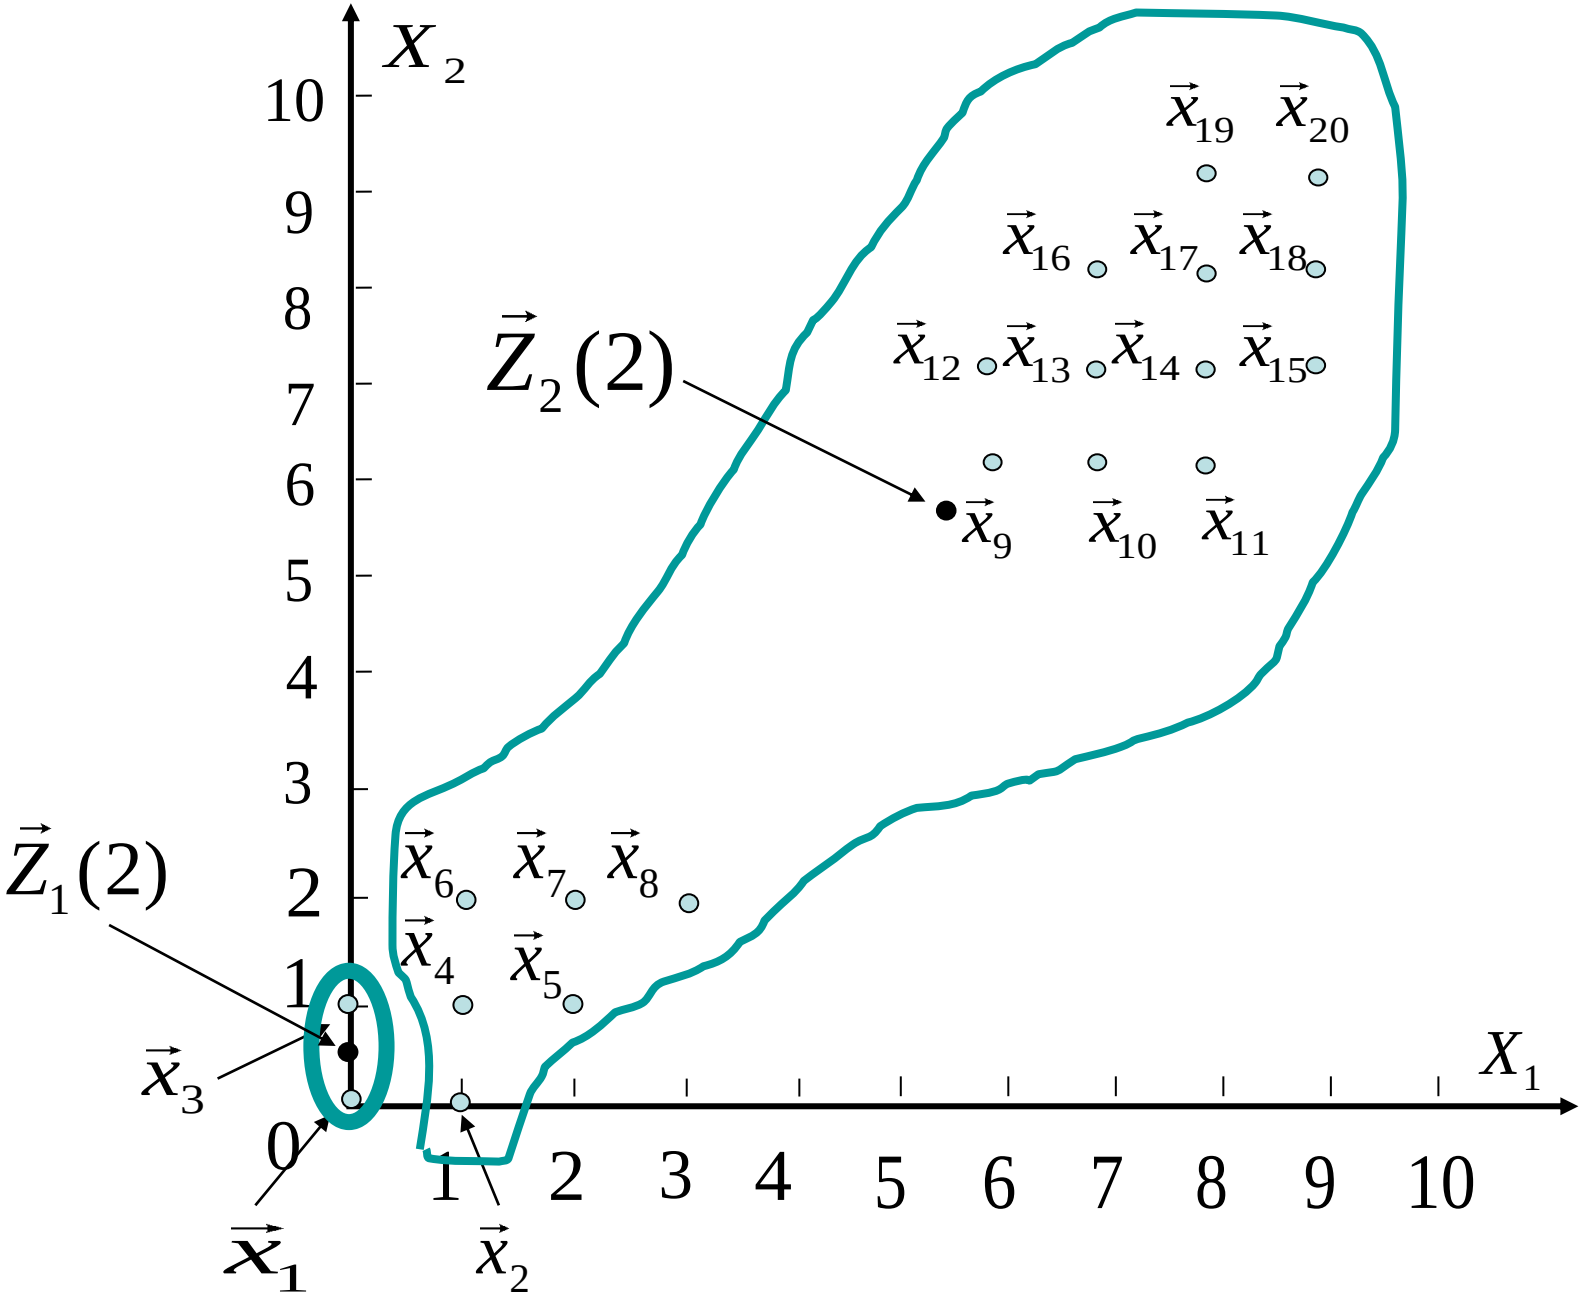
$$\because \| \vec{x}_4 - \vec{Z}_1(1) \| = 2 > \| \vec{x}_4 - \vec{Z}_2(1) \| = 1 \quad \therefore \vec{x}_4 \in \omega_2^{(1)}$$

$$\vec{x}_5, \vec{x}_6, \cdots, \vec{x}_{20} \in \omega_2^{(1)}$$

由此得到两类：

$$\omega_1^{(1)} = \{\vec{x}_1, \vec{x}_3\}, N_1 = 2$$

$$\omega_2^{(1)} = \{\vec{x}_2, \vec{x}_4, \vec{x}_5, \cdots, \vec{x}_{20}\}, N_2 = 18$$


X_2
X_1
$\vec{Z}_2(2)$
$\vec{Z}_1(2)$
$\vec{x}_1$
$\vec{x}_2$
$\vec{x}_3$
$\vec{x}_4$
$\vec{x}_5$
$\vec{x}_6$
$\vec{x}_7$
$\vec{x}_8$
$\vec{x}_9$
$\vec{x}_{10}$
$\vec{x}_{11}$
$\vec{x}_{12}$
$\vec{x}_{13}$
$\vec{x}_{14}$
$\vec{x}_{15}$
$\vec{x}_{16}$
$\vec{x}_{17}$
$\vec{x}_{18}$
$\vec{x}_{19}$
$\vec{x}_{20}$
0
1
2
3
4
5
6
7
8
9
10

第三步

$$\vec{Z}_1(2)=\frac{1}{N_1}\sum_{\vec{x}_i\in\omega_1^{(1)}}\vec{x}_i=\frac{1}{2}(\vec{x}_1+\vec{x}_3)=\frac{1}{2}\left[\begin{pmatrix}0\\0\end{pmatrix}+\begin{pmatrix}0\\1\end{pmatrix}\right]$$

$$=\frac{1}{2}\begin{pmatrix}0\\1\end{pmatrix}=(0,0.5)^T$$

$$\vec{Z}_2(2)=\frac{1}{N_2}\sum_{\vec{x}_i\in\omega_2^{(1)}}\vec{x}_i=\frac{1}{18}(\vec{x}_2+\vec{x}_4+\vec{x}_5+\ldots+\vec{x}_{20})$$

$$=(5.67,5.33)^T$$

第四步

因为 $\vec{Z}_j(2)\neq\vec{Z}_j(1),\ j=1,2$(新旧聚类中心不等)

转第二步。

第二步：重新计算 $\vec{x}_1,\vec{x}_2,\ldots,\vec{x}_{20}$ 到$\vec{Z}_1(2)$, $\vec{Z}_2(2)$ 的距离，把它们归为最近聚类中心，重新分为两类，

$$\omega_1^{(2)} = (\vec{x}_1, \vec{x}_2, ..., \vec{x}_8), N_1 = 8$$

$$\omega_2^{(2)} = (\vec{x}_9, \vec{x}_{10}, ..., \vec{x}_{20}), N_2 = 12$$

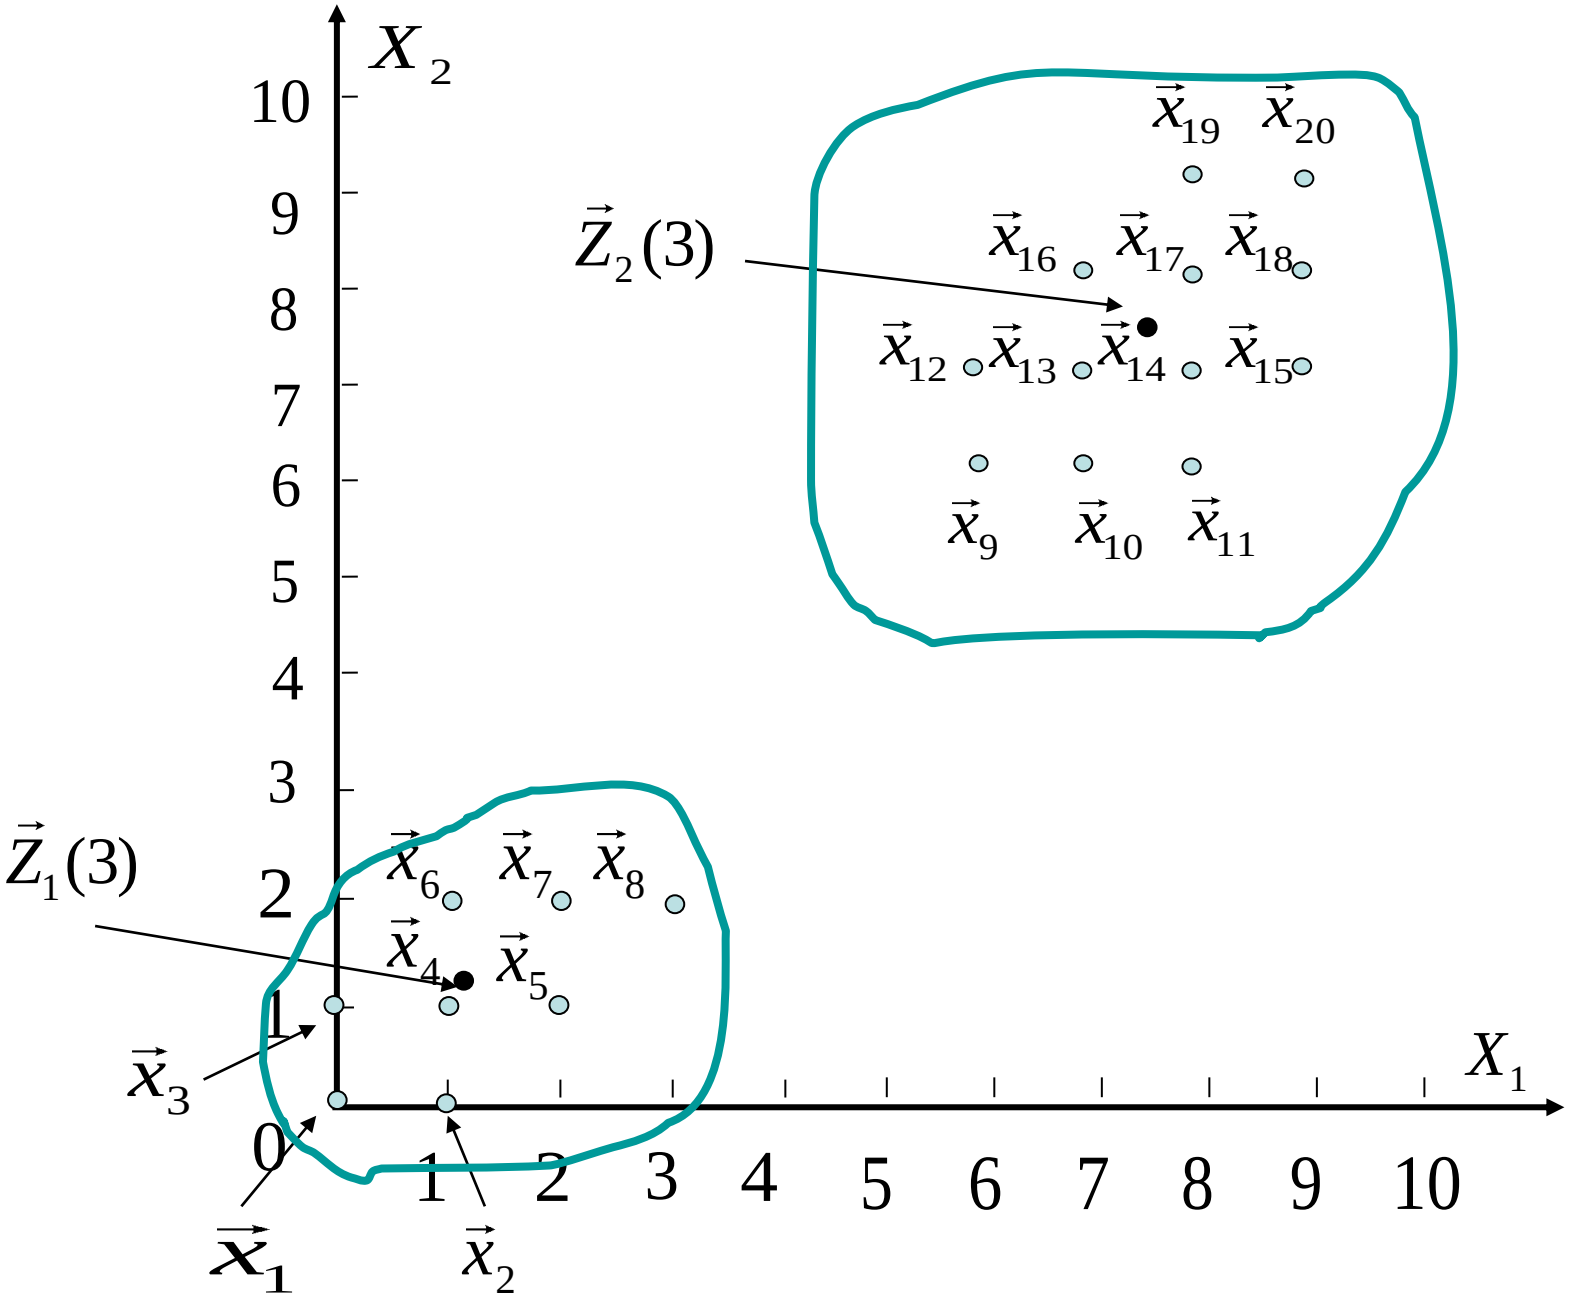
第三步

$$\vec{Z}_1(3) = \frac{1}{N_1} \sum_{\vec{x}_i \in \omega_1^{(2)}} \vec{x}_i = \frac{1}{8}(\vec{x}_1 + \vec{x}_2 + \vec{x}_3 + ... + \vec{x}_8)$$

$$= (1.25, 1.13)^T$$

$$\vec{Z}_2(3) = \frac{1}{N_2} \sum_{\vec{x}_i \in \omega_2^{(2)}} \vec{x}_i = \frac{1}{12}(\vec{x}_9 + \vec{x}_{10} + ... + \vec{x}_{20})$$

$$= (7.67, 7.33)^T$$


X_2
X_1
$\vec{Z}_2(3)$
$\vec{Z}_1(3)$
$\vec{x}_1$
$\vec{x}_2$
$\vec{x}_3$
$\vec{x}_4$
$\vec{x}_5$
$\vec{x}_6$
$\vec{x}_7$
$\vec{x}_8$
$\vec{x}_9$
$\vec{x}_{10}$
$\vec{x}_{11}$
$\vec{x}_{12}$
$\vec{x}_{13}$
$\vec{x}_{14}$
$\vec{x}_{15}$
$\vec{x}_{16}$
$\vec{x}_{17}$
$\vec{x}_{18}$
$\vec{x}_{19}$
$\vec{x}_{20}$
0 1 2 3 4 5 6 7 8 9 10

第四步 因$\vec{Z}_j(3) \neq \vec{Z}_j(2), j=1,2,$转第二步

第二步 重新计算$\vec{x}_1, \vec{x}_2, ..., \vec{x}_{20}$到$\vec{Z}_1(3), \vec{Z}_2(3)$的距离，

分别把$\vec{x}_1, \vec{x}_2, ..., \vec{x}_{20}$归于最近的那个聚类中心，

重新分为二类$\omega_1^{(3)} = (\vec{x}_1, \vec{x}_2, ..., \vec{x}_8)$

$\omega_2^{(3)} = (\vec{x}_9, \vec{x}_{10}, ..., \vec{x}_{20}), N_1 = 8, N_2 = 12$

第三步

$Z_1(3) = Z_1(4) = (1.25, 1.13)^T$

$Z_2(3) = Z_2(4) = (7.67, 7.33)^T$

计算结束。

4. 算法收敛性分析

C-均值法

- 收敛性分析

在分类过程中不断地计算新分划的类心并按最小距离原则归类可使类内距离平方和极小。

- 算法性能

- 是使模式到其类心距离平方和最小的最佳聚类
- 受类别数目和初始中心的影响，局部最优
- 方法简单，结果尚可

4. 算法收敛性分析

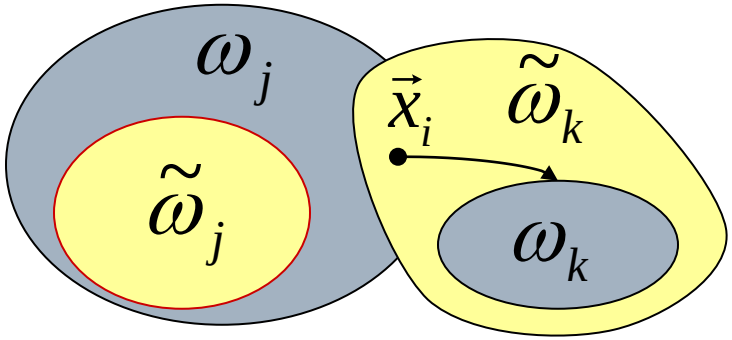
$$J^{(k)}=\sum_{j=1}^{c}\sum_{\vec{x}_i\in\omega_j^{(k)}}\left\|\vec{x}_i-\vec{z}_j^{(k)}\right\|^2$$

算法可使准则函数$J^{(k)}$变小，

- 设某样本 $\vec{x}_i$从聚类ω_j移至聚类ω_k中，移出后的集合记为$\tilde{\omega}_j$，移入后的集合记为$\tilde{\omega}_k$。可以证明

$$\tilde{J}_j=J_j-\frac{n_j}{n_j-1}\left\|\vec{x}_i-\vec{m}_j\right\|^2$$

$$\tilde{J}_k=J_k+\frac{n_k}{n_k+1}\left\|\vec{x}_i-\vec{m}_k\right\|^2$$



$$\because \left\|\vec{x}_i-\vec{m}_k\right\|^2<\left\|\vec{x}_i-\vec{m}_j\right\|^2,\quad (\vec{x}_i\text{距离}\omega_k\text{更近})$$

$$\frac{n_k}{n_k+1}\left\|\vec{x}_i-\vec{m}_k\right\|^2<\frac{n_j}{n_j-1}\left\|\vec{x}_i-\vec{m}_j\right\|^2$$

>1

$$\therefore \tilde{J}_j+\tilde{J}_k<J_j+J_k$$

距离平方和准则函数的变化关系证明

$$\because \vec{m} = \frac{1}{n}\sum_{l=1}^{n}\vec{x}_l = \frac{1}{n}\left(\sum_{l=1}^{n-1}\vec{x}_l + \vec{x}_i\right) = \frac{n-1}{n}\tilde{\vec{m}} + \frac{1}{n}\vec{x}_i \quad (1)$$

$$\therefore \vec{x}_i - \tilde{\vec{m}} = \frac{n}{n-1}(\vec{x}_i - \vec{m}) \quad (2)$$

$$J = \sum_{l=1}^{n}\left\|\vec{x}_l - \vec{m}\right\|^2 = \sum_{l=1}^{n-1}\left\|\vec{x}_l - \vec{m}\right\|^2 + \left\|\vec{x}_i - \vec{m}\right\|^2$$

$$= \sum_{l=1}^{n-1}\left\|\vec{x}_l - \frac{n-1}{n}\tilde{\vec{m}} - \frac{1}{n}\vec{x}_i\right\|^2 + \left\|\vec{x}_i - \vec{m}\right\|^2 = \sum_{l=1}^{n-1}\left\|\vec{x}_l - \tilde{\vec{m}} - \frac{1}{n}(\vec{x}_i - \tilde{\vec{m}})\right\|^2 + \left\|\vec{x}_i - \vec{m}\right\|^2$$

$$= \sum_{l=1}^{n-1}[(\vec{x}_l - \tilde{\vec{m}}) - \frac{1}{n-1}(\vec{x}_i - \vec{m})]'[(\vec{x}_l - \tilde{\vec{m}}) - \frac{1}{n-1}(\vec{x}_i - \vec{m})] + \left\|\vec{x}_i - \vec{m}\right\|^2$$

$$= \sum_{l=1}^{n-1}[\left\|\vec{x}_l - \tilde{\vec{m}}\right\|^2 - \frac{2}{n-1}(\vec{x}_l - \tilde{\vec{m}})'(\vec{x}_i - \vec{m}) + \frac{1}{(n-1)^2}(\vec{x}_i - \vec{m})'(\vec{x}_i - \vec{m})] + \left\|\vec{x}_i - \vec{m}\right\|^2$$

$$= \sum_{l=1}^{n-1}\left\|\vec{x}_l - \tilde{\vec{m}}\right\|^2 - 2[(\frac{1}{n-1}\sum_{l=1}^{n-1}\vec{x}_l) - \tilde{\vec{m}}]'(\vec{x}_i - \vec{m}) + \frac{1}{(n-1)}\left\|\vec{x}_i - \vec{m}\right\|^2 + \left\|\vec{x}_i - \vec{m}\right\|^2$$

$$= \tilde{J} - 2(\tilde{\vec{m}} - \tilde{\vec{m}})'(\vec{x}_i - \vec{m}) + \frac{n}{n-1}\left\|\vec{x}_i - \vec{m}\right\|^2$$

$$= \tilde{J} + \frac{n}{(n-1)}\left\|\vec{x}_i - \vec{m}\right\|^2$$

$$\therefore \tilde{J}_j = J_j - \frac{n_j}{(n_j-1)}\left\|\vec{x}_i - \vec{m}_j\right\|^2$$

注：上述推导过程中省略了下标*j*

C均值的计算复杂度

一般流程：

- 先随机设定k个聚类中心（此处的k决定了最终的k类）然后计算n个点到k个点的距离，单个点与点距离计算的复杂度为d
- 聚类完成之后，我们需要进一步迭代。首先计算聚的k个类的聚类中心，然后用找到的k个聚类中心进行再次聚类。
- 当聚类中心不再变动时，聚类停止。
- 设此时迭代次数为t次。

因此可以看出，k-means聚类复杂度为 O=k*n*d*t

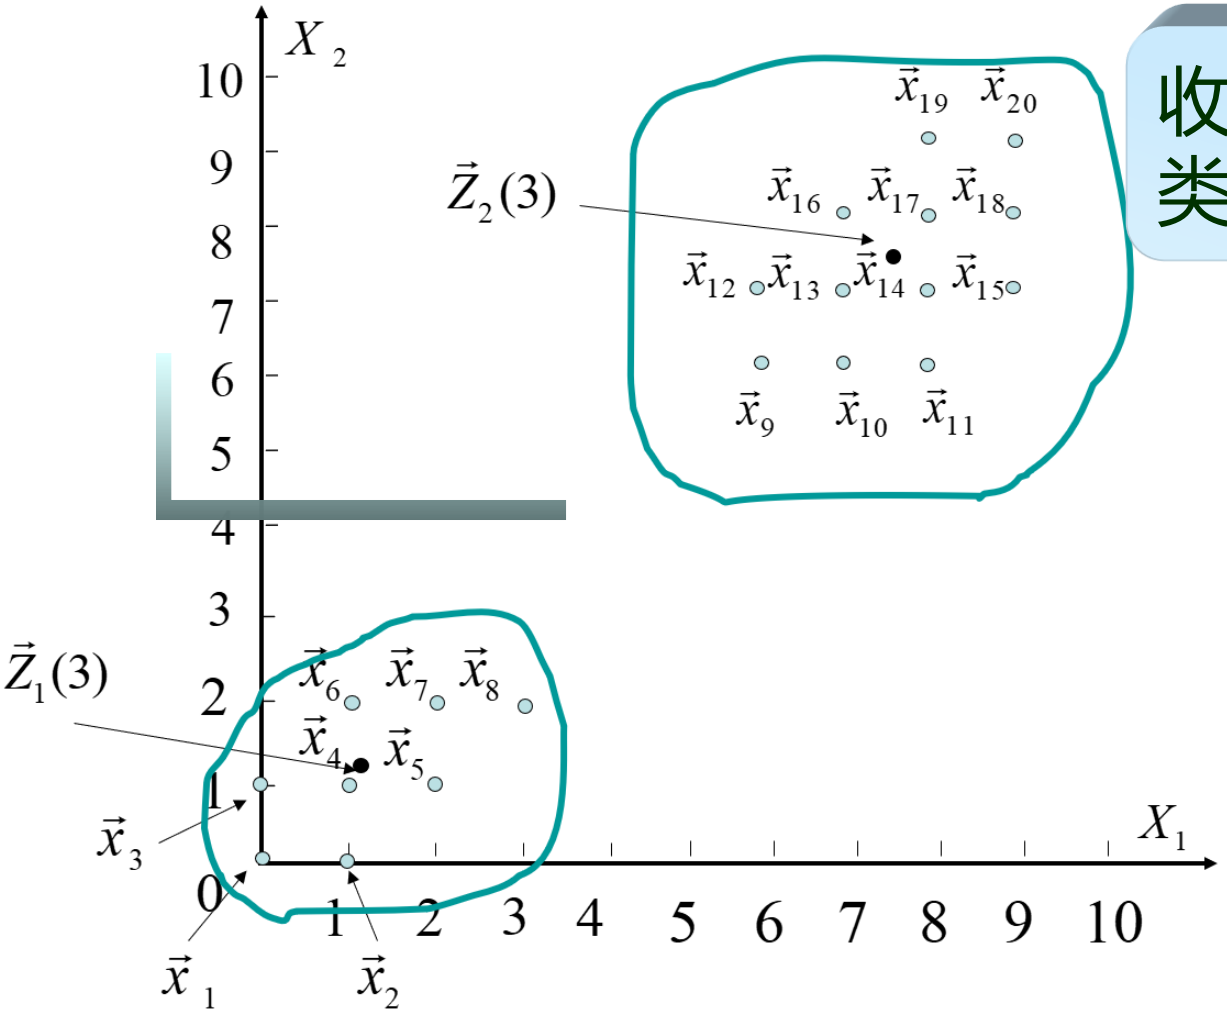
5. 性能

C-均值法

- 算法性能

➢是使模式到其类心距离平方和最小的最佳聚类
➢以确定的类数c、模式输入次序、及选定的初始聚类中心为前提，受此限制结果只是局部最优
➢算法简单，收敛。如模式呈现类内团状分布，效果很好，故应用较多。

小结



收敛特性
类内距离平方和极小。

- 算法性能

2.3 最近邻方法
Nearest Neighbour Classification

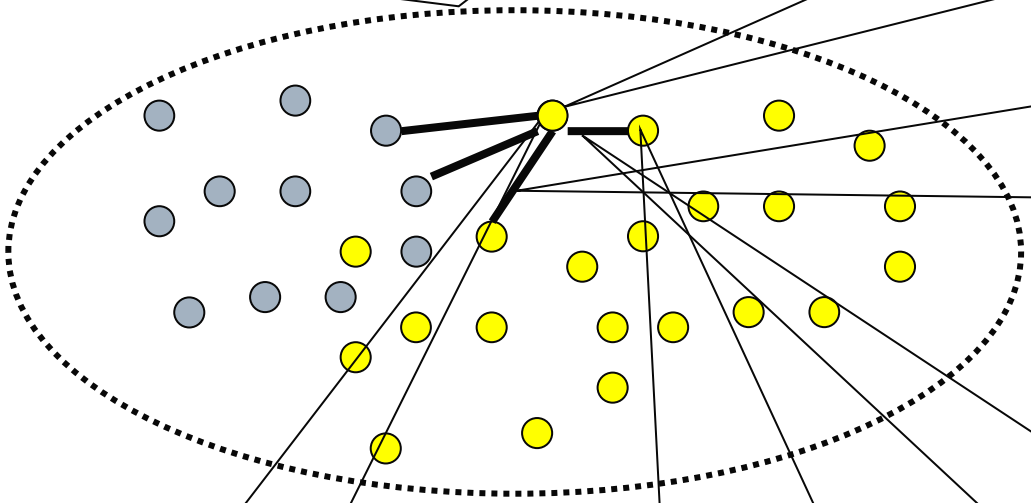
2.3.1 最近邻决策规则

2.3.2 剪辑最近邻法

2.3.1 最近邻决策规则—1-NN

(1)已知N个已知类别样本X

(2)输入未知类别样本x



(3)计算x到$x_i \in X$, $(i=1,2,\ldots,N)$的距离$d_i(x)$

(4)找出最小距离$d_m(x)=\min\{d_i(x)\}$

(5)看x_m属于哪一类：$x_m \in \omega_2$

(6) 判$x \in \omega_2$

问题

1近邻算法是：

- A 有监督分类
- B 无监督分类
- C 半监督分类

2.3.1 最近邻决策规则—1-NN

c类问题,设 $\vec{x}_j^{(i)} \in \omega_i \quad (i=1,2,\cdots c\ , j=1,2,\cdots N_i)$

最近邻分类规则:

对待识别模式 $\vec{x}$，分别计算它与 $N=\sum_{i=1}^{c} N_i$ 个已知类别的样本$\vec{x}_j^{(i)}$的距离,将它判为距离最近的那个样本所属的类。

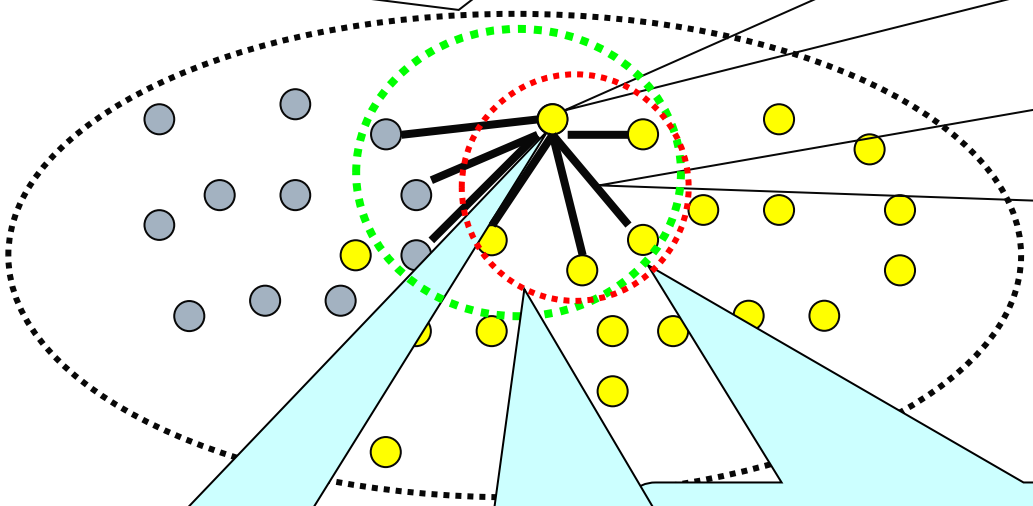
即 $d_i(\vec{x}) = \min_{j=1,2,\cdots,N_i} \left\| \vec{x} - \vec{x}_j^{(i)} \right\| \quad i=1,2,\cdots,c$

如果 $d_m(\vec{x}) = \min_{i=1,2,\cdots,c} d_i(\vec{x})$ 则 $\vec{x} \in \omega_m$

2.3.1 最近邻决策规则—k-NN

(1)已知N个已知类别样本X

(2)输入未知类别样本x



(3)计算x到$x_i \in X$, $(i=1,2,\ldots,N)$的距离$d_i(x)$

(4)找出x的k个最近邻元 $X_k=\{x_i, i=1,2,\ldots,k\}$

(5)看X_k中属于哪一类的样本最多 $k_1=3<k_2=4$

(6) 判$x \in \omega_2$

2.3.1 最近邻决策规则—k-NN

k-NN分类思想:

对待识别模式 $\vec{x}$ 分别计算它与 $N=\sum_{i=1}^{c} N_i$ 个已知类别的样本 $\vec{x}_j^{(i)}$ 的距离,取k个最近邻样本,这k个样本中哪一类最多, 就判属哪一类。 $\sum_{i=1}^{c} k_i = k$

即,令 $k_i,(i=1,,..,c)$ 为 $\vec{x}$ 的k个最近邻样本属于ω_i类的样本数，那么定义ω_i类的判决函数为

$$d_i(\vec{x}) = k_i$$

如果 $d_m(\vec{x}) = \max_{i=1,2,\cdots,c} d_i(\vec{x})$ 则 $\vec{x} \in \omega_m$

小 结

- K近邻是有监督还是无监督分类
- K近邻算法的演化过程

End

