厦门大学信息学院 本科选修课
2024-2025 第二学期

模 式 识 别
Pattern Recognition

主 讲：王程教授、陈龙彪副教授
厦门大学信息学院计算机科学与技术系
人工智能引论101计划系列课程



第四章　贝叶斯决策理论

4.1引言

4.2基于最小错误率的贝叶斯决策

4.3基于最小风险的贝叶斯决策

4.4分类器、判别函数及决策面

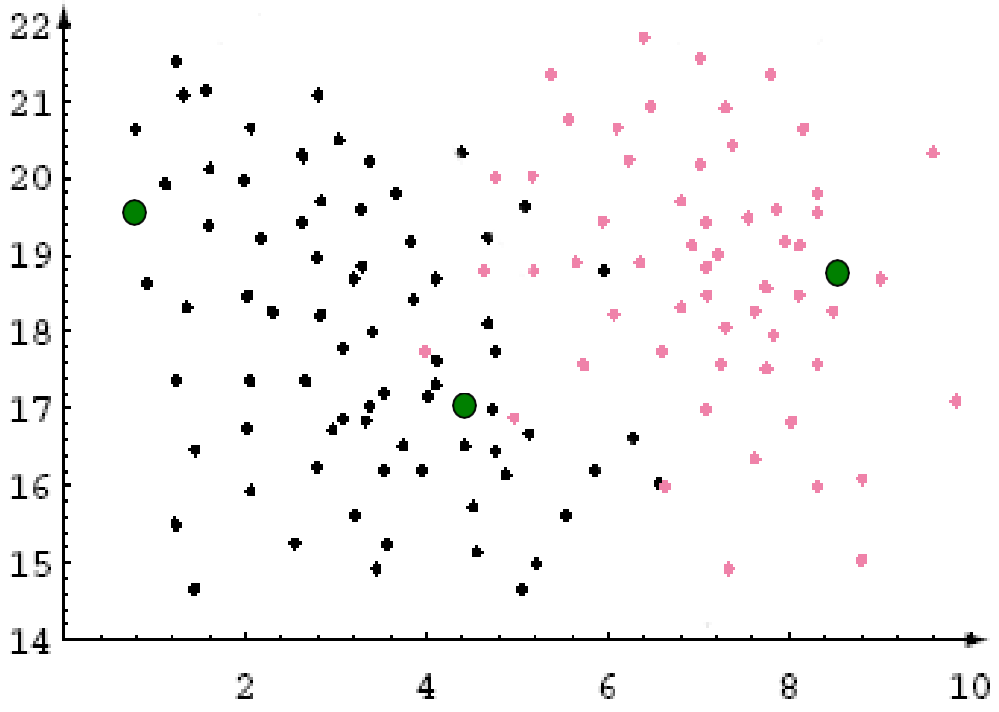
4.5概率推理&生成式学习算法

4.1 引 言

- 统计决策理论
  - 是模式分类问题的基本理论之一
- 贝叶斯决策理论
  - 是统计决策理论中的一个基本方法
- 贝叶斯决策的两个要求
  - 各个类别的总体概率分布(先验概率和类条件概率密度) 是已知的
  - 要决策分类的类别数是一定的

4.1 引 言

决 策



黑色：第一类

粉色：第二类

绿色：哪一类？

统计决策理论就是根据每一类总体的概率分布决定未知类别的样本属于哪一类！

4.1 引 言

决策准则

- 评价决策有多种标准，对于同一个问题，采用不同的标准会得到不同意义下“ 最优” 的决策
- 贝叶斯决策常用的准则：
  - 最小错误率准则
  - 最小风险准则
  - **Neyman-Pearson**(黎曼皮尔逊)准则
  - 最小最大决策准则

4.1 引 言

基本概念

- 在连续情况下，假设对要识别的物理对象有d种特 征观察量$x_1,x_2,\ldots x_d$，这些特征的所有可能的取值 范围构成了d维特征空间。

- 称向量 $\boldsymbol{x}=\left[x_1,x_2,\cdots,x_d\right]^T$ $\boldsymbol{x}\in\boldsymbol{R}^d$ 为d维特征向量。

- 假设要研究的分类问题有c个类别，类型空间表示为：

$$\Omega=\{\omega_1,\omega_2,\cdots,\omega_c\}$$

4.1 引 言

几个重要概念

- 先验概率: $P(\omega_i)$ 未获得观测数据之前类别的分布
- 类条件概率: $P(x|\omega_i)$ 表示在 ω_i 类条件下 x 的概率分布密度
- 后验概率: $P(\omega_i|x)$ 在 x 出现条件下 ω_i 类出现的概率

第四章　贝叶斯决策理论

4.1引言

4.2基于最小错误率的贝叶斯决策

4.3基于最小风险的贝叶斯决策

4.4分类器、判别函数及决策面

4.5概率推理&生成式学习算法

4.2 基于最小错误率的贝叶斯决策

- 鲈鱼/鲑鱼例子
  - 自然状态下，先验的类别状态，ω_i，$i=1,2$
    - ω_i类别状态是一个随机变量，$P(\omega_i)$ 表示为先验概率。
    - 捕获鲈鱼和鲑鱼的几率相等。

      $P(\omega_1) = P(\omega_2)$ (先验)

      $P(\omega_1) + P(\omega_2) = 1$ (排除其它鱼的种类)

4.2 基于最小错误率的贝叶斯决策

- 仅含先验信息的判别规则

$$\begin{cases} P(\omega_1) > P(\omega_2), & \omega_1 \\ P(\omega_1) < P(\omega_2), & \omega_2 \end{cases}$$

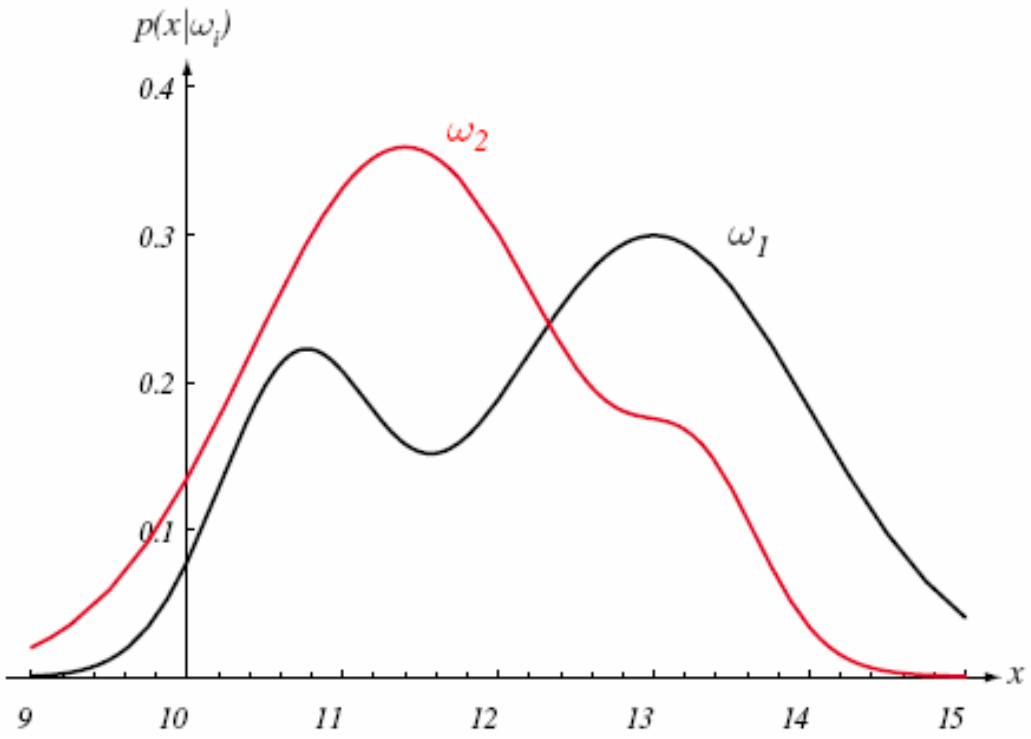
  - 这种分类决策没有意义
  - 由先验概率所提供的信息太少

- 采用类条件信息——类条件概率密度函数

  $p(x|\omega_1)$：鲈鱼的属性分布

  $p(x|\omega 2)$：鲑鱼的属性分布。

4.2 基于最小错误率的贝叶斯决策



鲈鱼和鲑鱼判别中的类条件概率密度函数
（以光泽度为例）

4.2 基于最小错误率的贝叶斯决策

- 贝叶斯公式
  - 先验概率，后验概率，概率密度函数之间关系

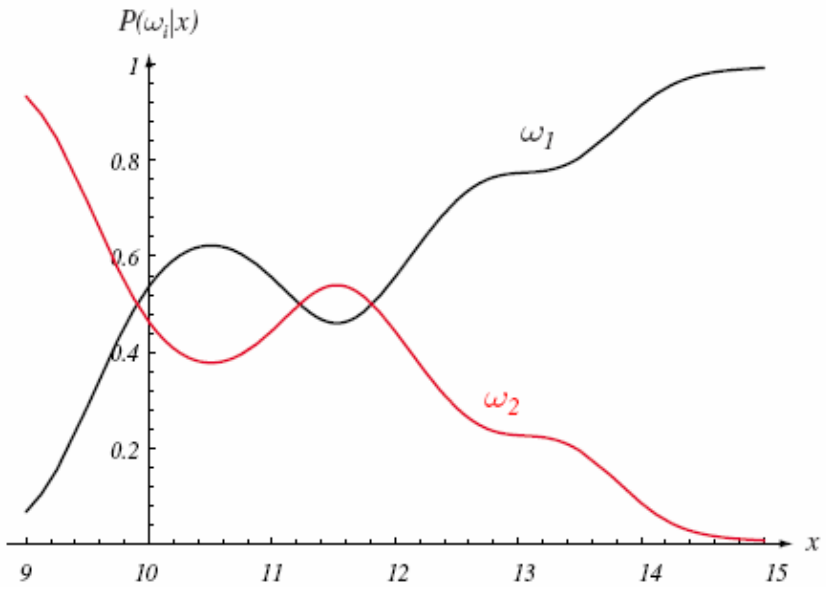
$$P(\omega_i \mid x) = \frac{p(x \mid \omega_i)P(\omega_i)}{\sum_{j=1}^{2} p(x \mid \omega_j)P(\omega_j)} \qquad i = 1,2$$

其中，$p(x) = \sum_{j=1}^{2} p(x \mid \omega_j)P(\omega_j)$为一因子

贝叶斯公式通过类条件概率密度形式的观察值， 将先验概率转化为后验概率。

4.2 基于最小错误率的贝叶斯决策

- 后验概率含义
  - $P(\omega_1|x)$：当观测向量为x值时，是鲈鱼的概率。
  - $P(\omega_2|x)$：当观测向量为x值时，是鲑鱼的概率。



4.2 基于最小错误率的贝叶斯决策

- 基于后验概率的决策规则：

存在一个观察值x(特征)

如果$P(\omega_1 \mid x) > P(\omega_2 \mid x)$　类别状态= ω_1

如果$P(\omega_1 \mid x) < P(\omega_2 \mid x)$　类别状态 = ω_2

因此，无论何时观测到某一个特定值x，概率误差为：

$P(error|x)=P(\omega_1|x)$ 判定为ω_2 (错误选择ω_1);

$P(error|x)=P(\omega_2|x)$ 判定为ω_1(错误选择ω_2);

4.2 基于最小错误率的贝叶斯决策

◆基于后验分布的判别规则：

错误概率的最小化判定规则：

如果 $P(\omega_1|x)>P(\omega_2|x)$，判定为$\omega_1$,

否则，判定为ω_2

因此， $P(error \mid x) = \min [P(\omega_1 \mid x), P(\omega_2 \mid x)]$

(最大后验概率准则可以保证最小错误率， 所以又称最小错误率准则)

4.2 基于最小错误率的贝叶斯决策

- 基于最小错误率的贝叶斯决策：

$$\begin{aligned} &P(\omega_1 \mid x) > P(\omega_2 \mid x) \qquad x \in \omega_1 \\ &P(\omega_1 \mid x) < P(\omega_2 \mid x) \qquad x \in \omega_2 \end{aligned}$$

等价形式

$$(1) P(\omega_i \mid x) = \max_{j=1,2} P(\omega_j \mid x) \qquad x \in \omega_i$$

$$(2)\, p(x \mid \omega_i) P(\omega_i) = \max_{j=1,2} p(x \mid \omega_j) P(\omega_j) \qquad x \in \omega_i$$

$$(3) l(x) = \frac{p(x \mid \omega_1)}{p(x \mid \omega_2)} \begin{matrix} > \\ < \end{matrix} \frac{P(\omega_2)}{P(\omega_1)} \qquad x \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$$ 似然比形式

$$(4) \ln[l(x)] = \ln p(x \mid \omega_1) - \ln p(x \mid \omega_2) \begin{matrix} > \\ < \end{matrix} \ln\left(\frac{P(\omega_1)}{P(\omega_2)}\right) \qquad x \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$$

4.2 基于最小错误率的贝叶斯决策

例：假设在某个局部地区细胞识别中正常和异常两类的先验概率分别为

正常状态：$P(\omega_1)=0.9$

异常状态：$P(\omega_2)=0.1$

现有一待识别的细胞，其观察值为$\boldsymbol{x}$，类条件概率密度分别为 $p(x|\omega_1)=0.2, p(x|\omega_2)=0.4$ 试对该细胞x进行分类。

解：

$$P(\omega_1|x)=\frac{p(x|\omega_1)P(\omega_1)}{\sum_{j=1}^{2}p(x|\omega_j)P(\omega_j)}=\frac{0.2\times0.9}{0.2\times0.9+0.4\times0.1}=0.818$$

$$P(\omega_2|x)=1-P(\omega_1|x)=0.182$$

$$P(\omega_1|x)=0.818>P(\omega_2|x)=0.182 \qquad \therefore x\in\omega_1$$

4.2 基于最小错误率的贝叶斯决策

最小错误率的讨论

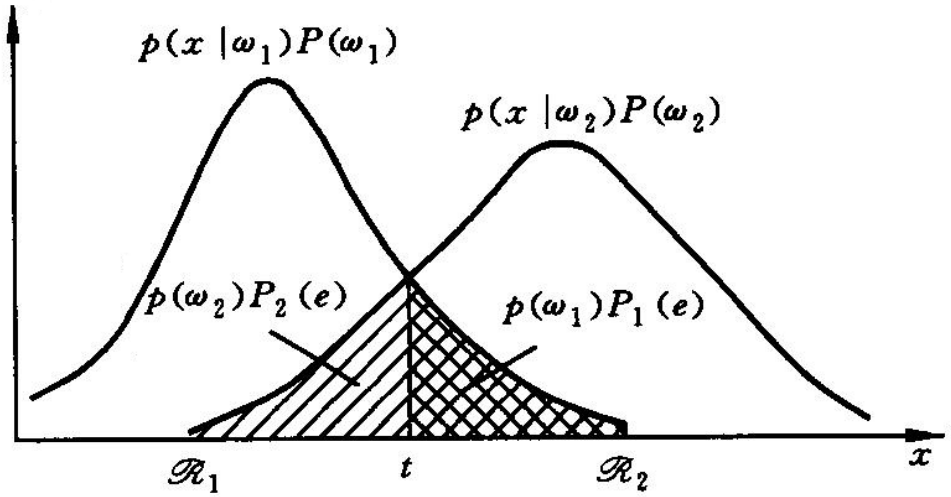
- 以一维情况为例讨论基于最小错误率的贝叶斯决策确实对应最小错误率
  - 统计意义上的错误率，即平均错误率，用**P(e)**表示

$$P(e)=\int_{-\infty}^{\infty}P(e,x)dx=\int_{-\infty}^{\infty}P(e\mid x)\,p(x)dx$$

其中，$P(e\mid x)=\begin{cases}P(\omega_1\mid x) & \text{当}P(\omega_2\mid x)>P(\omega_1\mid x)\\ P(\omega_2\mid x) & \text{当}\ P(\omega_1\mid x)>P(\omega_2\mid x)\end{cases}$

4.2 基于最小错误率的贝叶斯决策

最小错误率的讨论



$$P(e)=\int_{-\infty}^{\infty}P(e\mid x)\,p(x)dx$$

$$=\int_{-\infty}^{t}P(\omega_2\mid x)\,p(x)dx+\int_{t}^{\infty}P(\omega_1\mid x)\,p(x)dx$$

$$=\int_{-\infty}^{t}p(x\mid\omega_2)P(\omega_2)dx+\int_{t}^{\infty}p(x\mid\omega_1)P(\omega_1)dx$$

$$=P(\omega_2)P_2(e)+P(\omega_1)P_1(e)$$

4.2 基于最小错误率的贝叶斯决策

最小错误率的讨论

- 最大后验概率保证了选取到t*，同时t*保证了最小错误率；
- 每个样本的误差最小，保证了整个空间误差最小；
- 最小错误率所对应的分类器是最优分类器；
- 为什么存在基于最小错误率的最优分类器，还需要设计其他分类器呢？

样本有限情况下，类条件概率密度形式、参数估计都不准确。

4.2 基于最小错误率的贝叶斯决策

C类别情况下最下错误率

- 在*C*类别情况下最小错误率贝叶斯决策规则的后验概率形式：

$$P(\omega_i|x) = \max_{j=1,2,\cdots,c} P(\omega_j|x)$$

- 先验概率与类条件概率密度相联系的形式：

$$P(x|\omega_i)P(\omega_i) = \max_{j=1,2,\cdots,c} P(x|\omega_j)P(\omega_j), \text{则} \quad x \in \omega_i$$

4.2 基于最小错误率的贝叶斯决策

小结

贝叶斯公式：

$$P(\omega_i \mid x) = \frac{p(x \mid \omega_i)P(\omega_i)}{\sum_{j=1}^{2} p(x \mid \omega_j)P(\omega_j)} \qquad i = 1,2$$

基于最小错误率的贝叶斯决策规则：

$$\begin{aligned} &P(\omega_1 \mid x) > P(\omega_2 \mid x) && x \in \omega_1 \\ &P(\omega_1 \mid x) < P(\omega_2 \mid x) && x \in \omega_2 \end{aligned}$$

第四章　贝叶斯决策理论

4.1引言

4.2基于最小错误率的贝叶斯决策

4.3基于最小风险的贝叶斯决策

4.4分类器、判别函数及决策面

4.5概率推理&生成式学习算法

4.3 基于最小风险的贝叶斯决策

主要思想：

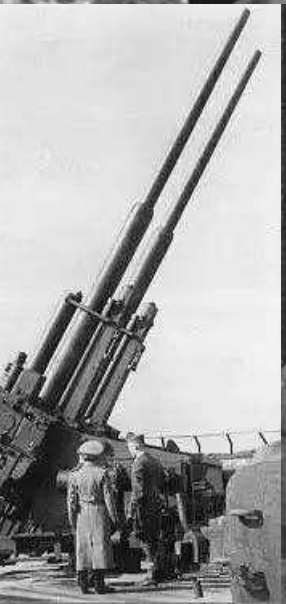
◆在最小错误率决策中，使错误率达到最小是重要。但实际上，有时候需要考虑一个比错误率更广泛的概念—风险，而风险又是和损失紧密相连的。

◆我们对样本的分类不仅要考虑到尽可能作出正确的判断，而且还要考虑到作出错误判断时 会带来什么后果。

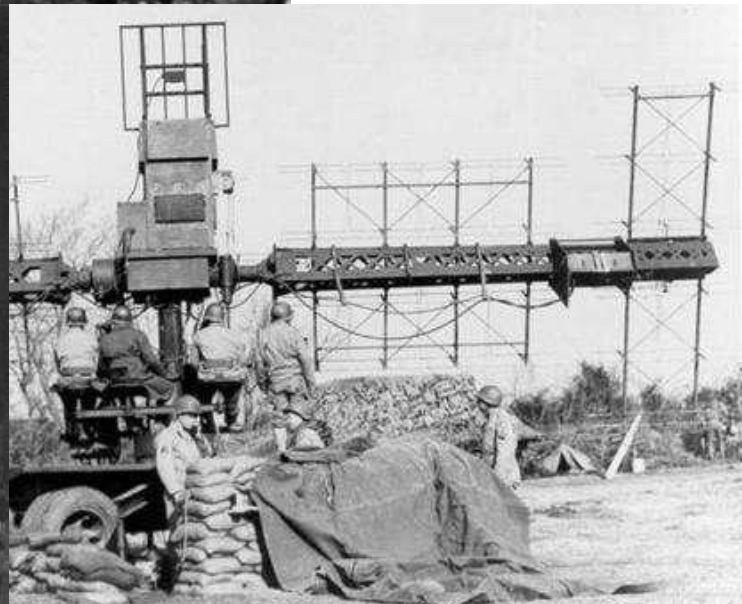
◆最小风险贝叶斯决策正是考虑各种错误造成损失不同而提出的一种决策规则。








LuftArchiv.de



4.3 基于最小风险的贝叶斯决策

两分类问题下的最小风险准则

决策行动：α_1 ：对应于类别判别ω_1；α_2:对应于类别判别ω_2

损失：$\lambda(\alpha_i,\omega_j)=\lambda_{ij}$表示当实际类别为$\omega_j$时误判为$\omega_i$所引起的损失。

条件风险（条件期望损失）：

$$R(\alpha_1 \mid x)=\lambda_{11}P(\omega_1 \mid x)+\lambda_{12}P(\omega_2 \mid x)$$

$$R(\alpha_2 \mid x)=\lambda_{21}P(\omega_1 \mid x)+\lambda_{22}P(\omega_2 \mid x)$$

最小风险决策规则：

如果 $R(\alpha_1 \mid x)<R(\alpha_2 \mid x)$ ，则根据决策行动α_1，判决类别ω_1。

4.3 基于最小风险的贝叶斯决策

似然比形式

$$R(\alpha_1 \mid x) = \lambda_{11}P(\omega_1 \mid x) + \lambda_{12}P(\omega_2 \mid x) \qquad R(\alpha_2 \mid x) = \lambda_{21}P(\omega_1 \mid x) + \lambda_{22}P(\omega_2 \mid x)$$

$R(\alpha_1 \mid x) < R(\alpha_2 \mid x)$ 等价于：

$$\lambda_{11}P(\omega_1 \mid x) + \lambda_{12}P(\omega_2 \mid x) < \lambda_{21}P(\omega_1 \mid x) + \lambda_{22}P(\omega_2 \mid x)$$

$$(\lambda_{12} - \lambda_{22})P(\omega_2 \mid x) < (\lambda_{21} - \lambda_{11})P(\omega_1 \mid x)$$

$$(\lambda_{12} - \lambda_{22})\frac{p(x \mid \omega_2)P(\omega_2)}{p(x)} < (\lambda_{21} - \lambda_{11})\frac{p(x \mid \omega_1)P(\omega_1)}{p(x)}$$

$$(\lambda_{12} - \lambda_{22})\,p(x \mid \omega_2)P(\omega_2) < (\lambda_{21} - \lambda_{11})\,p(x \mid \omega_1)P(\omega_1)$$

$$\frac{p(x \mid \omega_1)}{p(x \mid \omega_2)} > \frac{(\lambda_{12} - \lambda_{22})}{(\lambda_{21} - \lambda_{11})} \times \frac{P(\omega_2)}{P(\omega_1)}$$

与x无关，对于某个问题，是个可以事先计算的常量。

似然比大于某个阈值，则采取行动决策α_1(判决ω_1)；否则为：ω_2

4.3 基于最小风险的贝叶斯决策

两分类问题下的最小风险准则

$$(\lambda_{12}-\lambda_{22})P(\omega_2\mid x)<(\lambda_{21}-\lambda_{11})P(\omega_1\mid x),\qquad \omega_1$$

$$(\lambda_{12}-\lambda_{22})P(\omega_2\mid x)>(\lambda_{21}-\lambda_{11})P(\omega_1\mid x),\qquad \omega_2$$

在两类问题中，若有 $\lambda_{12}-\lambda_{22}=\lambda_{21}-\lambda_{11}$ ，决策规则变为

$$P(\omega_2\mid x)<P(\omega_1\mid x),\qquad \omega_1$$

$$P(\omega_2\mid x)>P(\omega_1\mid x),\qquad \omega_2$$

4.3 基于最小风险的贝叶斯决策

多类问题下的最小风险准则

在c个类别的问题中，如果损失函数为“0-1”损失函数：

$$\lambda(\alpha_i \mid \omega_j)=\begin{cases}0 & i=j\\ 1 & i\neq j\end{cases} \qquad i,j=1,...,c \qquad \alpha_i,\ i=1,2,\cdots,c$$

“0-1”损失函数：

1 对于c类问题只有c个决策，

2 实际类别 ω_j 正确判定为第j类时，损失为0。

3 实际类别 ω_j 误判为第 $i\neq j$ 类时，损失均为1。

4.3 基于最小风险的贝叶斯决策

“0-1”损失函数下的最小风险准则

$$R(\alpha_i \mid \boldsymbol{x}) = \sum_{j=1}^{c} \lambda(\alpha_i, \omega_j) P(\omega_j \mid \boldsymbol{x}) = \sum_{\substack{j=1 \\ i \neq j}}^{c} P(\omega_j \mid \boldsymbol{x})$$

$$\sum_{j=1}^{c} P(\omega_j \mid \boldsymbol{x}) = \frac{\sum_{j=1}^{c} p(\boldsymbol{x} \mid \omega_j) P(\omega_j)}{\sum_{i=1}^{c} p(\boldsymbol{x} \mid \omega_i) P(\omega_i)} = 1$$

$$R(\alpha_k \mid \boldsymbol{x}) = \min_{i=1,2,\cdots,c} R(\alpha_i \mid \boldsymbol{x})$$

$$= \min_{i=1,2,\cdots,c} \sum_{\substack{j=1 \\ j \neq i}}^{c} P(\omega_j \mid \boldsymbol{x})$$

$$= \min_{i=1,2,\cdots,c} [1 - P(\omega_i \mid \boldsymbol{x})] = \max_{i=1,2,\cdots,c} P(\omega_i \mid \boldsymbol{x})$$

最小错误率贝叶斯决策是在0-1损失函数条件下的最小风险贝叶斯决策，最小错误率贝叶斯决策是最小风险贝叶斯决策的特例。

第四章　贝叶斯决策理论

4.1引言

4.2基于最小错误率的贝叶斯决策

4.3基于最小风险的贝叶斯决策

4.4分类器、判别函数及决策面

4.5概率推理&生成式学习算法

4.4 分类器、判别函数及决策面

判别函数（Discriminant Function）：

- 用于表示决策规则的某些函数$g_i(x)$称为判别函数。每个类别对应一个判别函数

$$g_i(x),\ i=1,2,\cdots,c$$

- 通常定义一组判别函数$g_i(x),\ i=1,2,\cdots,c$ 用于表示多类决策规则。

- 如果使 $g_i(x) > g_j(x)$ 对于一切$i \neq j$ 成立，

  则将 $\boldsymbol{x}$ 归于 ω_i 类。

4.4 分类器、判别函数及决策面

决策面（Decision Surface）：

对于**c**类分类问题，按照决策规则可以把**d**维特征空间分成**c**个决策域，将划分决策域的边界面称为决策面，在数学上用解析形式可以表示成决策面方程。

- 判决区域$\mathbf{R}_i$是特征空间中的一个子空间，判决规则将所有落入$\mathbf{R}_i$的样本**x**分类为类别ω_i；
- 判决边界是特征空间中划分判决区域的（超）平面；
- 在判决边界上，通常有两类或多类的判别函数值相等。

4.4 分类器、判别函数及决策面

分类器设计（Classifier）：

分类器的功能是先计算出c个判别函数，再从中 选择出对应于判别函数为最大值的类作为决策结果。 分类器设计核心设计判别函数，求出判定面方程！

分类器最常用的表述方式为判别函数：

$g_i(x), \quad i=1,2,\cdots,c$ 每个类别对应一个判别函数。

基于判别函数的判决：

如果：$g_i(x) > g_j(x), \quad \forall i, j$ ，则属于ω_i

决策面方程： $g_i(x) = g_j(x)$

4.4 分类器、判别函数及决策面

基于最小错误率的判决函数

$$g_i(x) = p(\omega_i \mid x)$$

$$g_i(x) = p(x \mid \omega_i)\, p(\omega_i)$$

$$g_i(x) = \ln p(x \mid \omega_i) + \ln p(\omega_i)$$

基于最小风险的判决函数

$$g_i(x) = -R(\alpha_i \mid x)$$

4.4 分类器、判别函数及决策面

两分类下的判别函数

- 特殊的，对于两分类问题，也可以只用一个判别函数

令： $g(x)=g_1(x)-g_2(x)$

- **判决规则**

如果： $g(x)>0$ 则模式为 ω_1 否则为 ω_2

- **例如：**

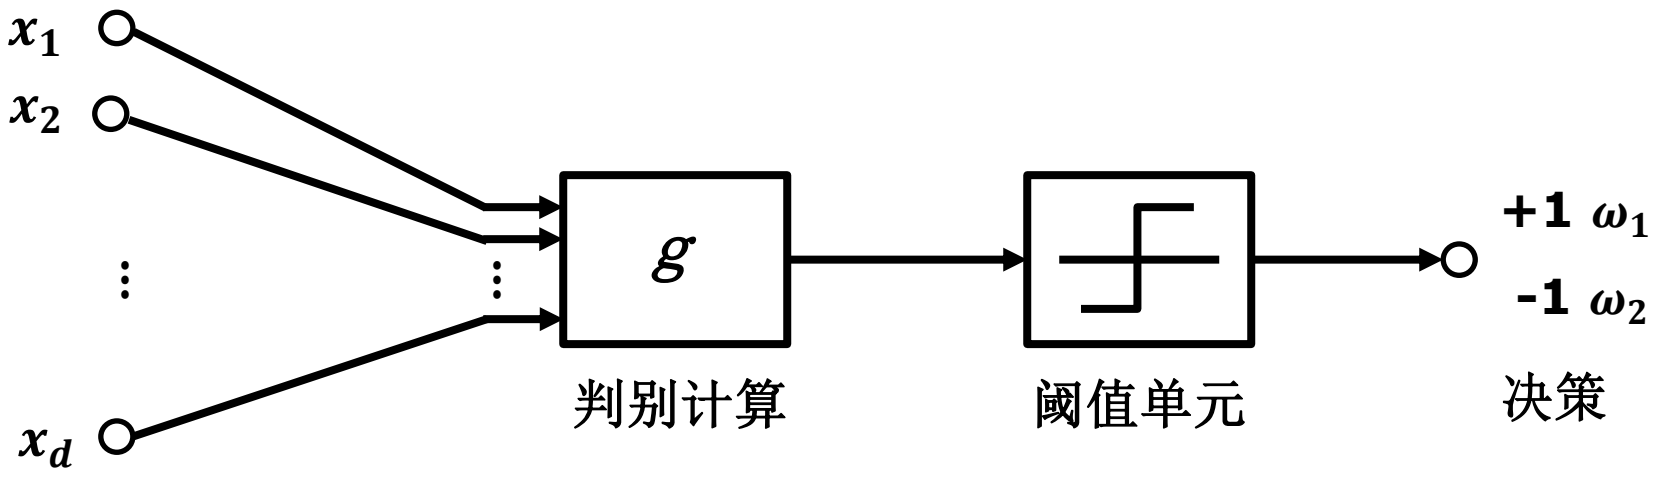
$$g(x)=p(\omega_1|x)-p(\omega_2|x) \qquad g(x)=\ln\frac{p(x|\omega_1)}{p(x|\omega_2)}+\ln\frac{p(\omega_1)}{p(\omega_2)}$$

$$g(x)=p(x|\omega_1)\,p(\omega_1)-p(x|\omega_2)\,p(\omega_2)$$

- **决策面：** $g(x)=0$

4.4 分类器、判别函数及决策面

两分类下的判别函数



图：两类分类器的构成

4.4 分类器、判别函数及决策面

例子

例题： 假设细胞识别中正常（ω_1）和异常（ω_2）两类的先验概率分别为0.9和0.1。现有一待识别的细胞，其观测值为$\boldsymbol{X}$，从类条件概率密度分布曲线上查得$P(\boldsymbol{X}|\omega_1)=0.2$，$P(\boldsymbol{X}|\omega_2)=0.4$，并且有表2.2的决策表。试利用最小误差率贝叶斯决策和最小风险贝叶斯决策进行分类。

损失 / 状态 / 决策	ω_1	ω_2
a_1	0	6
a_1	1	0

决策表

求：利用最小错误率和最小风险决策分别写出判别函数和决策面方程。

利用最小错误率决策，其对应的判别函数为：

$$g(x) = p(x|\omega_1)P(\omega_1) - p(x|\omega_2)P(\omega_2)$$
$$= 0.9p(x|\omega_1) - 0.1p(x|\omega_2)$$

决策面方程为：$9p(x|\omega_1) - p(x|\omega_2) = 0$

利用最小风险决策，其对应的判别函数为：

$$g(x) = R(\alpha_2|x) - R(\alpha_1|x) = \lambda_{21}P(\omega_1|x) - \lambda_{12}P(\omega_2|x)$$
$$= \lambda_{21}p(x|\omega_1)P(\omega_1) - \lambda_{12}p(x|\omega_2)P(\omega_2)$$
$$= 0.9p(x|\omega_1) - 0.6p(x|\omega_2)$$

决策面方程为：$9p(x|\omega_1) - 6p(x|\omega_2) = 0$

4.4 分类器、判别函数及决策面

多分类下的判别函数

判决函数：

$$g_i(x) = p(\omega_i | x)$$

$$g_i(x) = p(x|\omega_i)\, p(\omega_i)$$

$$g_i(x) = \ln p(x|\omega_i) + \ln p(\omega_i)$$

X	决策面
一维	分界点
二维	曲线
三维	曲面
d维(d>3)	超曲面

决策面：

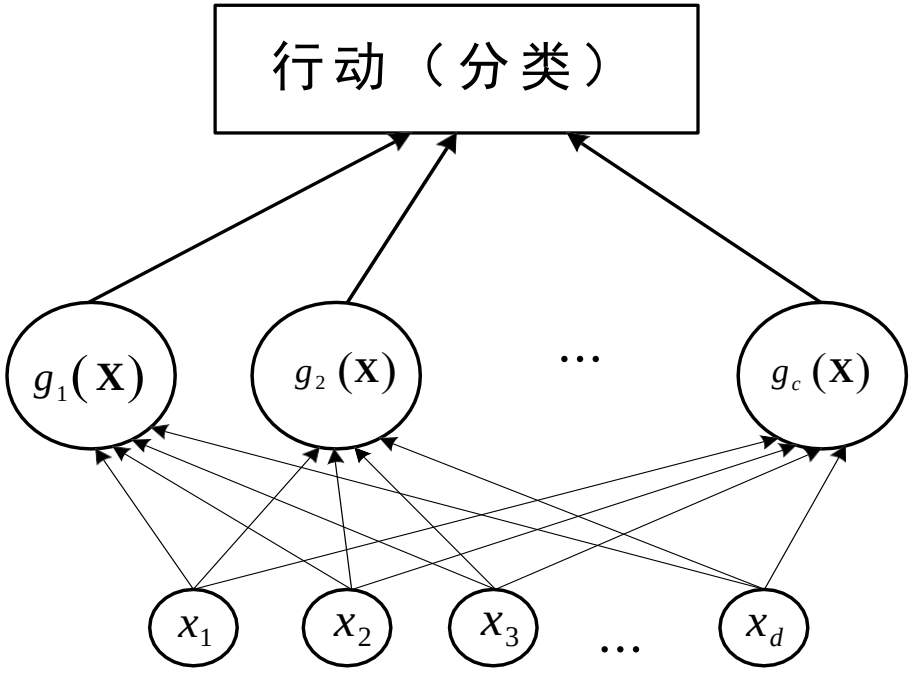
$$g_i(x) > g_j(x), \quad \forall j \neq j$$

则模式为： ω_i

4.4 分类器、判别函数及决策面

多分类下的判别函数

分类器设计：它的功能是先计算出c个判别函数g_i，再从中选出对应于判别函数为最大值的类作为决策结果。



4.4 分类器、判别函数及决策面

判别函数、决策面

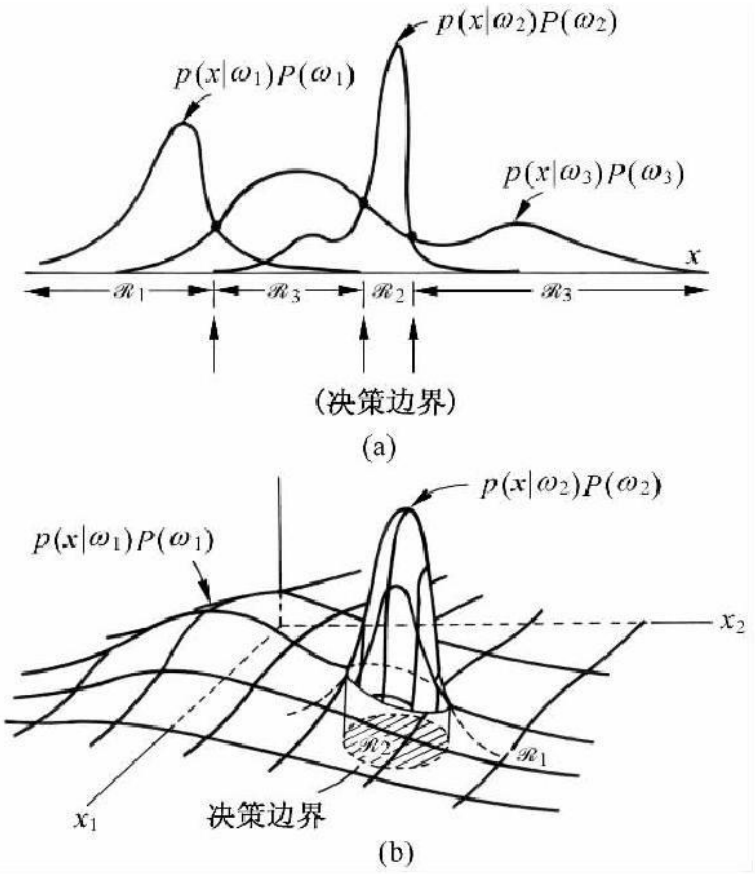
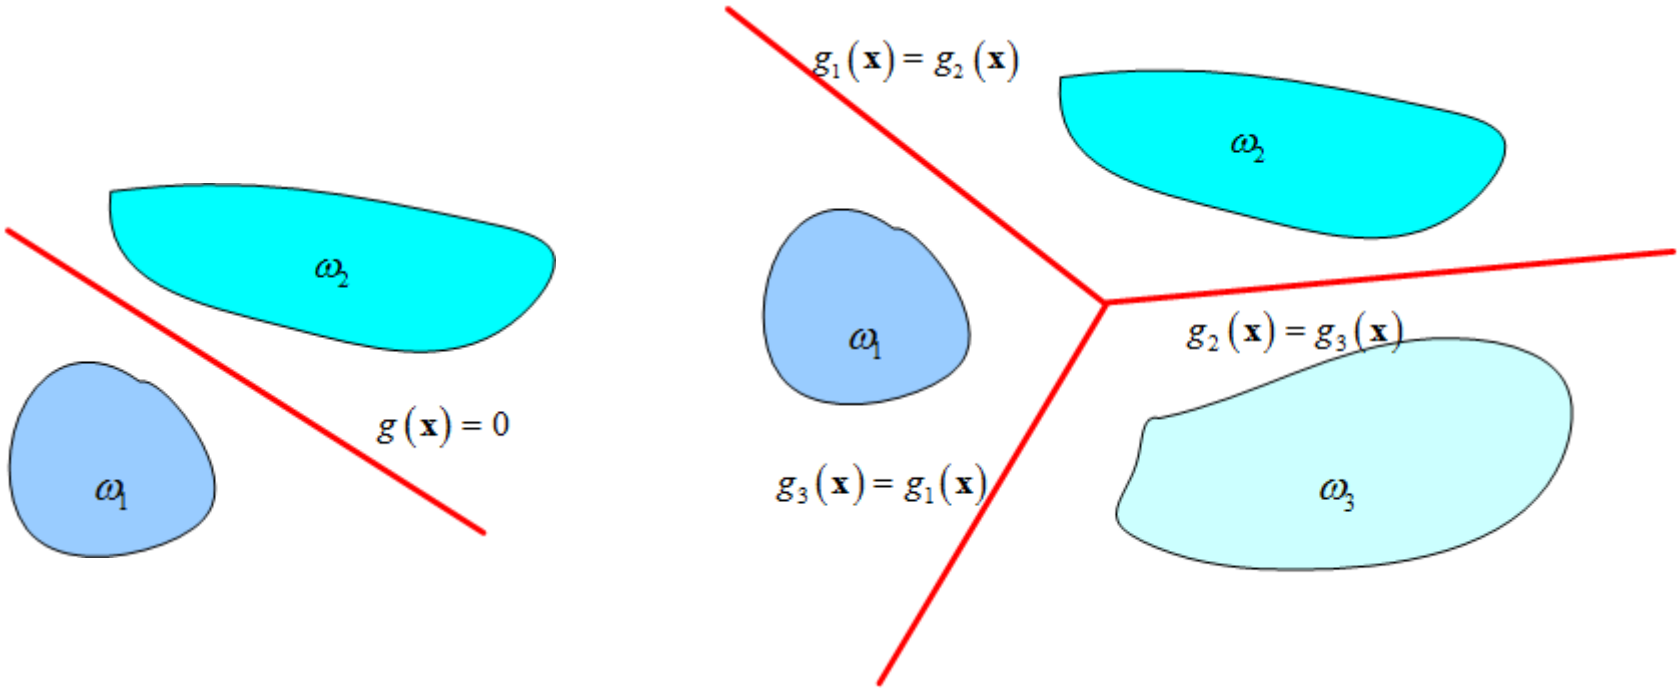


图 2.5 决策面

4.4 分类器、判别函数及决策面

判别函数，决策面



第四章　贝叶斯决策理论

4.1引言

4.2基于最小错误率的贝叶斯决策

4.3基于最小风险的贝叶斯决策

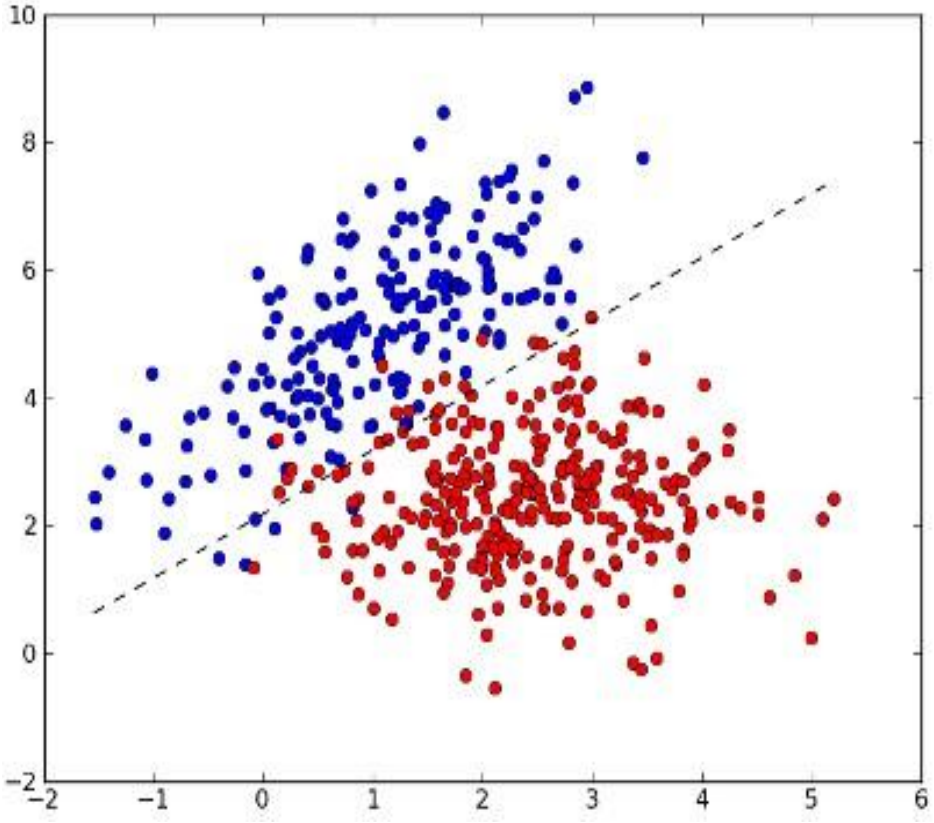
4.4分类器、判别函数及决策面

4.5概率推理&生成式学习算法

4.5概率推理&生成式学习算法

基于hard-decision的分类器的局限性

- 不确定度量
- 无法处理噪声数据
- 泛化能力差
- 难以优化



有什么替代方案？

4.5概率推理&生成式学习算法

生成式学习算法

解决方案：给定数据 x，建立类别标签 y 的分布模型。

$$p(y=c|\boldsymbol{x})=\frac{P(\boldsymbol{x}|y=c)*P(y=c)}{p(\boldsymbol{x})}$$

两种模型:

生成式

- 模型联合分布$p(x,y=c)=p(x|y=c)*p(y=c)$

判别式

- 直接建模分布 $p(y=c|\boldsymbol{x})$

给定 p(y | x) 我们就可以根据问题预测 $\hat{y}$ 。

一般的模型选择:$\hat{y}=argmax_{c\in C}P(y=c|x)$.

4.5概率推理&生成式学习算法

概率推理

我们掷同样的硬币10次：

正 反 正 正 反 正 正 正 反 正

下一次抛硬币的为 反 概率是多少？



正面



反面



4.5概率推理&生成式学习算法

概率推理

我们掷同样的硬币10次：

正 反 正 正 反 正 正 正 反 正

下一次抛硬币的为 反 概率是多少？

~ 0 ~ 0.3 ~ 0.38 ~ 0.5 ~ 0.76 ~ 1

4.5概率推理&生成式学习算法

概率推理

30%？为什么呢？

每次翻转都是随机的。因此，每个翻转序列都是随机的，也就是说，它有一定的概率被观察到。

对于第 i 次掷硬币，我们可以写成

$$p_i(F_i = \text{反}) = \theta_i$$

为了表示概率分布取决于 θ_i，我们写成

$$p_i(F_i = \text{反} \mid \theta_i) = \text{Ber}(F_i = \text{反} \mid \theta_i) = \theta_i$$

i.e. $F_i \sim \text{Ber}(\theta_i)$

$F_i \sim Ber(\theta_i)$，即F_i满足伯努利分布（Bernoulli distribution），这是一种离散概率分布，也被称为两点分布或 0-1 分布。

注意索引i，我们试图推理θ_{11}

4.5概率推理&生成式学习算法

概率推理

一个翻转序列的所有随机性都受参数 $\theta_1, \ldots, \theta_{10}$ 的制约：

$$p(\text{正}\ \text{反}\ \text{正}\ \text{正}\ \text{反}\ \text{正}\ \text{正}\ \text{正}\ \text{反}\ \text{正} \mid \theta_1, \theta_2, \ldots, \theta_{10})$$

我们知道 $\theta_1, \ldots, \theta_{10}$，我们能推断出 θ_{11} 吗？

乍一看，这之间没有联系。

找到θ_i使得 $p(\text{正}\ \text{反}\ \text{正}\ \text{正}\ \text{反}\ \text{正}\ \text{正}\ \text{正}\ \text{反}\ \text{正} \mid \theta_1, \theta_2, \ldots, \theta_{10})$ 的值尽可能高，这是一个非常重要的原则：

最大化观察结果的可能性。（ Maximum Likelihood，最大似然）

4.5概率推理&生成式学习算法

概率推理

$$p(\text{正}\ \text{反}\ \text{正}\ \text{正}\ \text{反}\ \text{正}\ \text{正}\ \text{正}\ \text{反}\ \text{正} \mid \theta_1, \theta_2, \ldots, \theta_{10})$$

第一个假设： 抛掷的硬币互不影响——**独立性（independence）**

$$\begin{aligned} & p(\text{正}\ \text{反}\ \text{正}\ \text{正}\ \text{反}\ \text{正}\ \text{正}\ \text{正}\ \text{反}\ \text{正} \mid \theta_1, \theta_2, \ldots, \theta_{10}) \\ = & p_1(F_1 = \text{正} \mid \theta_1) \cdot p_2(F_2 = \text{反} \mid \theta_2) \cdot \ldots \cdot p_{10}(F_{10} = \text{正} \mid \theta_{10}) \\ = & \prod_{i=1}^{10} p_i(F_i = f_i \mid \theta_i) \end{aligned}$$

注意 p_i, θ_i 中的 i ！这表明时间 1 和时间 2 的掷硬币情况不同。。。

硬币不会变。

4.5概率推理&生成式学习算法

概率推理

第二个假设：翻转的性质相同——分布相同（identical distribution）。

$$\prod_{i=1}^{10} p_i(F_i = f_i \mid \theta_i) = \prod_{i=1}^{10} p(F_i = f_i \mid \theta)$$

10 次翻转是独立同分布的（ *independent and identically distributed , (**i.i.d**.)*）

还记得θ_{11} 吗？根据 i.i.d. 假设，我们可以把它与 $\theta_1, \ldots, \theta_{10}$ 联系起来。

现在我们可以写出序列中关于θ 的概率了：

$$\prod_{i=1}^{10} p(F_i = f_i \mid \theta) = (1-\theta)\theta(1-\theta)(1-\theta)\theta(1-\theta)(1-\theta)(1-\theta)\theta(1-\theta)$$

$$= \theta^3(1-\theta)^7$$

4.5概率推理&生成式学习算法

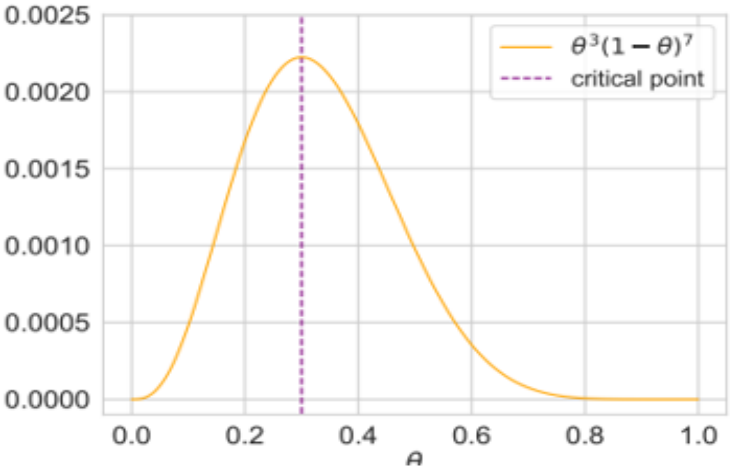
概率推理

根据我们的模型假设（i.i.d.）

$$p(\underbrace{\text{正 反 正 正 反 正 正 正 反 正}}_{\text{observed data, } \mathcal{D}} \mid \theta) = \theta^3(1-\theta)^7$$

还可以解释为函数 $f(\theta) := p(\mathcal{D} \mid \theta)$

我们要找到这个函数的最大值（最大似然值）。



Our goal

$$\theta_{\text{MLE}} = \arg\max_{\theta \in [0,1]} f(\theta)$$

注意：似然函数不是 θ 上的概率分布，因为一般情况下 $\int p(\mathcal{D} \mid \theta) d\theta \neq 1$

4.5概率推理&生成式学习算法

概率推理

Take the derivative $\frac{\mathrm{d}f}{\mathrm{d}\theta}$, set it to 0, and solve for θ.

如何最大化似然函数？

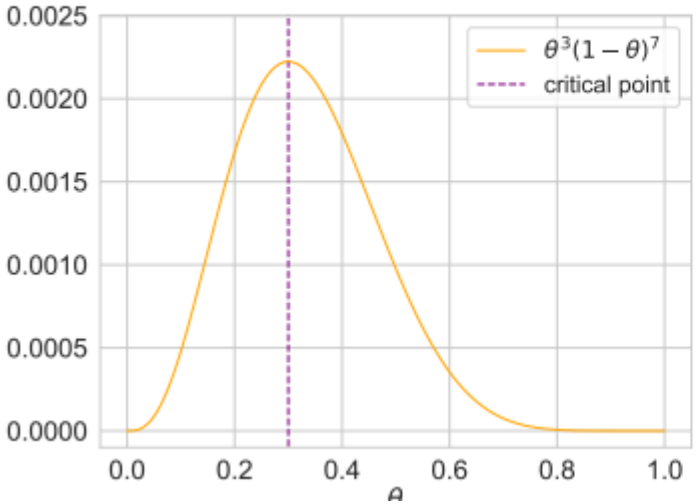
对$\frac{df}{d\theta}$求导，将其值等于0，并求出θ的值。

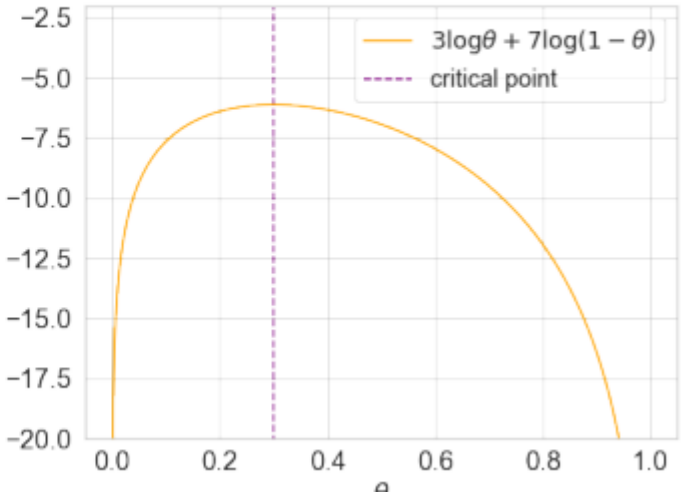
这是可能的，但即使对于简单的 $f\ (\theta)$ 来说，计算结果也很不好。

我们能简化问题吗？

可以！单调函数会保留临界点。

$$\arg\max_{\theta\in[0,1]} f(\theta) = \arg\max_{\theta\in[0,1]} \log f(\theta)$$





4.5概率推理&生成式学习算法

概率推理

任何硬币序列的最大似然估计 (MLE)?

$$\theta_{\mathrm{MLE}} = \frac{|T|}{|T|+|H|}$$

$|T|$, $|H|$ 分别用于用于统计 反 , 正 两种硬币的数量

我们想计算下一次掷硬币是 反 的概率

$$F_{11} \sim \mathrm{Ber}(\theta_{\mathrm{MLE}})$$

$$p(F_{11} = \text{反} \mid \theta_{\mathrm{MLE}}) = \mathrm{Ber}(F_{11} = \text{反} \mid \theta_{\mathrm{MLE}}) = \theta_{\mathrm{MLE}} = \frac{|T|}{|T| + |H|}$$

这就证明 30%是对我们最初问题的合理回答

但是...

4.5概率推理&生成式学习算法

概率统计

仅供娱乐，一个完全不同的序列（同一枚硬币！）：

$$\theta_{\text{MLE}} = 0.$$

正 正

但即使是一枚公平的硬币（$\theta = 0.5$），也有 25% 的几率出现这种结果！

MLE 解决方案似乎与直觉相反。为什么呢？

我们有先验知识：

"硬币通常不会总是正面着地”

我们如何

1. 用数学方法表示这些知识？
2. 将它们纳入我们的模型？

4.5概率推理&生成式学习算法

贝叶斯推理

如何用数学方法表示我们对 θ 的知识?

(主观的) 概率的贝叶斯解释:

分布 $p(\theta)$ 反映了我们对 θ 的主观知识.

先验分布 $p(\theta)$ 表示我们在观察任何数据之前的知识。

我们如何选择 $p(\theta)$? 唯一的约束条件是：

1. 它不能依赖于数据
2. 对于所有 θ，$p(\theta) \geq 0$
3. $\int p(\theta) d\theta = 1$

属性 2 和 3 必须在 θ 的支持值（即可行值）上成立。

在我们的设置中，只有 $\theta \in [0, 1]$ 的值才有意义！

这为（可能是主观的）模型选择留下了空间！

4.5概率推理&生成式学习算法

贝叶斯推理

贝叶斯公式告诉我们，在观察数据 $\mathcal{D}$ 之后，如何更新我们对θ 的知识。

$$p(\theta \mid \mathcal{D}) = \frac{p(\mathcal{D} \mid \theta) \cdot p(\theta)}{p(\mathcal{D})}$$

其中，$p(\theta \mid \mathcal{D})$ 是后验（posterior）分布。它表示我们在观察数据后对 θ 值的看法。

后验分布取决于以下项：

$$\text{posterior} \propto \text{likelihood} \cdot \text{prior}$$

- $p(\mathcal{D} \mid \theta)$ 是似然（likelihood）。
- $p(\theta)$ 是先验（prior），表示我们在观察数据之前的知识（beliefs）。
- $p(\mathcal{D})$ 是证据（evidence），它是一个归一化常数，确保后验分布积分为 1。

通常，我们通过指定似然（likelihood）和先验（prior）来定义模型。

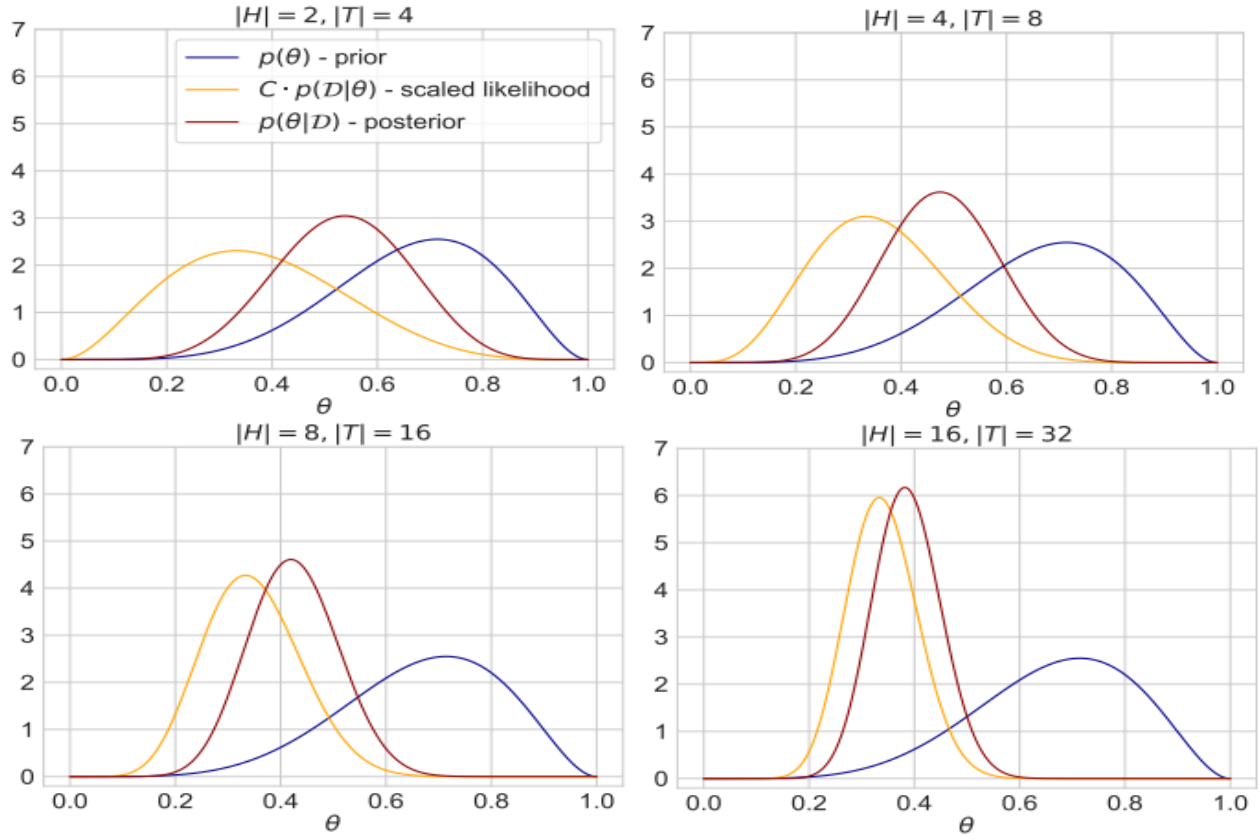
我们可以利用概率总和法则获得证据（evidence）。

$$p(\mathcal{D}) = \int p(\mathcal{D}, \theta)\, \mathrm{d}\theta = \int p(\mathcal{D} \mid \theta) p(\theta)\, \mathrm{d}\theta$$

4.5概率推理&生成式学习算法

贝叶斯推理

观察更多数据可增强我们的信心



为了更直观，图中对likelihood进行了缩放

4.5概率推理&生成式学习算法

最大后验估计

回到我们的硬币问题：如何从数据中估计 θ?

在 MLE（最大似然估计）中，我们问了一个错误的问题。

$$\theta_{\text{MLE}} = \arg\max_{\theta} \; p(\mathcal{D} \mid \theta)$$

MLE 忽视了先验知识（prior beliefs），在可用数据很少的情况下表现很差。

实际上，我们应该关注后验分布 $p(\theta \mid D)$ 。

如果我们最大化后验概率呢？

$$\theta_{\text{MAP}} = \arg\max_{\theta} \; p(\theta \mid \mathcal{D})$$

这种方法称为**最大后验（MAP）估计**。

4.5概率推理&生成式学习算法

最大后验估计

最大后验估计

$$\begin{aligned}\theta_{\mathrm{MAP}} &= \arg\max_{\theta} \; p(\theta \mid \mathcal{D}) \\ &= \arg\max_{\theta} \; \frac{p(\mathcal{D} \mid \theta)p(\theta)}{p(\mathcal{D})} \\ &= \arg\max_{\theta} \; p(\mathcal{D} \mid \theta)p(\theta)\end{aligned}$$

我们可以忽略 $\frac{1}{p(\mathcal{D})}$，因为它是一个与 θ 无关的（正）常数。

我们已经知道了之前的似然 $p(\mathcal{D} \mid \theta)$，那么如何选择先验 $p(\theta)$ 呢？

4.5概率推理&生成式学习算法

最大后验估计

通常，我们选择先验值是为了简化后续计算。

我们选择Beta分布，原因稍后会讲清楚。

$$\mathrm{Beta}(\theta \mid a, b) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)}\theta^{a-1}(1-\theta)^{b-1}, \quad \theta \in [0,1]$$

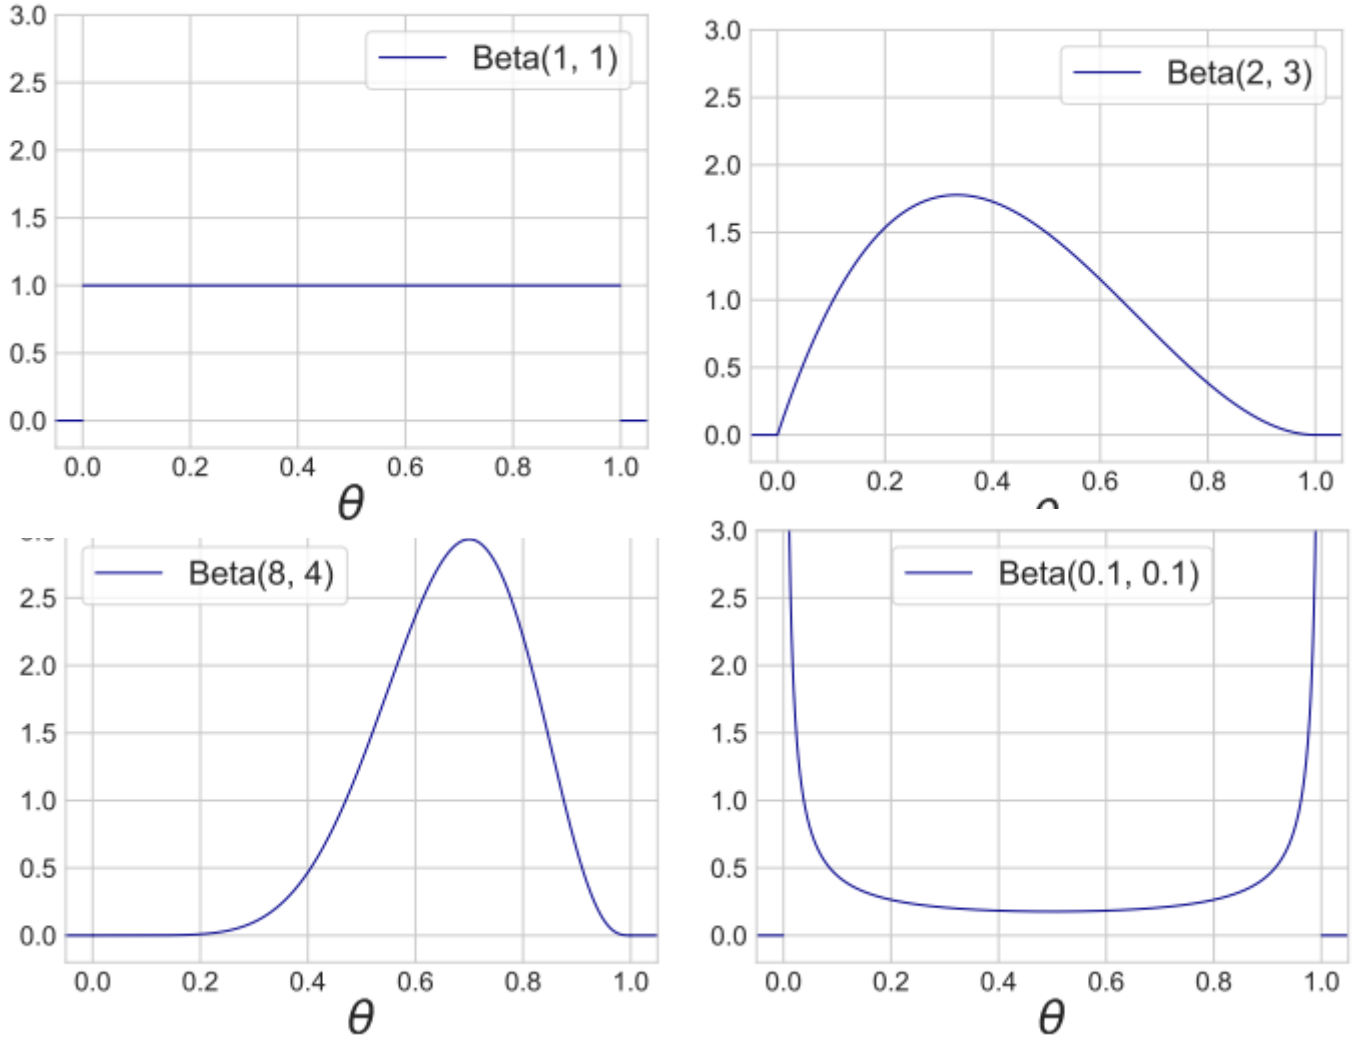
其中

- $a > 0, b > 0$ 为分布参数
- 对于$n \in \mathbb{N} \quad \Gamma(n) = (n-1)!$ 是gamma函数

4.5概率推理&生成式学习算法

最大后验估计

不同 a 和 b 选择下的 Beta PDF：



4.5概率推理&生成式学习算法

最大后验估计

让我们把所有东西放在一起：

$$p(\theta \mid \mathcal{D}) = \frac{p(\mathcal{D} \mid \theta) \cdot p(\theta)}{p(\mathcal{D})} \qquad p(\mathcal{D}) \text{ is constant w.r.t. } \theta.$$
$$\propto p(\mathcal{D} \mid \theta) \cdot p(\theta)$$

已知：

$$p(\mathcal{D} \mid \theta) = \theta^{|T|}(1-\theta)^{|H|},$$
$$p(\theta) \equiv p(\theta \mid a, b) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)}\theta^{a-1}(1-\theta)^{b-1}.$$

所以可以得到：

$$p(\theta \mid \mathcal{D}) \propto \theta^{|T|}(1-\theta)^{|H|} \cdot \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)}\theta^{a-1}(1-\theta)^{b-1}$$
$$\propto \theta^{|T|+a-1}(1-\theta)^{|H|+b-1}.$$

4.5概率推理&生成式学习算法

最大后验估计

我们正在寻找

$$\begin{aligned}\theta_{\mathrm{MAP}} &= \arg\max_{\theta} p(\theta \mid \mathcal{D}) \\ &= \arg\max_{\theta} \ \theta^{|T|+a-1}(1-\theta)^{|H|+b-1}\end{aligned}$$

和以前一样，如果我们考虑对数，问题就变得简单多了。

$$\begin{aligned}\theta_{\mathrm{MAP}} &= \arg\max_{\theta} \ \log p(\theta \mid \mathcal{D}) \\ &= \arg\max_{\theta} \ (|T|+a-1)\log\theta + (|H|+b-1)\log(1-\theta)\end{aligned}$$

通过一些代数，我们可以得到

$$\theta_{\mathrm{MAP}} = \frac{|T|+a-1}{|H|+|T|+a+b-2}$$

4.5概率推理&生成式学习算法

概率推理-小结

- 最大似然（Maximum likelihood）
- 最大后验（Maximum a posteriori）
- 完全贝叶斯分析（Fully Bayesian analysis）
- 先验、后验、似然比（Prior, Posterior, Likelihood）
- i.i.d. 假设（The i.i.d. assumption）
- 共轭先验（Conjugate prior）

接下来，回到生成式学习算法

4.5概率推理&生成式学习算法

生成式学习算法

解决方案：给定数据 x，建立类别标签 y 的分布模型。

$$p(y=c|\boldsymbol{x})=\frac{P(\boldsymbol{x}|y=c)*P(y=c)}{p(\boldsymbol{x})}$$

两种模型:

生成式

- 模型联合分布$p(x,y=c)=p(x|y=c)*p(y=c)$

判别式

- 直接建模分布 $p(y=c|\boldsymbol{x})$

给定 p($y\,|\,x$) 我们就可以根据问题预测 $\hat{y}$ 。

一般的模型选择:$\hat{y}=argmax_{c\in C}P(y=c|x)$.

4.5概率推理&生成式学习算法

生成式模型

利用贝叶斯定理获得类别后验

$$\mathrm{p}(y=c \mid \boldsymbol{x}) \propto \underbrace{\mathrm{p}(\boldsymbol{x} \mid y=c)}_{\text{类别条件}} \cdot \underbrace{\mathrm{p}(y=c)}_{\text{类别先验}}$$

该模型包括

- 类别先验：某点属于某个类别 c 的先验概率
- 类别条件：生成一个点 $\boldsymbol{x}$ 的概率，且该点属于 c 类

4.5概率推理&生成式学习算法

生成式模型

生成式模型的典型工作原理如下：

- 为类别条件 $\mathrm{p}(\boldsymbol{x} \mid y=c, \boldsymbol{\psi})$和类别先验 $\mathrm{p}(y=c \mid \boldsymbol{\theta})$选择一个参数模型。
- 根据数据D估算模型 $\{\boldsymbol{\psi}, \boldsymbol{\theta}\}$
  (例如，使用最大似然法获得估计值 $\{\hat{\boldsymbol{\psi}}, \hat{\boldsymbol{\theta}}\}$)。
  这一步被称为学习。

拟合后，我们就可以进行推理：利用贝叶斯规则对新的 $\boldsymbol{x}$ 进行分类

$$\mathrm{p}(y=c \mid \boldsymbol{x}, \hat{\boldsymbol{\psi}}, \hat{\boldsymbol{\theta}}) \propto \mathrm{p}(\boldsymbol{x} \mid y=c, \hat{\boldsymbol{\psi}}) \mathrm{p}(y=c \mid \hat{\boldsymbol{\theta}}) \tag{2}$$

此外，我们还可以生成新的数据——这也是该名称（生成式）的由来。

- 采样类标签 $y_{new} \sim \mathrm{p}(y \mid \hat{\boldsymbol{\theta}})$
- 采样特征向量 $\boldsymbol{x}_{new} \sim \mathrm{p}(\boldsymbol{x} \mid y=y_{new}, \hat{\boldsymbol{\psi}})$

4.5概率推理&生成式学习算法

生成式模型

我们如何选择类别先验 p($y = c$)?

标签 y 可以取 C 个离散值中的一个

⇒ 使用分类分布！

$$y \sim \text{Categorical}(\boldsymbol{\theta})$$

参数 $\boldsymbol{\theta} \in \mathrm{R}^C$ 规定了每个类别的概率

$$\mathrm{p}(y=c) = \theta_c \text{ 或等同于 } \mathrm{p}(y) = \prod_{c=1}^{C} \theta_c^{\mathbb{I}(y=c)}$$

其中，$0 \leq \theta_c \leq 1$ 并且 $\sum_{c=1}^{C} \theta_c = 1.$

给定数据 $D = \{(\boldsymbol{x}_i, y_i)\}$ 时，$\boldsymbol{\theta}$ 的最大似然估计值为：

$$\theta_c^{MLE} = \frac{1}{N} \sum_{i=1}^{N} \mathbb{I}(y_i = c)$$

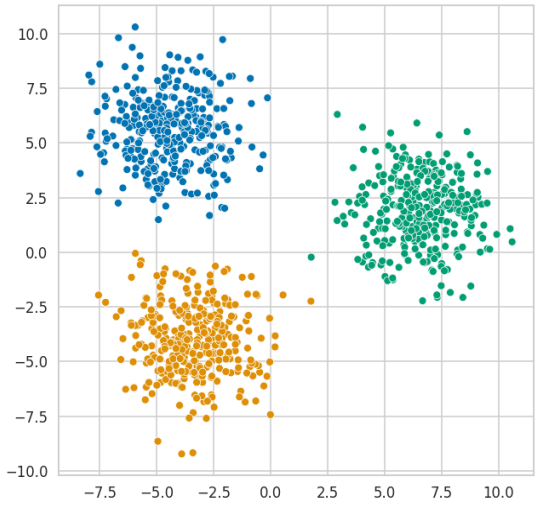
4.5概率推理&生成式学习算法

生成式模型

我们如何选择类条件式 $p(x \mid y = c)$?

特征向量 $x \in R^D$ 是连续的。

$\Rightarrow$ 对每个类别使用多元正态!



$$p(\boldsymbol{x} \mid y = c) = \mathcal{N}(\boldsymbol{x} \mid \boldsymbol{\mu}_c, \boldsymbol{\Sigma})$$
$$= \frac{1}{(2\pi)^{D/2}|\boldsymbol{\Sigma}|^{1/2}} \exp\left\{-\frac{1}{2}(\boldsymbol{x} - \boldsymbol{\mu}_c)^T \boldsymbol{\Sigma}^{-1}(\boldsymbol{x} - \boldsymbol{\mu}_c)\right\}$$

我们对每个类别使用相同的 $\boldsymbol{\Sigma}$，因为估算所有 $\boldsymbol{\Sigma}_c$ 在数值上表现不佳，除非我们有大量数据。

我们如何估计模型参数？
最大似然估计（MLE）

4.5概率推理&生成式学习算法

高斯判别分析

多变量正态分布:

$$p(x;\mu,\Sigma) = \frac{1}{(2\pi)^{n/2}|\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x-\mu)^T\Sigma^{-1}(x-\mu)\right).$$

均值向量 $\mu \in \mathbb{R}^n$

协方差矩阵 $\Sigma \in \mathbb{R}^{n\times n}$

对于服从 N(μ,Σ) 分布的随机变量 X，均值（不出所料）由 μ 给出：

$$\mathrm{E}[X] = \int_x x\, p(x;\mu,\Sigma)dx = \mu$$

4.5概率推理&生成式学习算法

高斯判别分析

向量随机变量 Z 的协方差定义为：

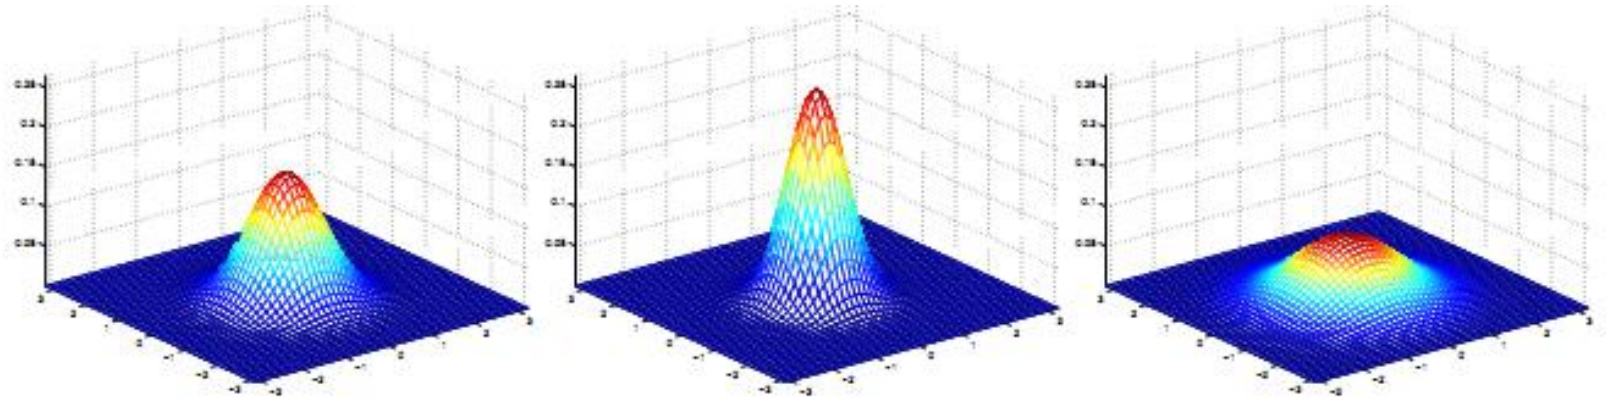
$$\begin{aligned}\mathrm{Cov}(Z) &= \mathrm{E}[(Z - \mathrm{E}[Z])(Z - \mathrm{E}[Z])^T] \\ &= \mathrm{E}[ZZ^T] - (\mathrm{E}[Z])(\mathrm{E}[Z])^T\end{aligned}$$

If $X \sim \mathcal{N}(\mu, \Sigma)$, then

$$\mathrm{Cov}(X) = \Sigma.$$

4.5概率推理&生成式学习算法

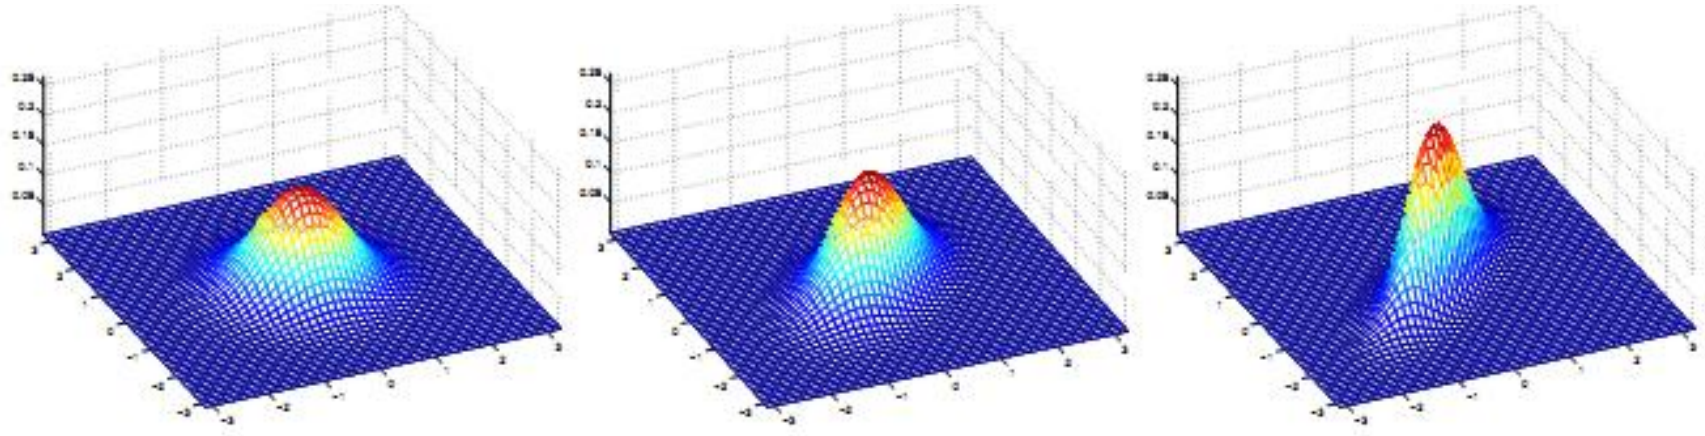
高斯判别分析



最左边的图显示了一个均值为零（即2x1的零向量）且协方差矩阵为Σ=*I*（2x2的单位矩阵）的高斯分布。均值为零且协方差为单位矩阵的高斯分布也称为**标准正态分布**。中间的图显示了一个均值为零且 Σ=0.6*I* 的高斯分布的密度；最右边的图显示了一个均值为零且 Σ=2*I* 的高斯分布。我们可以看到，随着 Σ 变大，高斯分布变得更加“分散”，而随着 Σ 变小，分布变得更加“压缩”。

4.5概率推理&生成式学习算法

高斯判别分析



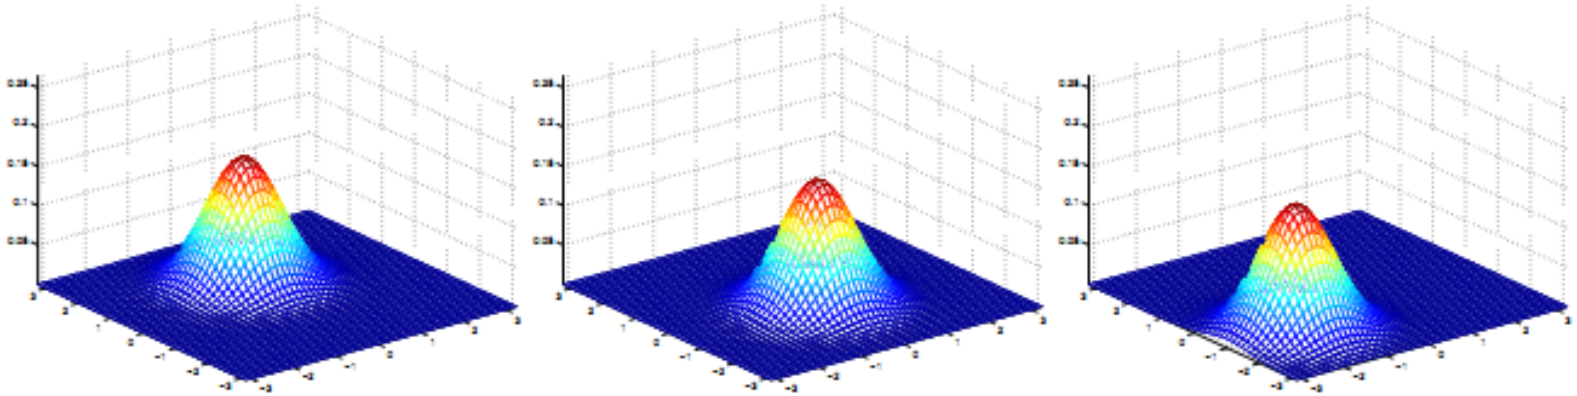
上图显示了均值为0的高斯分布，其协方差矩阵分别为：

$$\Sigma = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}; \quad \Sigma = \begin{bmatrix} 1 & 0.5 \\ 0.5 & 1 \end{bmatrix}; \quad .\Sigma = \begin{bmatrix} 1 & 0.8 \\ 0.8 & 1 \end{bmatrix}.$$

4.5概率推理&生成式学习算法

高斯判别分析

作为最后一组示例，固定 $\Sigma = I$，通过改变 μ，我们也可以移动密度的均值。



上图是使用 $\Sigma = I$ 生成的，分别对应于：

$$\mu = \begin{bmatrix} 1 \\ 0 \end{bmatrix}; \quad \mu = \begin{bmatrix} -0.5 \\ 0 \end{bmatrix}; \quad \mu = \begin{bmatrix} -1 \\ -1.5 \end{bmatrix}.$$

4.5概率推理&生成式学习算法

高斯判别分析

模型:

当我们遇到输入特征 x 为连续值随机变量的分类问题时，我们可以使用高斯判别分析 (Gaussian Discriminant Analysis, GDA) 模型，该模型使用多元正态分布对 $p(x|y)$ 进行建模。

该模型为：

$$\begin{aligned} y &\sim \text{Bernoulli}(\phi) \\ x|y=0 &\sim \mathcal{N}(\mu_0, \Sigma) \\ x|y=1 &\sim \mathcal{N}(\mu_1, \Sigma) \end{aligned}$$

4.5概率推理&生成式学习算法

高斯判别分析

分布如下：

$$
\begin{aligned}
p(y) &= \phi^y(1-\phi)^{1-y} \\
p(x|y=0) &= \frac{1}{(2\pi)^{n/2}|\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x-\mu_0)^T\Sigma^{-1}(x-\mu_0)\right) \\
p(x|y=1) &= \frac{1}{(2\pi)^{n/2}|\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x-\mu_1)^T\Sigma^{-1}(x-\mu_1)\right)
\end{aligned}
$$

4.5概率推理&生成式学习算法

高斯判别分析

模型的参数是 ϕ 、Σ、 μ_0、 μ_1（注意，虽然有两个不同的均值向量 μ_0 和 μ_1 ，但该模型通常只使用一个协方差矩阵 Σ。）

数据的对数似然（log-likelihood）为：

$$\begin{aligned}\ell(\phi, \mu_0, \mu_1, \Sigma) &= \log \prod_{i=1}^{m} p(x^{(i)}, y^{(i)}; \phi, \mu_0, \mu_1, \Sigma) \\ &= \log \prod_{i=1}^{m} p(x^{(i)} | y^{(i)}; \mu_0, \mu_1, \Sigma) p(y^{(i)}; \phi).\end{aligned}$$

4.5概率推理&生成式学习算法

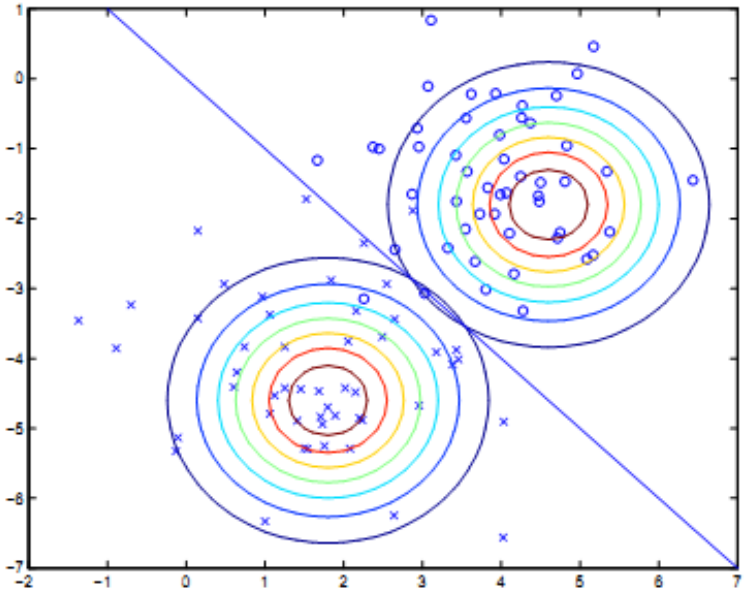
高斯判别分析

通过最大化与参数相关的 ℓ，我们可以找到参数的最大似然估计值：

$$
\begin{aligned}
\phi &= \frac{1}{m}\sum_{i=1}^{m} 1\{y^{(i)}=1\} \\
\mu_0 &= \frac{\sum_{i=1}^{m} 1\{y^{(i)}=0\}x^{(i)}}{\sum_{i=1}^{m} 1\{y^{(i)}=0\}} \\
\mu_1 &= \frac{\sum_{i=1}^{m} 1\{y^{(i)}=1\}x^{(i)}}{\sum_{i=1}^{m} 1\{y^{(i)}=1\}} \\
\Sigma &= \frac{1}{m}\sum_{i=1}^{m} (x^{(i)}-\mu_{y^{(i)}})(x^{(i)}-\mu_{y^{(i)}})^T.
\end{aligned}
$$

4.4 分类器、判别函数及决策面

高斯判别分析



分布如下：

$$
\begin{aligned}
p(y) &= \phi^{y}(1-\phi)^{1-y} \\
p(x|y=0) &= \frac{1}{(2\pi)^{n/2}|\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x-\mu_0)^{T}\Sigma^{-1}(x-\mu_0)\right) \\
p(x|y=1) &= \frac{1}{(2\pi)^{n/2}|\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x-\mu_1)^{T}\Sigma^{-1}(x-\mu_1)\right)
\end{aligned}
$$

答疑

1. 全概率是不是为1?

1.设某工厂有两个车间生产同型号家用电器，第一车间的次品率为 0.15，第二车间的次品率为 0.12，两个车间的成品都混合堆放在一个仓库，假设第 1,2 车间生产的成品比例为 2:3，今有一客户从成品仓库中随机提一台产品，求该产品合格的概率。

解：设 B={从仓库中随机提出的一台是合格品}

A_i={提出的一台是第 i 车间生产的}，i=1,2

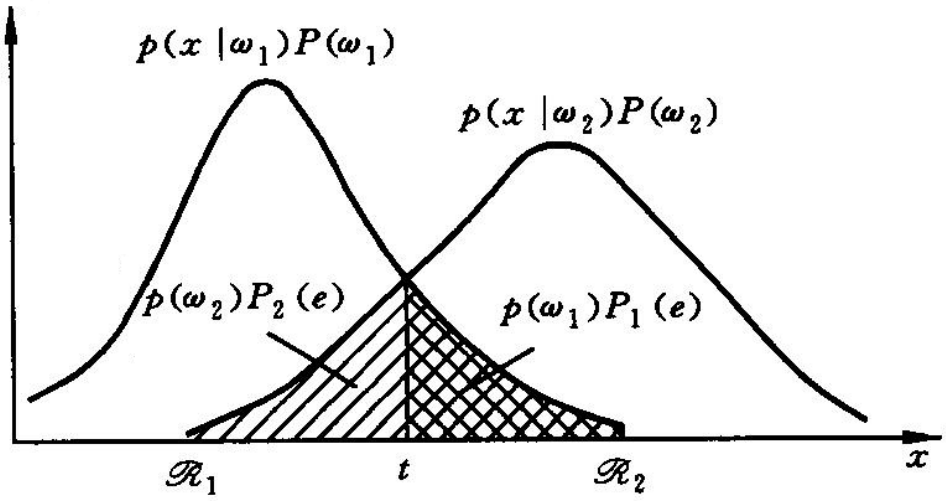
则有分解 $B=A_1B \cup A_2B$

由题意 P(A1)=2/5,P(A2)=3/5,P(B|A1)=0.85,P(B|A2)=0.88

由全概率公式 $P(B)= P(A_1)\ P(B|A_1)+ P(A_2)\ P(B|A_2)=0.4*0.85+0.6*0.88=0.868.$

答疑

2. 错误率图示及含义?



End

