模式识别-复习课
Pattern Recognition

2025.6

概　念

- **模式识别**：确定一个样本的类别属性（模式类）的过程，即把某一样本归属于多个类型中的某个类型。**模式分类的过程**。
- **样本**（Sample)：一个具体的研究（客观）对象。如患者，某人写的一个汉字，一幅图片等。
- **模式**（Pattern）：对客体（研究对象）特征的描述（定量的或结构的描述），是取自客观世界的某一样本的测量值的集合（或综合）。
- **特征**（Features）：能描述模式特性的量（测量值）。
  在统计模式识别方法中，通常用一个矢量表示，称之为特征矢量，记为 $\vec{x} = (x_1, x_2, \cdots, x_n)'$
- **模式类**（Class）：具有某些共同特性的模式的集合。

概　念

- **已知样本（known sample）**：事先知道类别标号的样本（训练样本）。
- **未知样本（unknown sample）**：类别标号未知但特征已知的样本（待识别样本，测试样本）。
- **模式识别过程**：模式空间→特征空间→类型空间
- **模式空间**：在模式空间里，每个样本模式都是一个点的位置由该模式在各维上的测量值确定。
- **特征空间**：对模式空间里的各坐标元素进行综合分析，以提取最能揭示样本属性的特征，这些特征就构成特征空间。
- **类型空间**：根据适当的判决规则，把特征空间里的样本区分成不同的类型，从而把特征空间塑造成了类型空间。

概　念

- **分类器的学习和适应：给定一般模型或分类器的形式，利用样本(例子)去学习或估计模型的未知参数。**
  - **有监督学习(Supervised learning)：已知训练样本集中每个输入样本的类别标记和分类代价，寻找能降低总体代价的方向。已知分类情况，计算各类在特征空间的分布，然后对未知样本进行分类.**
  - **无监督学习(Unsupervised learning)：样本的类别标记和分类代价未知，由聚类器形成聚类(clusters)或者“自然组织(natural groupings)”。事先不知有多少类，有哪些类，只能根据样本间的相似性进行聚合。**

模式识别系统

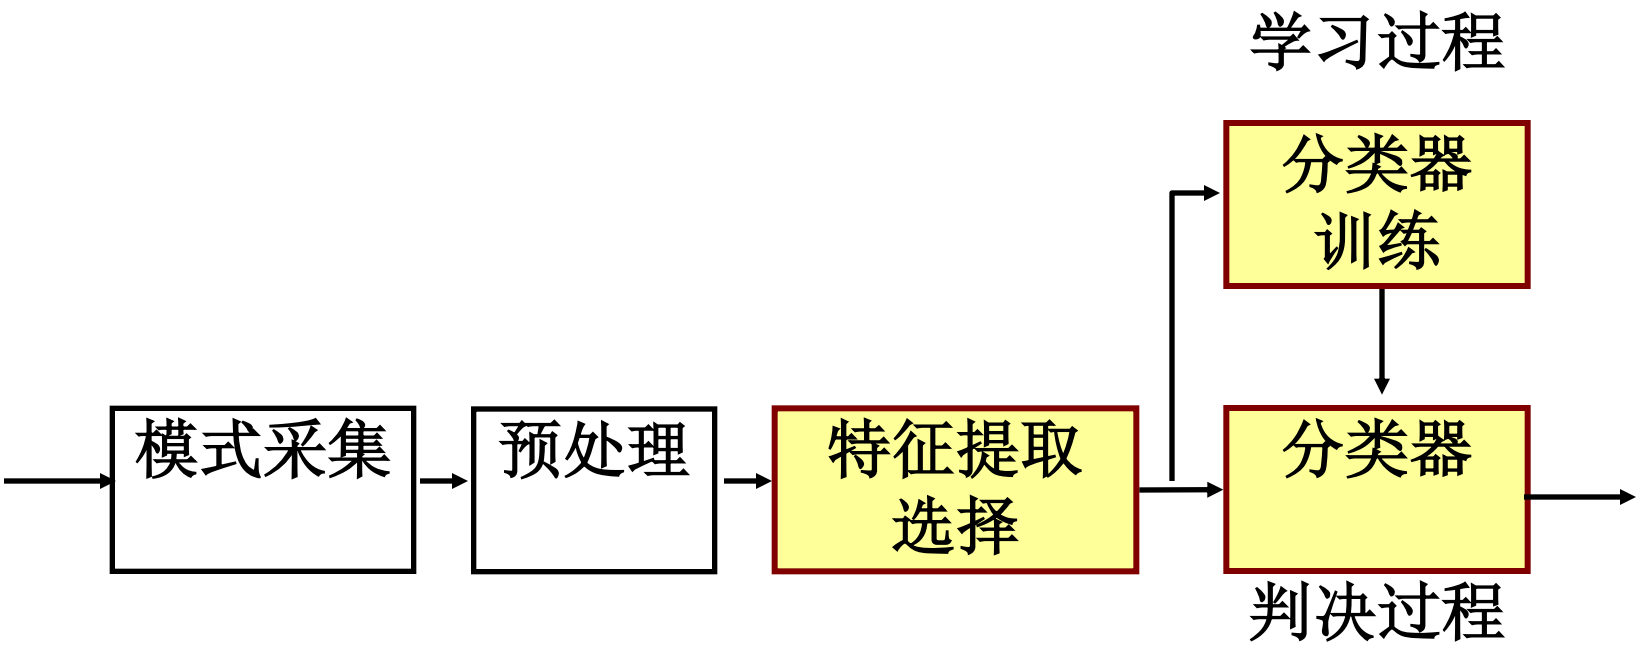


图1 模式识别系统框图

统计判决

- 理论基础：概率论，数理统计
- 模式描述方法：特征向量 $\vec{x} = (x_1, x_2, \cdots, x_n)'$
- 模式判定
  是一个聚合类。用条件概率分布 $p(\vec{x}|\omega_i)$ 表示,m类就有m个分布，然后判定未知模式属于哪一个分布。
- 主要方法
  几何分类：线性分类，非线性分类
  统计分类：Bayes决策
  无教师的分类：聚类分析
- 主要优点
  1）比较成熟
  2）能考虑干扰噪声等影响
  3）识别模式基元能力强
- 主要缺点
  1）对结构复杂的模式抽取特征困难
  2）不能反映模式的结构特征，难以描述模式的性质
  3）难以从整体角度考虑识别问题

聚类分析 总结

- 内容：
  - 聚类的基本概念；
  - 相似性测度、类间距离 、聚类准则；
  - 简单聚类、层次聚类 ；
  - 动态聚类。
- 要求：

  重点:相似性测度、C均值聚类和层次聚类算法。

  难点:聚类准则函数。

聚类分析 总结

方法：根据待分类的模式属性或特征相似程度进行分类，相似的模式归为一类，不相似的模式分划到不同类中。

聚类分析 总结

一、影响分类的因数

（1）分类准则；（2）特征量的选择；（3）量纲。

二、模式相似性测度

（一） 距 离 测 度

(1) 欧氏距离

(2) 马氏距离 $d^2(\vec{x}_i,\vec{x}_j)=(\vec{x}_i-\vec{x}_j)'V^{-1}(\vec{x}_i-\vec{x}_j)$

对坐标系平移、旋转、比例不变（非奇异线性变换不变）。

（二） 相 似 测 度

相关系数 （特征矢量的方向） $r(\vec{x},\vec{y})=\dfrac{(\vec{x}-\bar{\vec{x}})'(\vec{y}-\bar{\vec{y}})}{[(\vec{x}-\bar{\vec{x}})'(\vec{x}-\bar{\vec{x}})(\vec{y}-\bar{\vec{y}})'(\vec{y}-\bar{\vec{y}})]^{1/2}}$

对坐标系平移、旋转、比例不变。

（三） 匹 配 测 度

(0-1) 匹配系数

聚类算法

（一）简单聚类

①最邻近规则试探法

给定阀值T，聚类到z_j

②最大最小距离法

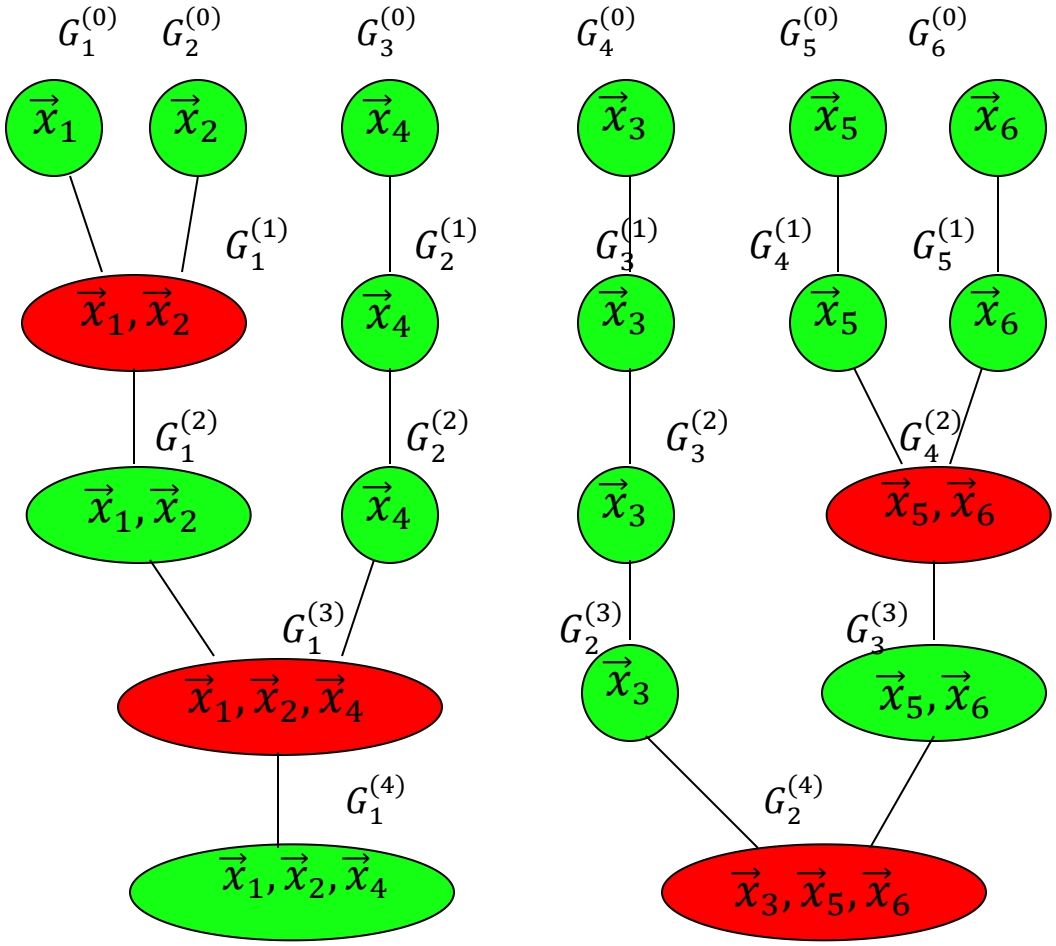
给定$0<\theta<1$，距当前类心最大者为新的聚类中心，按最小距离原则聚类。

（二）层次聚类

初始每个样本点为一类（N类），将类间距离最小者合并为一类，逐级进行。

类间距离可用：最小、最大、中间、重心、平均距离等。

层次聚类示意图



停止条件： 类间距离>门限T 或/和 **类别数目**=C

（三）动态聚类算法

- **C-均值算法（适用于团状分布的情况）**

$$\forall c > 0,\ \ \vec{z}_i(1) = \vec{x}_{i_1},\ i = 1, 2, \ldots, c;$$

$$\vec{z}_j(k) = \frac{1}{N_j}\sum_{i=1}^{N_j}\vec{x}_i^{(j)}\ ,\ \ \mathrm{N} = \sum_{\mathrm{j}=1}^{\mathrm{c}}\mathrm{N_j}\ ,\ \ \vec{x}_i^{(j)} \in \omega_{\mathrm{j}}$$

重新聚类

- **ISODATA算法**

c（预期类数），N_c（初始类心个数），θ_N（各类最小样本数），

θ_s（类中样本特征分量标准差上限），$\varepsilon\sigma_{jmax}$，

θ_D（聚合中心最小间距），L，I

C-均值算法步骤

(1) 任选个模式特征矢量作为初始聚类中心,令k=0:

$$\vec{z}_1^{(0)}, \vec{z}_2^{(0)}, \cdots, \vec{z}_c^{(0)}$$

(2) 将待分类的模式特征矢量集中的模式逐个按最小距离原则分划给类中的某一类，即

IF $d_{il}^{(k)} = \min_j[d_{ij}^{(k)}]$, $i = 1, 2, \cdots, c$. $d_{ij}^{(k)} = (\vec{x}_i - \vec{z}_j^{(k)})'(\vec{x}_i - \vec{z}_j^{(k)})$

then $\vec{x}_i \in \omega_l^{(k+1)}$

得到新的类： $\omega_j^{(k+1)}, j = 1, 2, \cdots, c$

(3) 计算重新分类后的各类心

$$\vec{z}_j^{(k+1)} = \frac{1}{n_j^{(k+1)}} \sum_{\vec{x}_i \in \omega_j^{(k+1)}} \vec{x}_i \quad , \quad j = 1, 2, \cdots, c$$

(4) IF $(\vec{z}_j^{(k+1)} = \vec{z}_j^{(k)}, j = 1, 2, \cdots, c)$

then End

else $k = k + 1$; goto (2);

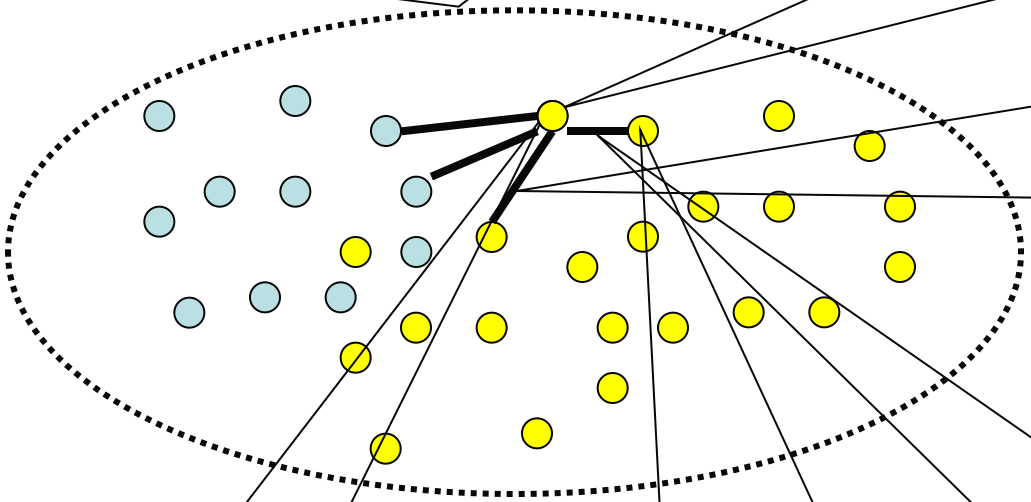
C-均值算法性能

- 算法简单，收敛。如模式呈现类内团状分布，效果很好，故应用较多。
- 能使各模式到其所判属类别中心距离平方之和为最小。
- 以确定的类数*c*、模式输入次序、及选定的初始聚类中心为前提，受此限制结果只是局部最优。

最近邻方法　　2.6.1 最近邻决策规则—1-NN

(1) 已知N个已知类别样本X

(2) 输入未知类别样本x



(3) 计算x到 $x_i \in X$, $(i=1,2,\ldots,N)$ 的距离 $d_i(x)$

(4) 找出最小距离 $d_m(x)=\min\{d_i(x)\}$

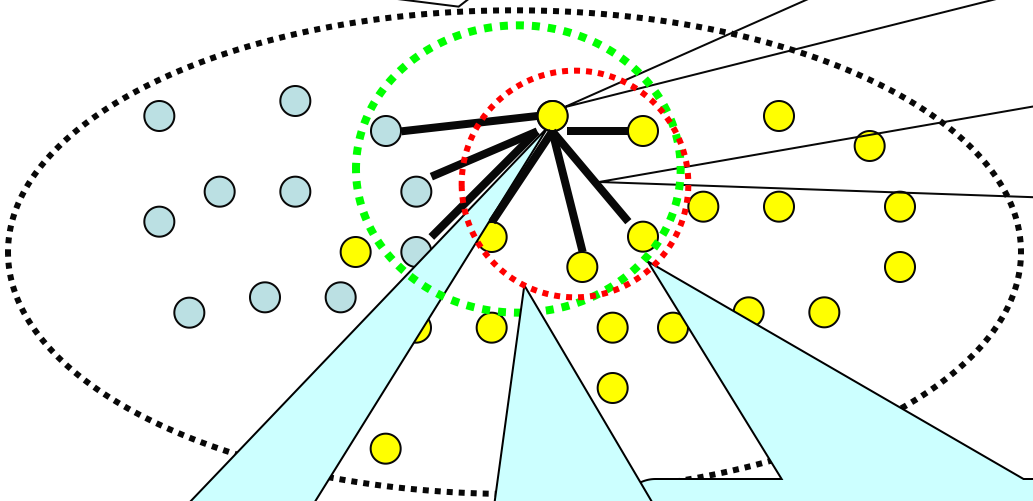
(5) 看x_m属于哪一类：$x_m \in \omega_2$

(6) 判 $x \in \omega_2$

最近邻方法　　2.6.1 最近邻决策规则—k-NN

(1) 已知N个已知类别样本X

(2) 输入未知类别样本x



(3) 计算x到 $x_i \in X$, $(i=1, 2, \ldots, N)$ 的距离 $d_i(x)$

(4) 找出x的k个最近邻元 $X_k=\{x_i, i=1, 2, \ldots, k\}$

(5) 看 X_k 中属于哪一类的样本最多 $k_1=3<k_2=4$

(6) 判 $x \in \omega_2$

2.6.2 剪辑最近邻方法

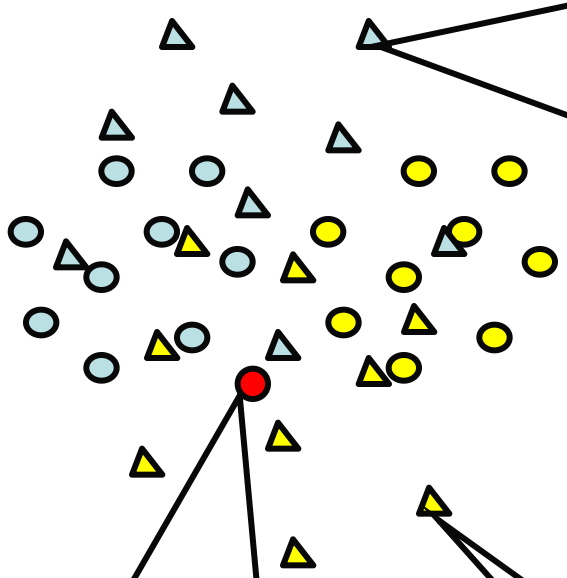
剪辑1-NN最近邻方法

□ $\in \omega_1$

■ $\in \omega_2$

○ $\in X^{(NR)}$

△ $\in X^{(NT)}$



用$X^{(NR)}$中的样本采用最近邻规则对$X^{(NT)}$中的每个样本分类，剪辑掉$X^{(NT)}$中被错误分类的样本。

用$X^{(NTE)}$ 对输入的未知样本做1-NN分类。

余下判决正确的样本组成剪辑样本集$X^{(NTE)}$ 。

1-NN

判决函数　$d_i(\vec{x}) = \underbrace{\min}_{j=1,2,\cdots,N_i} \left\| \vec{x} - \vec{x}_j^{(i)} \right\|$　$i = 1, 2, \cdots, c$

判决规则：如果　$d_m(\vec{x}) = \underbrace{\min}_{i=1,2,\cdots,c} d_i(\vec{x})$　**则**　$\vec{x} \in \omega_m$

k-NN

判决函数　$d_i(\vec{x}) = k_i$

判决规则：如果　$d_m(\vec{x}) = \underbrace{\max}_{i=1,2,\cdots,c} d_i(\vec{x})$　**则**　$\vec{x} \in \omega_m$

第三章 类域界面方程法 总结

分类⇒特征空间的分划⇒子空间的界面：判别函数

$d(\vec{x}) = 0$　　$d(\vec{x}) = \vec{w}'\vec{x}$

求解 $\vec{w} = (w_1, w_2, \cdots, w_n, w_{n+1})'$

线性判别函数

$$d(\vec{x}) = w_1x_1 + w_2x_2 + \cdots + w_nx_n + w_{n+1} \triangleq \vec{w}_0'\vec{x} + w_{n+1}$$

式中$\vec{w}_0 = (w_1, w_2, \cdots, w_n)'$**,称为权矢量或系数矢量。写成矢量形式** $d(\vec{x}) \triangleq \vec{w}'\vec{x}$ **这里,** $\vec{x} = (x_1, x_2, \cdots, x_n, 1)'$ **,** $\vec{w} = (w_1, w_2, \cdots, w_n, w_{n+1})'$ **称为增广特征矢量和增广权矢量。增广特征矢量的全体称为增广特征空间。**

判别规则： $d(\vec{x}) = \vec{w}'\vec{x}\begin{cases} > 0 \Rightarrow \vec{x} \in \omega_1 \\ < 0 \Rightarrow \vec{x} \in \omega_2 \\ = 0 \Rightarrow \vec{x} \in \omega_i \text{或拒判} \end{cases}$

解多类问题的两分法:

(1) $\frac{\omega_i}{\bar{\omega}_i}$ 两分法

有不确定区域

$$if \begin{cases} d_i(\vec{x}) > 0 \\ d_j(\vec{x}) \le 0, \quad \forall j \ne i \end{cases} then \quad \vec{x} \in \omega_i$$

(2) $\frac{\omega_i}{\omega_j}$ 两分法

$$if\ d_{ij}(\vec{x}) > 0, \forall j \ne i, \ then\ \vec{x} \in \omega_i$$

(3) 没有不确定区的 $\frac{\omega_i}{\omega_j}$ 两分法

令 $d_{ij}(\vec{x}) = d_i(\vec{x}) - d_j(\vec{x}) = (\vec{w}_i - \vec{w}_j)'\vec{x}$

$$if \quad d_i(\vec{x}) > d_j(\vec{x}), \forall j \ne i \quad then\ \vec{x} \in \omega_i$$

$$or$$

$$if \quad d_i(\vec{x}) = \max_j[d_j(\vec{x})] \quad then\ \vec{x} \in \omega_i$$

判别函数值的鉴别意义、权空间及解空间

(1) 系数矢量 $\vec{w}_0$ 是超平面 $d(\vec{x}) = 0$ 的法矢量；

(2) $d(\vec{x})$ 的绝对值 $|d(\vec{x})|$ 正比于 $\vec{x}$ 到超平面的距离；

(3) $d(\vec{x})$ 的正（负）反映 $\vec{x}$ 在超平面 $d(\vec{x}) = 0$ 的正（负）侧。

统计判决 总结

概念:

后验概率: $P(\omega_i|\vec{x})$

类概密: $p(\vec{x}|\omega_i)$

先验概率: $P(\omega_i)$

条件期望: $E_i[g(\vec{x})] = \int_{X^n} g(\vec{x})\, p(\vec{x}|\omega_i)\, d\vec{x}$

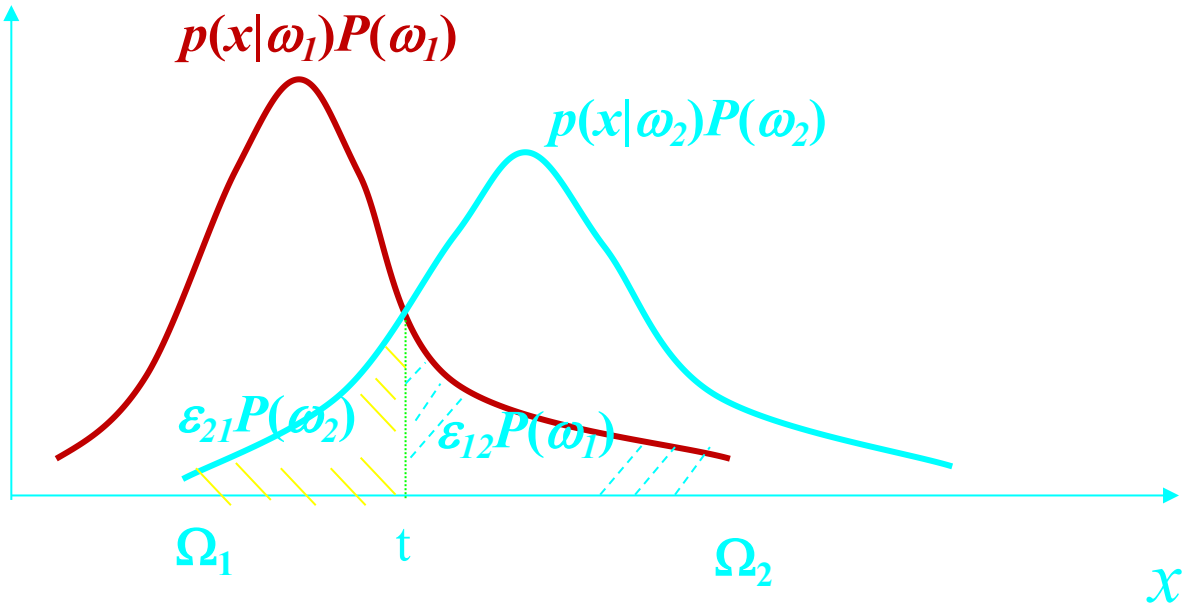
最小误判概率准则判决

总的误判概率

$$\varepsilon_{12} = \int_{\Omega_2} p(\vec{x}|\omega_1)d\vec{x} \qquad \varepsilon_{21} = \int_{\Omega_1} p(\vec{x}|\omega_2)d\vec{x}$$

$$P(e) = P(\omega_1)\varepsilon_{12} + P(\omega_2)\varepsilon_{21}$$

$$= P(\omega_1)\int_{\Omega_2} p(\vec{x}|\omega_1)d\vec{x} + P(\omega_2)\int_{\Omega_1} p(\vec{x}|\omega_2)d\vec{x}$$



多类问题，最小误判概率准则有如下几种等价的判决规则

(1) if $P(\omega_i|\vec{x}) > P(\omega_j|\vec{x}), \forall j \neq i$ then $\vec{x} \in \omega_i$

if $P(\omega_i|\vec{x}) = \max_j[P(\omega_j|\vec{x})]$ then $\vec{x} \in \omega_i$

(2) if $p(\vec{x}|\omega_i)P(\omega_i) > p(\vec{x}|\omega_j)P(\omega_j), \forall j \neq i$ then $\vec{x} \in \omega_i$

if $p(\vec{x}|\omega_i)P(\omega_i) = \max_j[p(\vec{x}|\omega_j)P(\omega_j)]$ then $\vec{x} \in \omega_i$

(3) if $l_{ij}(\vec{x}) = \dfrac{p(\vec{x}|\omega_i)}{p(\vec{x}|\omega_j)} > \dfrac{P(\omega_j)}{P(\omega_i)} = \theta_{ij}, \forall j \neq i$ then $\vec{x} \in \omega_i$

(4) if $\ln p(\vec{x}|\omega_i) + \ln P(\omega_i) > \ln p(\vec{x}|\omega_j) + \ln P(\omega_j), \forall j \neq i$ then $\vec{x} \in \omega_i$

正态模式分类的误判概率

对数似然比

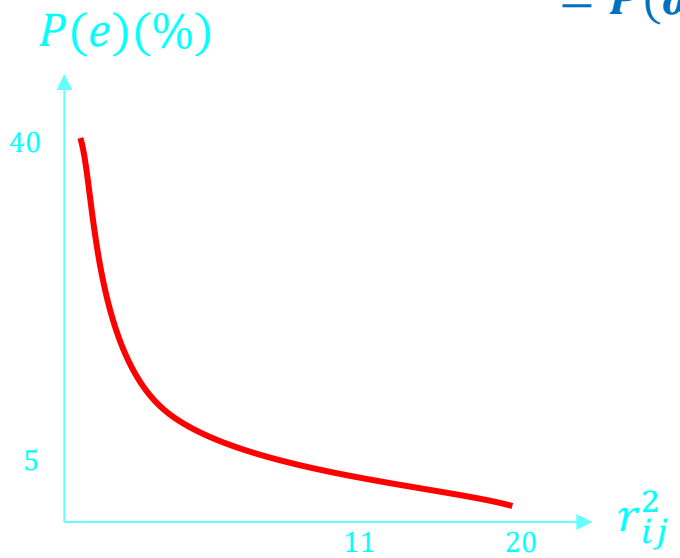
$$L_{ij}(\vec{x}) \triangleq \ln l_{ij}(\vec{x}) = \ln p(\vec{x}|\omega_i) - \ln p(\vec{x}|\omega_j)$$

$$= \vec{x}'\Sigma^{-1}(\vec{\mu}_i - \vec{\mu}_j) - \frac{1}{2}(\vec{\mu}_i + \vec{\mu}_j)'\Sigma^{-1}(\vec{\mu}_i - \vec{\mu}_j)$$

总的误判概率为

$$P(e) = P(\omega_i)P(L_{ij} < \alpha|\omega_i) + P(\omega_j)P(L_{ij} > \alpha|\omega_j)$$

$$= P(\omega_i)\Phi\left[\frac{\alpha - \frac{1}{2}r_{ij}^2}{r_{ij}}\right] + P(\omega_j)\left\{1 - \Phi\left[\frac{\alpha + \frac{1}{2}r_{ij}^2}{r_{ij}}\right]\right\}$$



最小损失准则判决

- 对一个实属ω_i类的模式采用了决策α_j所造成损失记为损失函数 $\lambda(\frac{\alpha_j}{\omega_i}) \triangleq \lambda_{ij}$
- 条件平均损失 $R_j(\vec{x}) = \sum_{i=1}^{c} \lambda_{ij} P(\omega_i|\vec{x})$
- （总的）平均损失 $R = \int_{\Omega} R_j(\vec{x}) p(\vec{x}) d\vec{x} = \sum_{j=1}^{c} \int_{\Omega_j} R_j(\vec{x}) p(\vec{x}) d\vec{x}$

$$= \sum_{i=1}^{c} P(\omega_i) E_i[\lambda(\alpha(\vec{x})|\omega_i)]$$

$$= E[\lambda(\alpha(\vec{x}))]$$

- [定理]：使条件平均损失最小的判决也必然使总的平均损失最小。
- 最小损失准则判决：$if\ R_j(\vec{x}) = \min_i[R_i(\vec{x})]\ then\ \vec{x} \in \omega_j$
- 两类问题

$$\frac{p(\vec{x}|\omega_1)}{p(\vec{x}|\omega_2)} \gtrless \frac{P(\omega_2)(\lambda_{21} - \lambda_{22})}{P(\omega_1)(\lambda_{12} - \lambda_{11})} \Rightarrow \vec{x} \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$$

最小最大损失准则

适用于$P(\omega_i)$未知或是变动的情况。

当类概密已知，损失函数λ_{ij}、类域Ω_i取定后，平均损失R是$P(\omega_i)$的线性函数

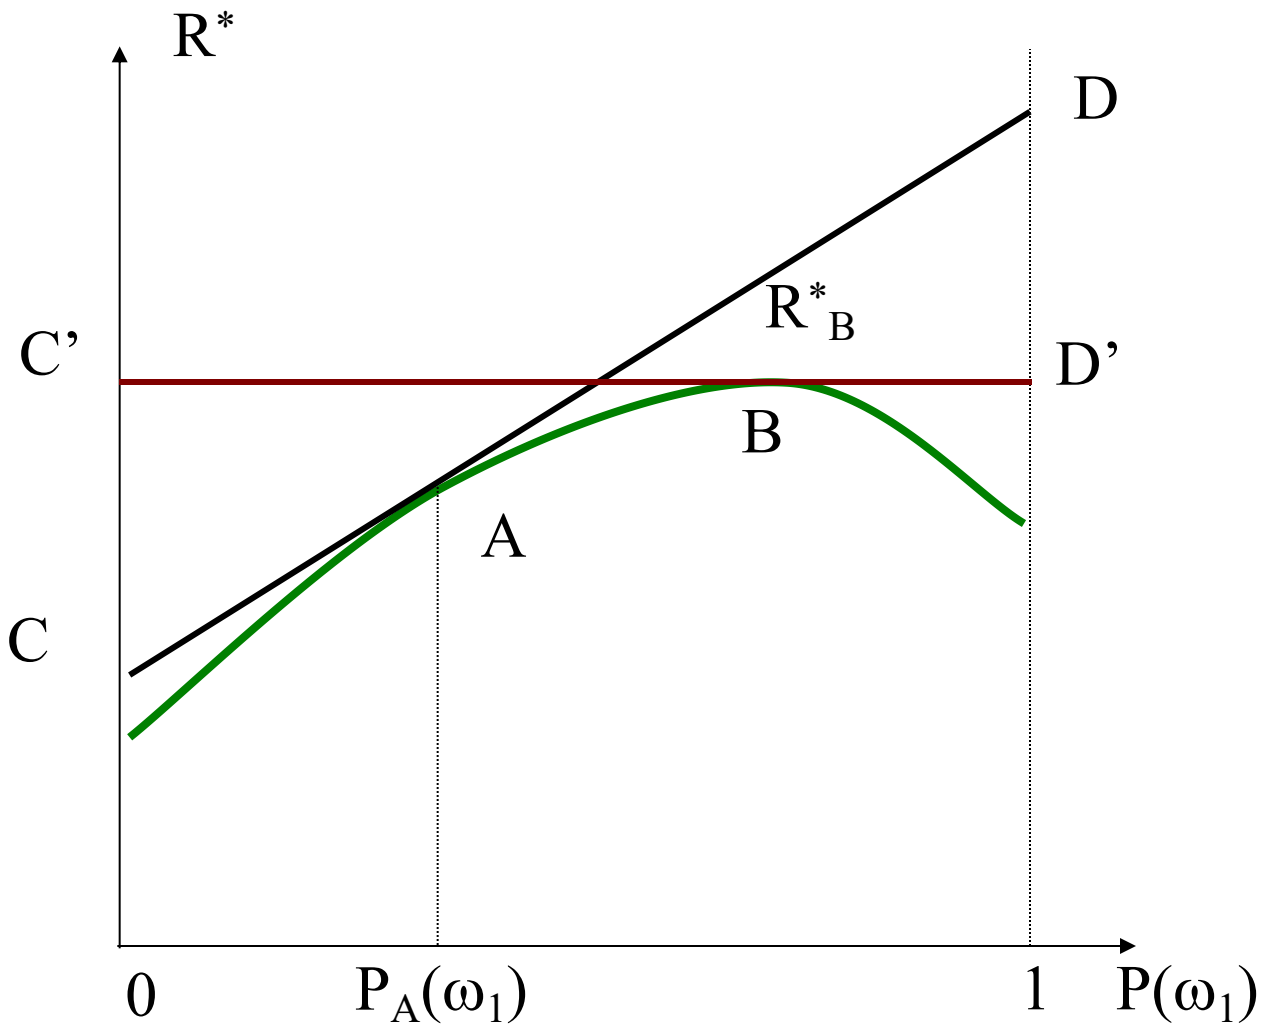
$$R = \lambda_{22} + (\lambda_{21} - \lambda_{22}) \int_{\Omega_1} p(\vec{x}|\omega_2) d\vec{x}$$

$$+P(\omega_1)[(\lambda_{11} - \lambda_{22}) + (\lambda_{12} - \lambda_{11}) \int_{\Omega_2} p(\vec{x}|\omega_1) d\vec{x} + (\lambda_{22} - \lambda_{21}) \int_{\Omega_1} p(\vec{x}|\omega_2) d\vec{x}]$$

$$\underline{\Delta}\ a + bP(\omega_1)$$

方法：按最小损失准则，对$P(\omega_i) \in (0, 1)$，计算R～$P(\omega_i)$曲线，找出使R取最大值的$P^*(\omega_i)$，然后最小损失准则对具体的模式分类识别。最小最大损失判决规则为

$$if \quad \frac{p(\vec{x}|\omega_1)}{p(\vec{x}|\omega_2)} \gtrless \frac{(\lambda_{21} - \lambda_{22})(1 - P^*(\omega_1))}{(\lambda_{12} - \lambda_{11})P^*(\omega_1)} \Rightarrow \vec{x} \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$$



$$dR(P(\omega_1))/dP(\omega_1) = b = 0$$

$$R_B^* = a = \lambda_{22} + (\lambda_{21} - \lambda_{22}) \int_{\Omega_1} p(\vec{x}|\omega_2) d\vec{x}$$

各种判决适用情况

- 在某些实际问题中，可能存在以下几种情况：
  - (1) 不知道各类的先验概率$P(\omega_i)$；
  - (2) 难于确定误判的代价λ_{ij}；
  - (3) 某一种错误较另一种错误更为重要。
- 针对(1)，可以采用最小最大损失准则或令各类概率相等的办法克服；
- 针对(2)，如果允许的话，可以避开使用损失函数而采用最小误判概率准则；
- 针对(3)，可以采用N-P判决。

统计判决要点总结

$$l_{12}(\vec{x})=\frac{p(\vec{x}|\omega_1)}{p(\vec{x}|\omega_2)}\underset{<}{\overset{>}{}}\frac{P(\omega_2)}{P(\omega_1)} \qquad \vec{x}\in\begin{cases}\omega_1\\ \omega_2\end{cases}$$

最小误判概率准则

$$l_{12}(\vec{x})=\frac{p(\vec{x}|\omega_1)}{p(\vec{x}|\omega_2)}\underset{<}{\overset{>}{}}\frac{P(\omega_2)(\lambda_{21}-\lambda_{22})}{P(\omega_1)(\lambda_{12}-\lambda_{11})} \qquad \vec{x}\in\begin{cases}\omega_1\\ \omega_2\end{cases}$$

最小损失准则

$$l_{12}(\vec{x})=\frac{p(\vec{x}|\omega_1)}{p(\vec{x}|\omega_2)}\underset{<}{\overset{>}{}}\frac{(\lambda_{21}-\lambda_{22})(1-P^*(\omega_1))}{(\lambda_{12}-\lambda_{11})P^*(\omega_1)} \qquad \vec{x}\in\begin{cases}\omega_1\\ \omega_2\end{cases}$$

最小最大损失判决准则

$$l_{12}(\vec{x})=\frac{p(\vec{x}|\omega_1)}{p(\vec{x}|\omega_2)}\underset{<}{\overset{>}{}}\lambda \qquad \vec{x}\in\begin{cases}\omega_1\\ \omega_2\end{cases}$$

N-P准则

统计决策中的训练、学习与错误率测试、估计

本章目的：

已知类别的样本（训练样本）→学习或训练→类概密

$p(\vec{x}|\omega_i)$

统计推断概述

参数估计

如果已知ω_i类的概密 $p(\vec{x}|\omega_i)$的函数类型，但不知道其中的参数或参数集 $\{\theta_i\} \triangleq \vec{\theta} = (\theta_1, \theta_2, \cdots, \theta_m)'$

→可采用参数估计确定未知参数 $\vec{\theta}$

(1) 将参数作为非随机量处理，如矩法估计、最大似然估计；

(2) 将参数作为随机变量，如贝叶斯估计。

非参数估计

当不知道类的概型时，可采用非参数估计方法，也称为总体推断，这类方法有

(1) p-窗法；

(2) 有限项正交函数级数逼近法。

最大似然估计
(Maximum Likelihood Estimate)

- 似然函数 $p(\vec{x}_1, \vec{x}_2, \cdots, \vec{x}_N; \vec{\theta})$

  称为相对于 $X^{(N)} = \{\vec{x}_1, \vec{x}_2, \cdots, \vec{x}_N\}$ 的 $\vec{\theta}$ 的似然函数。

  如果各个 $\vec{x}_j (j = 1,2,\cdots,N)$ 是独立抽取的，则有

$$p(X^{(N)}|\vec{\theta}) = p(\vec{x}_1|\vec{\theta})p(\vec{x}_2|\vec{\theta})\cdots p(\vec{x}_N|\vec{\theta}) = \prod_{j=1}^{N} p(\vec{x}_j|\vec{\theta})$$

- 最大似然估计

取 $p(X^{(N)}|\vec{\theta}) = \max_{\vec{\theta}}[p(X^{(N)}|\vec{\theta})]$ 的 $\hat{\vec{\theta}}$ 作为未知参数集的估计值。

根据已知样本$X^{(N)}$和下列似然方程组或对数似然方程组，可得 $\hat{\vec{\theta}}$

$$\frac{\partial p(X^{(N)}|\vec{\theta})}{\partial \vec{\theta}} = 0 \qquad \frac{\partial [\ln p(X^{(N)}|\vec{\theta})]}{\partial \vec{\theta}} = \sum_{j=1}^{N} \frac{\partial}{\partial \vec{\theta}} \ln p(\vec{x}_j|\vec{\theta}) = 0$$

贝叶斯估计

（1）确定未知参数集 $\vec{\theta}$ 的先验概密 $p(\vec{\theta}) = N(\vec{\theta}_0, C_0)$；

（2）由样本集 $X^{(N)}$ 求 $p(X^{(N)}|\vec{\theta})$

$$p(X^{(N)}|\vec{\theta}) = p(\vec{x}_1, \vec{x}_2, \cdots, \vec{x}_N|\vec{\theta}) = \prod_{j=1}^{N} p(\vec{x}_j|\vec{\theta})$$

这里 $p(\vec{x}_j|\vec{\theta})$ 的概型是已知的；

（3）计算

$$p(\vec{\theta}|X^{(N)}) = p(\vec{\theta}|\vec{x}_1, \vec{x}_2, \cdots, \vec{x}_N) = \alpha^{-1}(X^{(N)}) \prod_{j=1}^{N} p(\vec{x}_j|\vec{\theta}) p(\vec{\theta})$$

$$\alpha(X^{(N)}) = \int_{\Theta} p(X^{(N)}|\vec{\theta}) p(\vec{\theta}) d\vec{\theta} = \int_{\Theta} \prod_{j=1}^{N} p(\vec{x}_j|\vec{\theta}) p(\vec{\theta}) d\vec{\theta}$$

（4）计算

$$\hat{\vec{\theta}}(X^{(N)}) = \int_{\Theta} \vec{\theta}\, p(\vec{\theta}|X^{(N)}) d\vec{\theta} = E[\vec{\theta}|X^{(N)}]$$

贝叶斯学习

贝叶斯学习与贝叶斯估计前提条件是相同的，不同的是，贝叶斯学习不是进行概密的参数估计，而是进行总体概密的估计以获得 $p(\vec{x}|X^{(N)})$ 。

在前一节贝叶斯估计的四个步骤中，贝叶斯学习在执行完了前三个步骤得到未知参数的 $\vec{\theta}$ 后验概密 $p(\vec{\theta}|X^{(N)})$之后不是去求 $\hat{\vec{\theta}}$，而是直接求总体的后验概密 $p(\vec{x}|X^{(N)})$ 。

$$p(\vec{x}|X^{(N)}) = \int_{\Theta} p(\vec{x},\vec{\theta}|X^{(N)})d\vec{\theta} = \int_{\Theta} p(\vec{x}|\vec{\theta},X^{(N)})p(\vec{\theta}|X^{(N)})d\vec{\theta}$$

$$= \int_{\Theta} p(\vec{x}|\vec{\theta})p(\vec{\theta}|X^{(N)})d\vec{\theta}$$

深度学习

- 受到大脑结构分层的启发，神经网络的研究发现多隐层的人工神经网络具有优异的特征学习能力
- 学习得到的特征对数据有更本质的刻画，从而有利于可视化或分类
- 深度学习可以通过学习一种深层非线性网络结构，实现复杂函数逼近，表征输入数据分布式表示
- 深度学习网络：
  - 输入层，多层隐藏层，输出层
  - 激活函数（ReLU，Sigmoid）
  - 反向传播（随机梯度下降法，批量梯度下降法）

深度学习的过拟合



Step 1: 定义一组函数

Step 2: 模型和数据的拟合

Step 3: 选择最优函数

NO

过拟合!

在训练数据效果好?

YES

NO

在训练数据效果好?

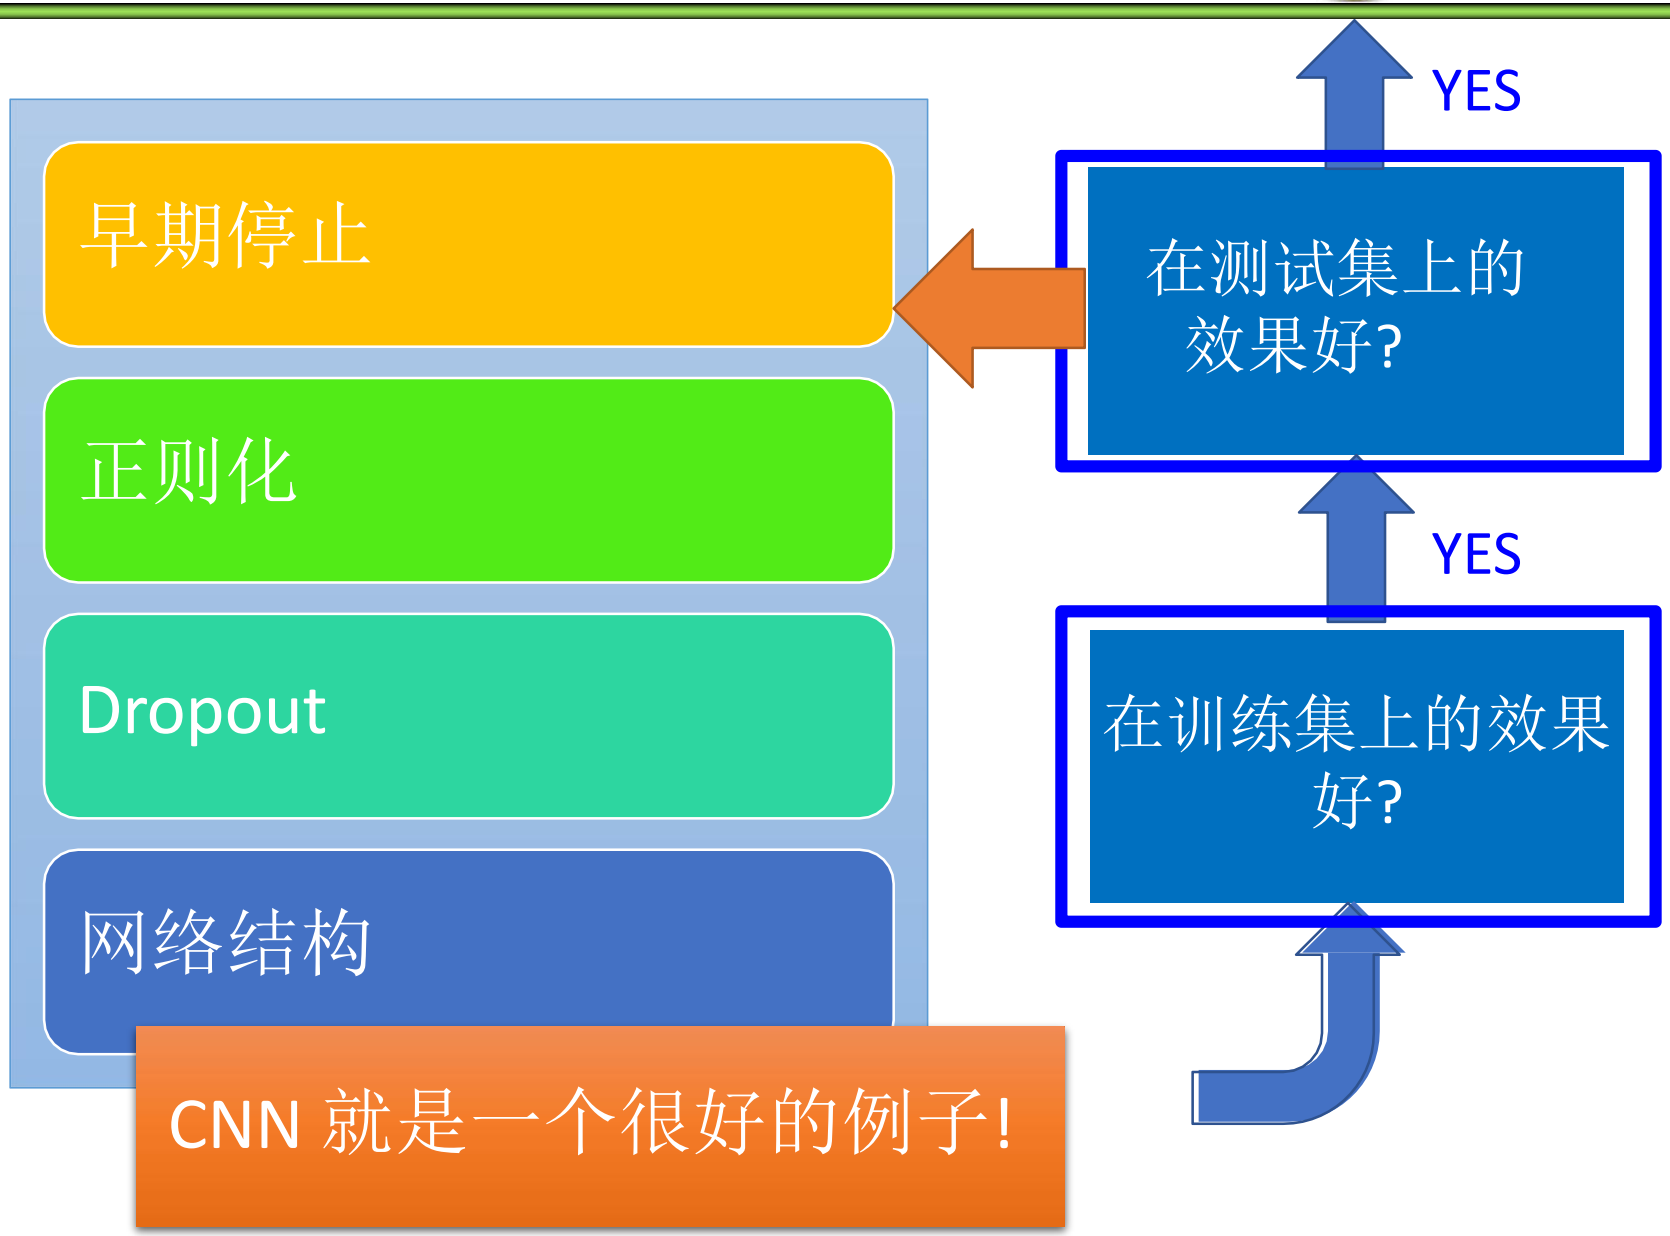
YES



神经网络

深度学习的秘诀




YES
在测试集上的效果好?
YES
在训练集上的效果好?
早期停止
正则化
Dropout
网络结构
CNN 就是一个很好的例子!

CNN网络结构



属性 1

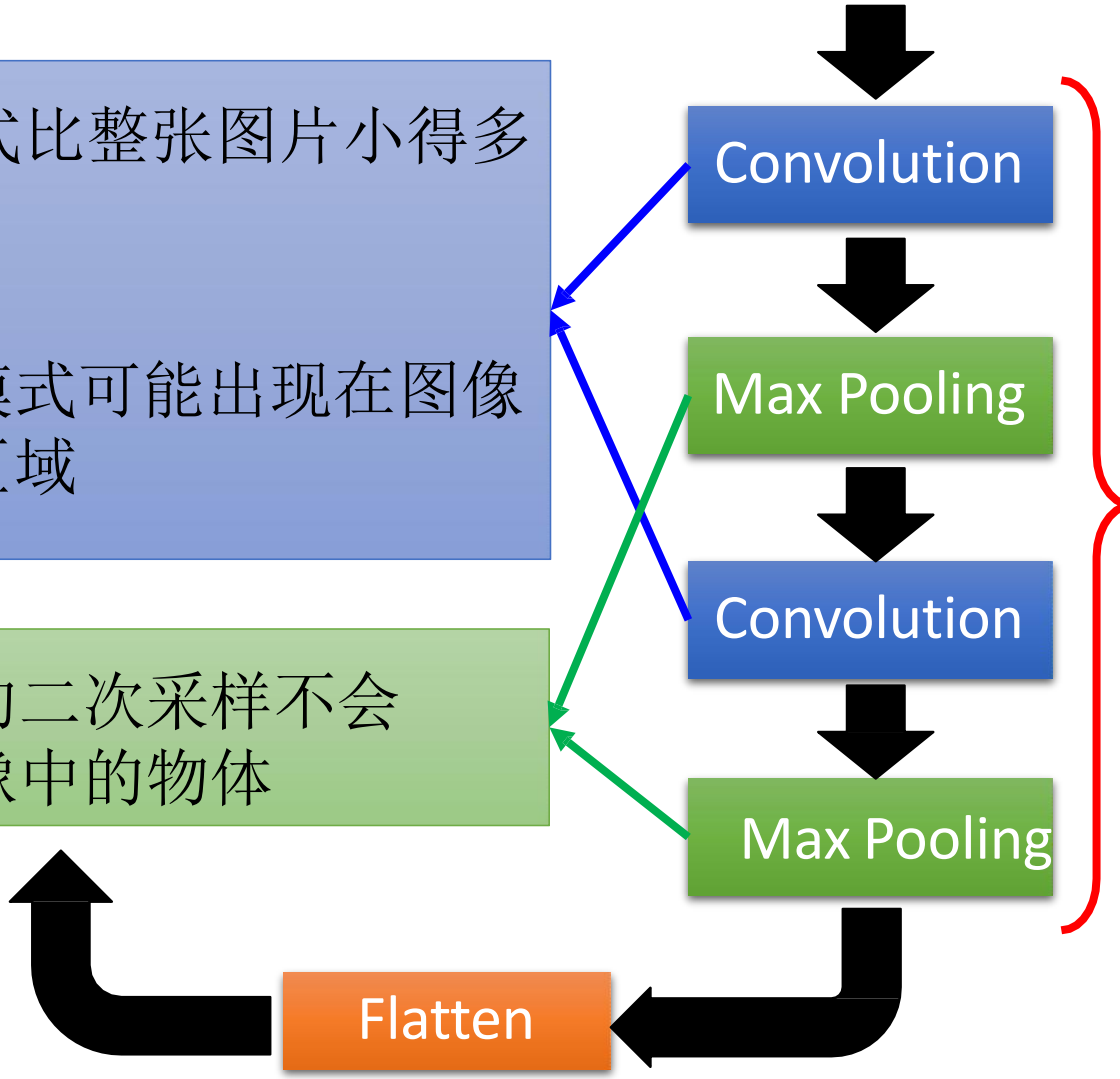
- 一些模式比整张图片小得多

属性 2

- 同样的模式可能出现在图像的不同区域

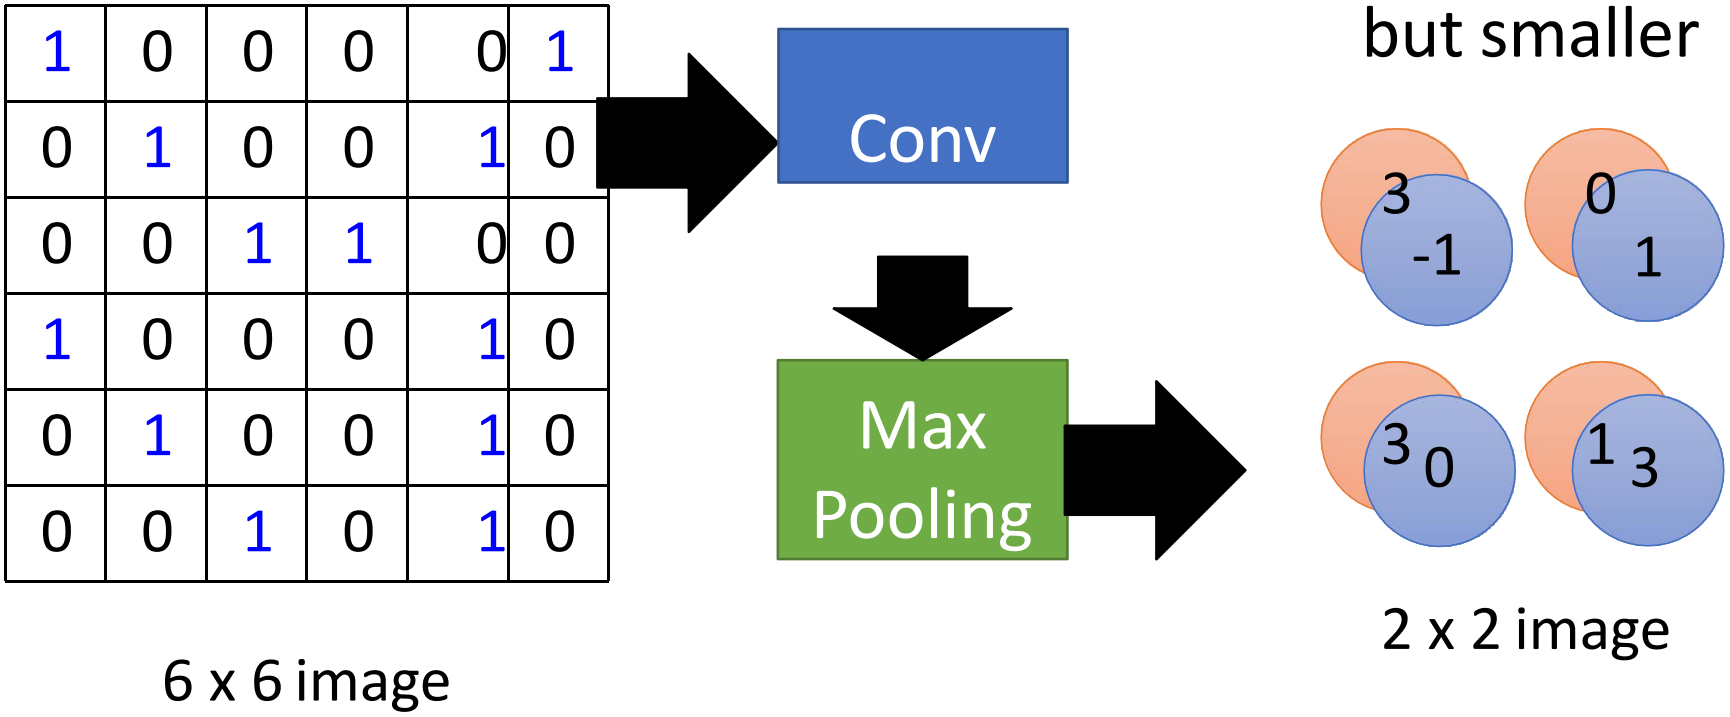
属性 3

- 对图像的二次采样不会改变图像中的物体



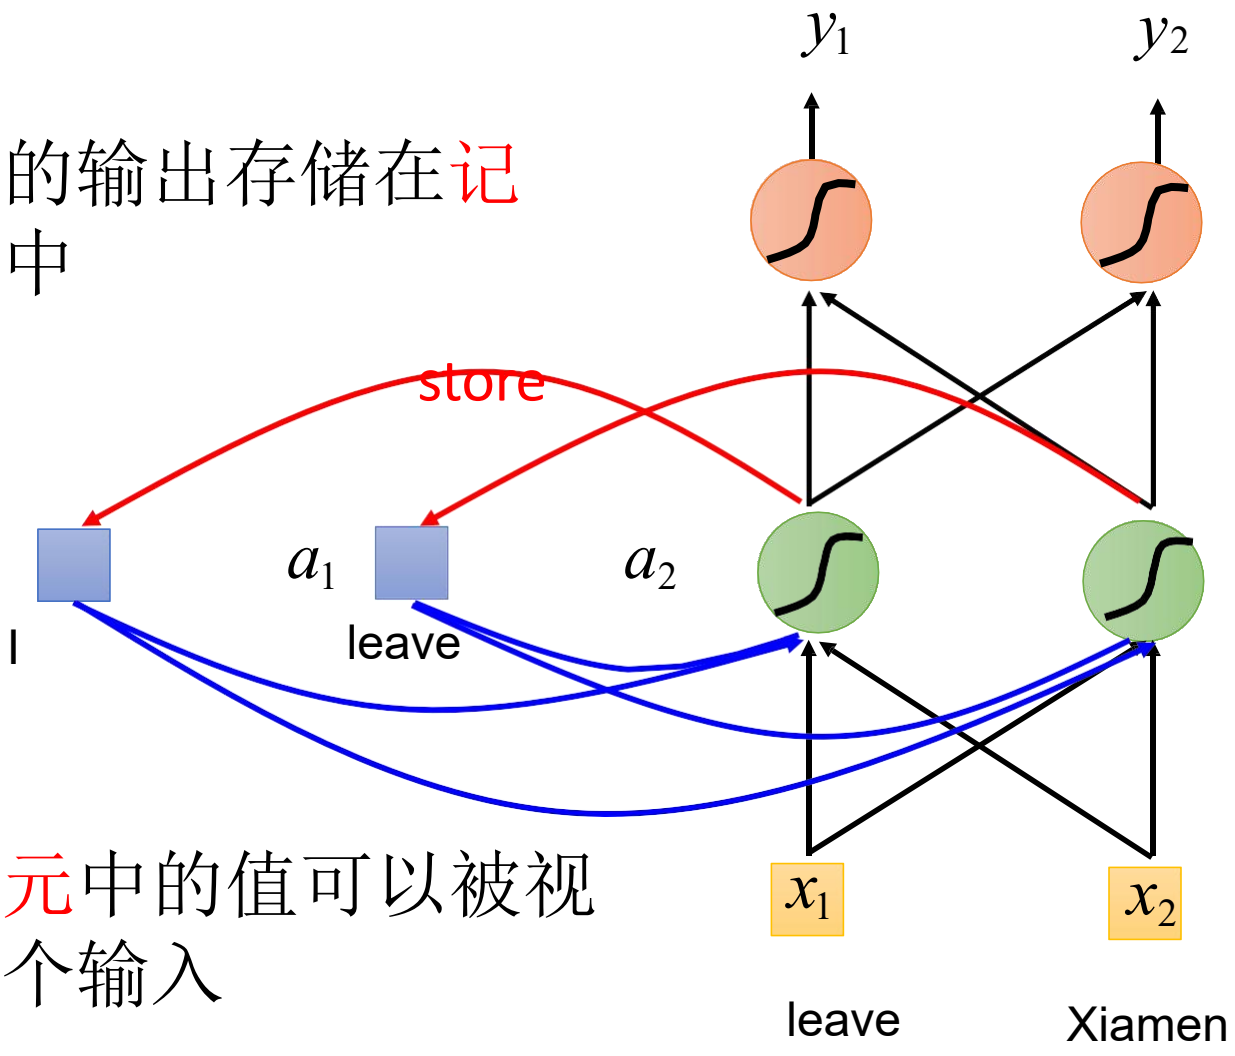
CNN – Convolution

- 卷积的相关概念：
  - 卷积核(Kernel)
  - 填充(Padding)
  - 步长(Stride)
  - 通道(Channel)



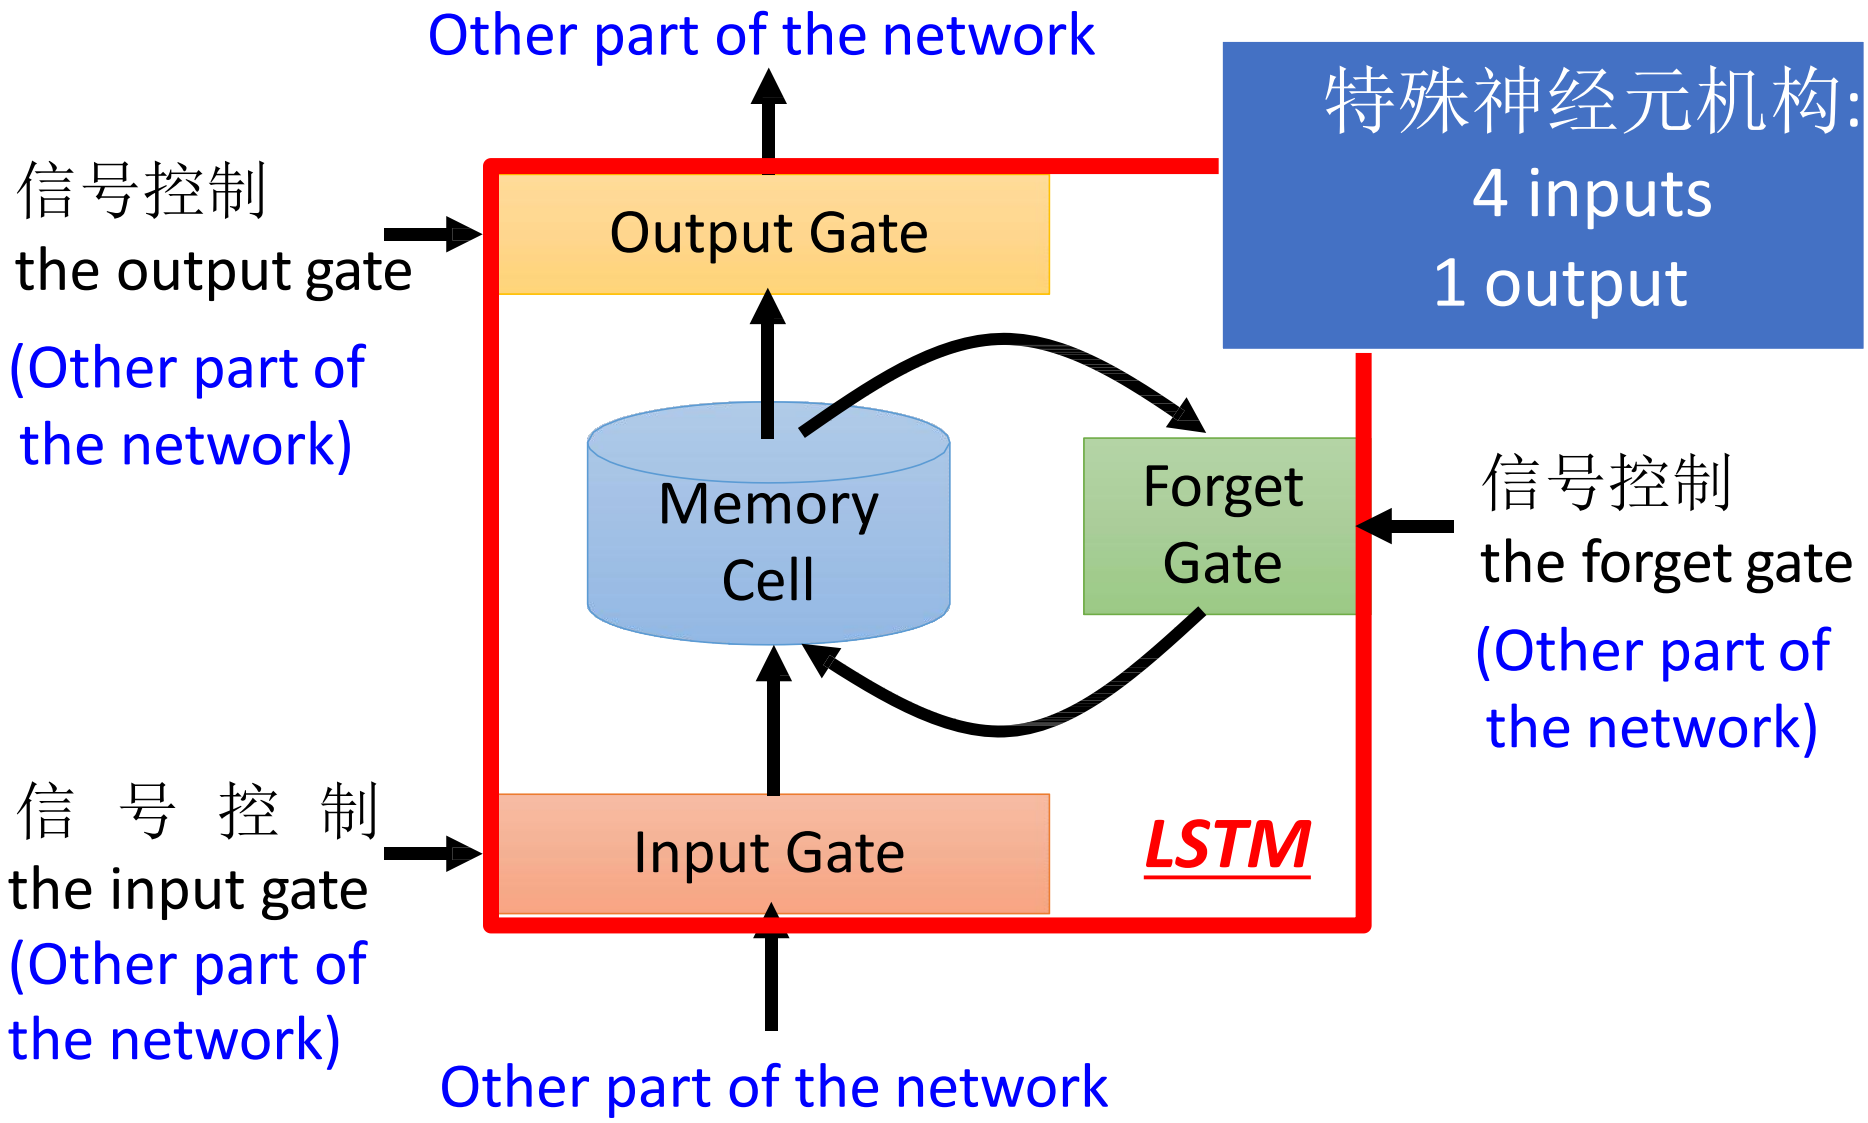
循环神经网络（RNN）

隐藏层的输出存储在记忆单元中



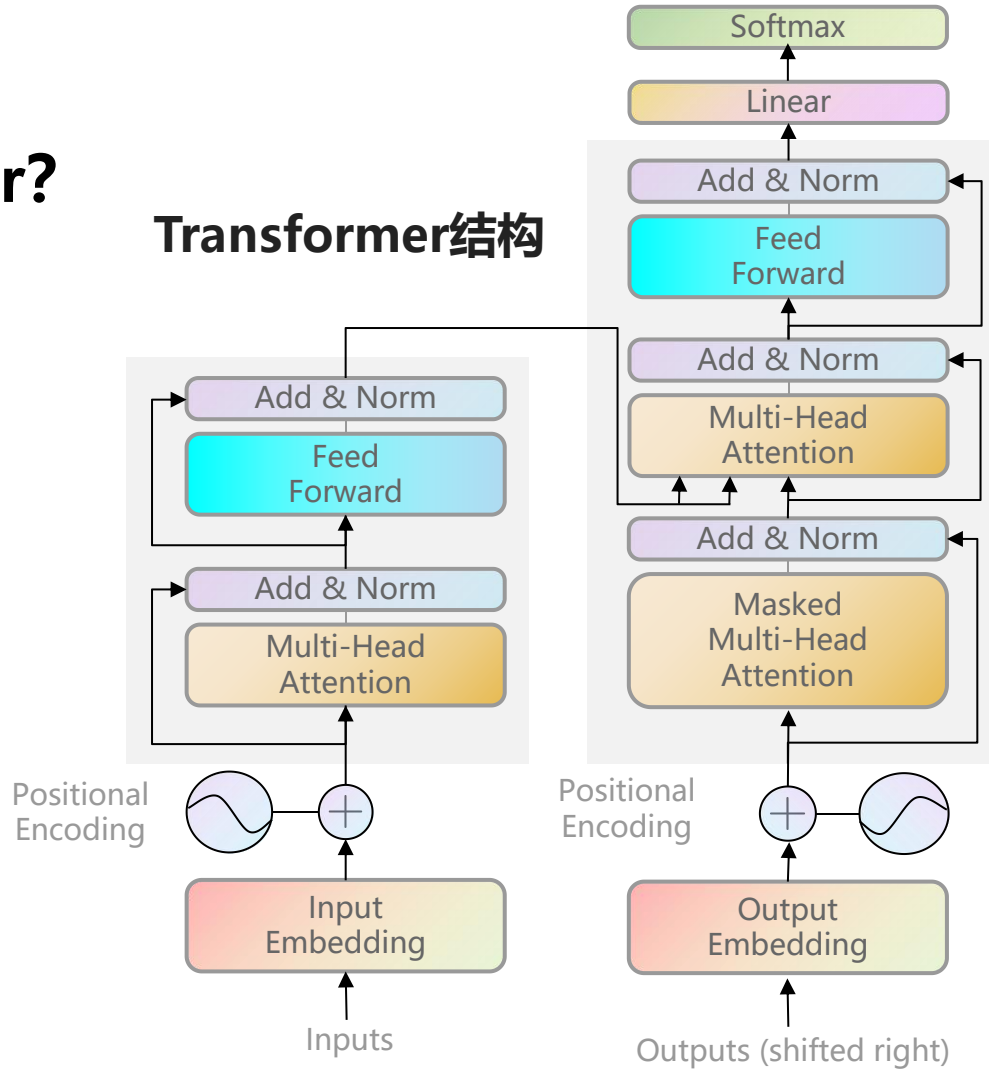
记忆单元中的值可以被视为另一个输入

Long Short-term Memory (LSTM)



Transformer

- Transformer
  - 为什么需要Transformer?
  - Encoder-Decoder模型
  - Attention注意力机制



大语言模型相关知识

- **预训练**：让模型在见到特定任务数据之前，先通过学习大量通用数据来捕获广泛有用的特征，从而提升模型在目标任务上的表现和泛化能力。
  - 自回归语言模型
  - 自编码语言模型
- **微调**：通过在新任务的少量标注数据上进一步训练预训练模型，使模型能够学习到与目标任务相关的特定特征和规律，从而更好地适应新任务。
  - 监督微调
  - 基于人类反馈的强化学习微调
  - 全量微调
  - 参数高效微调（LoRA，Adapters）

大语言模型相关知识

- **Prompt**：一段用于引导模型理解问题的文本，通常位于问题的开头或结尾。它用于为模型提供上下文和任务要求，以帮助模型更好地理解和回答问题。
  - Zero-shot Prompt
  - Few-shot Prompt
- **思维链**：通过让大模型逐步参与将一个复杂问题分解为一步一步的子问题并依次进行求解的过程可以显著提升大模型的性能。而这些推理的中间步骤就被称为思维链。
- **检索增强生成RAG**：一种结合了信息检索技术与语言生成模型的人工智能技术。该技术通过从外部知识库中检索相关信息，并将其作为提示（Prompt）输入给大型语言模型（LLMs），以增强模型处理知识密集型任务的能力，如问答、文本摘要、内容生成等。

期末考试

- 题型
  - 一、概念解释（10个，30分）
  - 二、单选/多选题（10个，30分）
  - 三、简答题（4个，40分）
- 时间
  - 6月7日（本周六） 19：10-20：50
- 地点
  - 学武楼C201

预祝各位同学考试顺利！